

Proyecto 5: OpenFACADES

Carlos Sanchiz Pérez

Nicolás Vives Vicente

Escuela Politécnica Superior

Máster Universitario en Ciencia de Datos

Modelado Computacional, Simulación y Optimización

Curso académico [2025-2026]



Universitat d'Alacant
Universidad de Alicante

Índice

1. Resumen	4
2. Objetivos	5
2.1. Planteamiento del problema	5
2.2. Objetivo general	5
2.3. Objetivos específicos	5
2.4. Hipótesis de partida	6
2.4.1. Justificación de la expansión	7
2.5. Reparto de tareas del equipo	7
3. Estado del Arte	8
3.1. Evolución del análisis urbano	8
3.2. Aplicaciones del <i>framework</i> OpenFACADES	9
4. Metodología y modelado	10
4.1. Casos de estudio y diseño	11
4.2. Datos geoespaciales y huellas de edificios	12
4.3. Recuperación de Imágenes a Nivel de Calle (SVI)	13
4.3.1. De Mapillary a Google Street View	14
4.3.2. Sistema de recuperación SVI	14
4.4. Procesamiento de las imágenes y extracción de fachadas	15
4.4.1. Fase 1: Descarga de metadatos y cálculo del ángulo de Visión (AOV)	15
4.4.2. Fase 2: Descarga de panorámicas	15
4.4.3. Fase 3: Detección y recorte mediante GroundingDINO	16
4.4.4. Fase 4: Filtrado de calidad visual	16
4.5. Inferencia semántica mediante Visión-Lenguaje (VLM)	17
4.5.1. Balanceo estadístico y deduplicación	17
4.5.2. Ingeniería de <i>prompts</i> y extracción de atributos	18
4.5.3. Procesamiento de los resultados obtenidos del modelo	22

5. Resultados	24
5.1. Resultados de la extracción y filtrado	24
5.2. Resultados de la Captura SVI y la extracción de fachadas	25
5.2.1. Análisis de la extracción visual	25
5.3. Resultados de la inferencia	26
5.3.1. Resultados del balanceo estadístico y deduplicación	26
5.4. Rendimiento del VLM y evaluación del procesamiento de los <i>outputs</i>	27
5.5. Análisis de los atributos estructurales base	29
5.5.1. Análisis de la distribución de los tipos de edificios	29
5.5.2. Análisis de la antigüedad de los edificios	31
5.5.3. Análisis de materiales de las fachadas	32
5.5.4. Análisis de la distribución del número de plantas	34
5.5.5. Análisis de los materiales de construcción estructurales	35
5.6. Análisis de las características extra	37
5.6.1. Análisis de elementos singulares	37
5.6.2. Análisis de la distribución de estilos arquitectónicos	38
5.6.3. Análisis del estado de conservación visible	40
5.6.4. Análisis de la proporción de acristalamiento	41
5.7. Análisis de score (Sentimientos)	43
5.7.1. Análisis individual	44
5.7.2. Análisis de la percepción estética y visual	45
5.7.3. Matrices de correlación	46
6. Conclusiones	48
A. Anexo	50

1. Resumen

El análisis de arquitecturas y morfología a escala urbana ha dependido tradicionalmente de un costoso trabajo de campo manual o de bases de datos espaciales que carecen de información detallada a nivel de calle. Para abordar este desafío, esta investigación explora, adapta y expande el entorno de trabajo de código abierto OpenFACADES [8], combinando el uso de Imágenes a Nivel de Calle (SVI) extraídas de Mapillary con Modelos de Visión-Lenguaje (VLM) avanzados para la catalogación automatizada de las fachadas de entornos urbanos. El objetivo principal es desarrollar un pipeline que permita realizar un estudio comparativo de las arquitecturas de cuatro grandes capitales: Madrid, París, Ámsterdam y Nueva York (Manhattan), realizando mejoras al proyecto original según se avanza en la realización de este estudio.

La metodología implementada supera las limitaciones del modelo base. Se realizó una mejora al proyecto original aplicando filtros a las estructuras antes de aplicar el modelo de detección Zero-Shot (GroundingDINO) para el aislamiento preciso de las fachadas. Durante la fase de inferencia (utilizando InternVL), se implementó una estrategia de ingeniería de prompts divididos para evitar la saturación del contexto, logrando extraer no solo características morfológicas, sino también emulando el etiquetado humano de percepción estética (complejidad, originalidad, monotonía, orden y atractivo). Debido a la naturaleza probabilística del VLM, se desarrolló un sistema de postprocesamiento que logró recuperar con un 95,12 % de éxito al solucionar los errores sintácticos de formato JSON generados por el modelo, consolidando una matriz final de 2.400 registros válidos.

Los resultados del Análisis Exploratorio de Datos (EDA) muestran profundas diferencias. Manhattan se perfila como una anomalía frente a la muestra europea, dominada por las estructuras comerciales. Pueden verse altas varianzas en altura, estilos modernos y diferencias notables en la evaluación estética de su arquitectura industrial y corporativa. Por el contrario, Madrid, París y Ámsterdam consolidan el modelo de “ciudad mixta”, aunque con identidades únicas detectadas por la IA: la gran presencia del ladrillo y alta cantidad de ventanas en Ámsterdam, frente al clasicismo de París y las arquitecturas tradicionales de Madrid.

Este trabajo demuestra la viabilidad de integrar la Inteligencia Artificial generativa y los Sistemas de Información Geográfica para enriquecer la extracción de información de entornos urbanos sin la necesidad de encuestas costosas y lentas, capturando de forma automatizada las características de interés.

2. Objetivos

2.1. Planteamiento del problema

En la actualidad, el análisis arquitectónico de las ciudades a gran escala presenta un desafío importante. Tradicionalmente, catalogar el estilo, los materiales o el estado de conservación de las fachadas requería de trabajo manual, lo cual resulta lento y costoso. Aunque existen bases de datos espaciales, estas suelen carecer de información detallada sobre el aspecto de los edificios a pie de calle.

El proyecto de código abierto *OpenFACADES* surge como una solución a este problema, proponiendo el uso de imágenes panorámicas a pie de calle (Street View) combinadas con Inteligencia Artificial capaz de “leer” imágenes (Modelos de Visión-Lenguaje o VLM) para extraer información y características arquitectónicas. Sin embargo, el modelo original presenta limitaciones en la extracción de grandes cantidades de datos y en el nivel de detalle de la información que es capaz de reconocer.

2.2. Objetivo general

El objetivo principal de este trabajo es **explorar, adaptar y expandir en la medida de lo posible el *framework* OpenFACADES**. Para lograrlo se establece una idea principal, que es la extracción de imágenes de regiones de 4 capitales mundiales muy importantes, como son Madrid, París, Nueva York y Ámsterdam. La idea es realizar un estudio completo sobre las características arquitectónicas de estas ciudades a la vez que se cumplen los objetivos concretos que se exponen en la siguiente sección.

2.3. Objetivos específicos

Para alcanzar el objetivo general, se han planteado los siguientes objetivos específicos, que pueden ser considerados mejoras sobre el modelo base:

1. **Filtro geométrico:** Implementar un sistema de limpieza del espacio, que descarte edificaciones no relevantes para el proyecto como quioscos, cobertizos o enormes estructuras como un estadio de fútbol. Para ello se desarrolla un código que se basa en el cálculo del área de las imágenes satelitales de los edificios, asegurando que solo se tengan en cuenta edificios con una superficie entre los límites establecidos.

2. **Simular etiquetado de sentimientos humanos con la IA:** En el artículo del trabajo [7], correspondiente a uno de los proyectos realizados a partir del repositorio OpenFACADES [8], el análisis principal era la inferencia de sentimientos de un grupo de personas encuestadas sobre las fachadas de los edificios a un conjunto mucho más grande de imágenes de fachadas a través de un modelo de IA. Puesto que no se dispone de los datos de este artículo trataremos de emularlo prescindiendo de las etiquetas humanas y utilizando únicamente el modelo de Inteligencia Artificial.
3. **Análisis comparativo:** Cualquier fase del proyecto se realiza con el fin de poder hacer un análisis comparativo y visual sobre las 4 capitales: Madrid, París, Nueva York y Ámsterdam.

2.4. Hipótesis de partida

El planteamiento base del repositorio OpenFACADES [8], utiliza la combinación de plataformas de imágenes a nivel de calle (SVI) y Modelos de Visión-Lenguaje (VLMs) para sustituir el trabajo de catalogación de fachadas por humanos.

Los *notebooks* de referencia proporcionados en el repositorio original establecen un flujo de trabajo básico, estructurado en las siguientes fases que sirven como punto de partida para este trabajo:

1. **Adquisición SVI mediante Mapillary:** A partir de unas coordenadas geográficas simples (*Bounding Box*), el código base se conecta a la API de Mapillary para descargar metadatos de imágenes panorámicas y cruza las coordenadas de la cámara con las huellas de los edificios (procedentes nativamente de OpenStreetMap) para seleccionar aquellas fotografías que apuntan directamente hacia las fachadas.
2. **Detección y recorte (*Cropping*):** Dado que las imágenes descargadas son panorámicas esféricas (360 grados), el código original utiliza un modelo de detección de objetos *Zero-Shot* (como GroundingDINO), lo que permite enmarcar y recortar la región específica de la imagen donde se encuentra el edificio.
3. **Inferencia base:** Mediante un *prompt* predefinido, el modelo base está configurado para extraer exclusivamente ocho características estructurales y materiales, devolviéndolas en formato JSON:
 - `building_type` (Uso principal del edificio).
 - `alternate_building_type` (Uso secundario o alternativo).

- `building_age` (Año aproximado de construcción).
- `floors` (Número total de plantas).
- `surface_material` (Material principal de revestimiento de la fachada).
- `alternate_surface_material` (Material secundario de la fachada).
- `construction_material` (Material principal de la estructura del edificio).
- `alternate_construction_material` (Material estructural secundario).

2.4.1. Justificación de la expansión

Si bien este flujo de trabajo original demuestra ser viable en concepto, los *notebooks* del repositorio están diseñados como pruebas de concepto para entornos muy controlados y volúmenes de datos reducidos. El código base asume un comportamiento ideal de la red, una disponibilidad homogénea de imágenes y una respuesta perfecta por parte de la IA.

Como hipótesis de desarrollo de este proyecto, se plantea que para escalar esta arquitectura a un análisis más grande, automatizado y comparativo de grandes capitales mundiales, el modelo base resulta insuficiente. No dispone de filtros geométricos previos, carece de mecanismos de rescate frente a los errores de formato (no seguir el JSON) generados por el VLM, sufre bloqueos de red al extraer huellas de OSM y su análisis no contempla elementos singulares ni permite replicar el estudio del análisis perceptual. Sobre estas carencias se fundamentan los objetivos específicos y el desarrollo del trabajo.

2.5. Reparto de tareas del equipo

Para el correcto desarrollo de este proyecto, las tareas se han distribuido de la siguiente manera entre los miembros del equipo:

- **Carlos Sanchiz:** Responsable de la fase de inferencia mediante Inteligencia Artificial. Se encargó del diseño e ingeniería de *prompts*, la ejecución del Modelo de Visión-Lenguaje (VLM) y el procesamiento de los resultados. Esto incluyó el desarrollo del proceso de limpieza y consolidación de los datos (JSON a CSV). En la fase final de análisis visual, se centró principalmente en las métricas subjetivas de percepción estética humana simulada por la IA (*scores*) y también en las características singulares implementadas como mejora.

- **Nicolás Vives:** Responsable de la fase de captura de imágenes y preprocesamiento. Llevó a cabo la fase inicial del flujo de trabajo, incluyendo la integración con *Overture Maps*, el filtrado geométrico de las huellas de edificios, y la captura fotográfica interactuando con las APIs de *Mapillary* así como el intento de prueba con *Google Street View* y el modelo de detección *GroundingDINO* para el recorte de fachadas. En la fase del análisis visual se centró en los atributos arquitectónicos base y también en las características singulares implementadas como mejora.

Ambos miembros hemos colaborado en totalidad en la toma de decisiones metodológicas y la redacción e interpretación de los resultados globales.

3. Estado del Arte

Para comprender la relevancia y la innovación que aporta el *framework OpenFACADES* además de las mejoras implementadas en este proyecto, es necesario repasar la evolución de las metodologías de análisis urbano, desde los procesos manuales hasta la actual irrupción de la Inteligencia Artificial Generativa.

3.1. Evolución del análisis urbano

Históricamente, el estudio de la arquitectura de las ciudades a gran escala ha estado limitado por la disponibilidad de datos. Los métodos tradicionales requerían trabajo de humano, encuestas y auditorías manuales, lo que restringía los estudios a barrios pequeños o calles específicas [10].

Con la llegada de los Sistemas de Información Geográfica (SIG) y el catastro digital, se logró escalar el análisis espacial. Sin embargo, estas bases de datos suelen ser bidimensionales (huellas de edificios o *footprints*) o modelos 3D de bajo nivel de detalle, los cuales carecen de información relevante sobre el aspecto visual, los materiales o la antigüedad de las fachadas a nivel de calle [2].

Para superar la falta de datos visuales, la comunidad científica comenzó a utilizar Imágenes a Pie de Calle (SVI, por sus siglas en inglés: *Street View Imagery*). Plataformas comerciales como *Google Street View* y repositorios colaborativos de código abierto como *Mapillary* han democratizado el acceso a imágenes panorámicas de 360 grados de casi cualquier entorno urbano del mundo [1].

En la última década, las imágenes SVI se han utilizado extensamente para evaluar el índice de vegetación, la transitabilidad de las aceras o la percepción de seguridad [4]. No obstante, extraer información arquitectónica específica de un solo edificio en una foto panorámica donde aparecen coches, árboles y peatones seguía siendo un desafío complicado.

El verdadero punto de inflexión ocurrió con la aplicación del *Deep Learning* al análisis urbano. Inicialmente, se utilizaron Redes Neuronales Convolucionales (CNNs) para tareas de segmentación semántica de imágenes. Estos modelos clásicos podían dibujar “cajas” alrededor de ventanas o puertas. Sin embargo, eran modelos rígidos: solo podían detectar aquello para lo que habían sido estrictamente entrenados y fallaban al intentar comprender conceptos abstractos como el “estilo arquitectónico” o el “estado de conservación” [11].

En los últimos años, el estado del arte ha sido redefinido por los **Modelos Fundacionales y de Visión-Lenguaje (VLM)**. Herramientas como *GroundingDINO* (utilizado en la fase de extracción de este proyecto) permiten detectar y recortar fachadas simplemente usando texto (*prompts*), sin necesidad de reentrenar el modelo. Posteriormente, modelos avanzados como CLIP, LLaVA o InternVL son capaces de procesar la imagen del edificio y “razonar” sobre ella, respondiendo a preguntas complejas en formato de texto o JSON [9].

El proyecto *OpenFACADES* representa el estado del arte actual al unificar la descarga de imágenes SVI, el recorte inteligente de fachadas y la inferencia mediante VLM en un único flujo de trabajo automatizado.

3.2. Aplicaciones del *framework* OpenFACADES

El entorno de trabajo propuesto por *OpenFACADES* ha impulsado diversas líneas de investigación aplicadas a la caracterización del entorno construido. A continuación, se destacan los principales casos de uso y las evoluciones de esta herramienta en la literatura reciente:

- **Decodificación morfológica mediante VLMs:** En la base del ecosistema se sitúan las investigaciones fundamentales que validaron la utilidad de los Modelos de Visión-Lenguaje para la extracción de características arquitectónicas. Trabajos como el de Liang et al. (2025) [5] demostraron la capacidad de automatizar la lectura de tipologías, materiales y épocas de construcción directamente desde imágenes SVI como en el repositorio original.

- **Predicción de atributos mediante Redes Neuronales de Grafos:** La evolución del *framework* ha permitido dar el salto de la mera extracción visual a la predicción analítica compleja. Investigaciones posteriores [6] han implementado Redes Neuronales de Grafos Heterogéneos (HGNN) para combinar características urbanas jerárquicas con imágenes de vistas cruzadas (*cross-view imagery*, combinando vista satelital y de calle), permitiendo inferir atributos de los edificios con un alto nivel de precisión a escala urbana.
- **Gemelos Digitales (Digital Twins) enriquecidos:** Otro avance crucial derivado de esta tecnología ha sido la integración de metadatos cualitativos en entornos de simulación espacial. El trabajo de [3] aplicó estas metodologías para incorporar la percepción humana directamente en modelos de ciudad 3D y gemelos digitales urbanos.
- **Evaluación de la percepción y el sentimiento humano:** Por último, destaca la línea de investigación enfocada en cuantificar cómo los observadores perciben estética y psicológicamente la envolvente arquitectónica. El estudio de Liang et al. (2024) [7] establece un mecanismo para evaluar el sentimiento humano hacia los exteriores de los edificios utilizando redes neuronales y SVI. Este trabajo constituye el pilar teórico y la principal referencia de este trabajo, del cual como se ha comentado inspira el objetivo de emular el etiquetado humano subjetivo (complejidad visual, originalidad, orden, monotonía y atractivo) de forma automatizada mediante inferencia VLM.

Este trabajo se posiciona en este punto, no solo validando el modelo original, sino tratando de resolver sus carencias reales y mejorarlo en la medida de lo posible, ya que nos ajustamos a los límites computacionales de Google Colab.

4. Metodología y modelado

El camino a seguir propuesto para cumplir los objetivos expuestos se divide en un flujo de trabajo estructurado en las fases de extracción espacial, procesamiento visual e inferencia semántica. Para abordar las limitaciones del modelo base y escalar el entorno de *OpenFACADES* a un estudio comparativo entre ciudades, la arquitectura se ha diseñado como un *pipeline* que combina Sistemas de Información Geográfica (SIG), visión computacional y modelos de Inteligencia Artificial.

4.1. Casos de estudio y diseño

Antes de definir las áreas de estudio definitivas que se describen a continuación, se llevó a cabo una exhaustiva fase de exploración con el objetivo de identificar regiones urbanas con una gran relevancia arquitectónica y una densidad suficiente de imágenes a nivel de calle en la plataforma Mapillary. Durante este proceso, se ha visto que numerosos sectores urbanos de gran importancia, como el AZCA de Madrid o las principales avenidas de Barcelona, presentan dificultades para la toma de imágenes. En el caso del distrito financiero madrileño el problema era directamente una falta de imágenes en Mapillary, mientras que en Barcelona se tenía el problema de la distancia desde el punto de toma de la foto hasta la fachada, que debido a la amplitud de las calles en la mayoría de casos resultaba demasiado lejana.

Bajo este criterio, para garantizar un análisis comparativo con un notable contraste de arquitectura, se han seleccionado cuatro zonas urbanas delimitadas por coordenadas (*bounding box*) correspondientes a cuatro importantes capitales históricas:

- **Madrid (Centro histórico):** Se ha acotado una zona de alta densidad urbana para evaluar la arquitectura tradicional española. Coordenadas BBOX: [-3.7140, 40.4110, -3.7040, 40.4170].
- **París (Entorno Haussmann):** Centrado cerca de la Ópera, buscando identificar la predominancia de la piedra caliza y los característicos balcones y cornisas. Coordenadas BBOX: [2.3250, 48.8700, 2.3350, 48.8750].
- **Nueva York (Manhattan/SoHo):** Seleccionado para contrastar con la arquitectura europea mediante la detección de fachadas de ladrillo, acero y escaleras de incendios exteriores. Coordenadas BBOX: [-74.0040, 40.7200, -73.9950, 40.7260].
- **Ámsterdam (Canales Centrales):** Escogido por sus particulares parcelas estrechas y su predominancia del ladrillo. Coordenadas BBOX: [4.8840, 52.3680, 4.8920, 52.3740].

Una vez establecidas las regiones a estudiar se crea un grupo de directorios independiente para cada una de estas zonas, separando los datos geométricos, las imágenes y los resultados finales.

4.2. Datos geoespaciales y huellas de edificios

El proceso comienza con la delimitación de las regiones geográficas de interés para el estudio mediante una *bounding box*. A partir de estas coordenadas de latitud y longitud, el sistema realiza una consulta a bases de datos vectoriales abiertas para extraer las huellas geométricas de los edificios existentes.

Aunque el *framework* original contempla la unión de datos procedentes de OpenStreet-Map (OSM) y Overture Maps, las restricciones de tráfico y las políticas de bloqueo por IP que sufren los servidores públicos de la API de OSM desde entornos de computación en la nube (como Google Colab) introducen demasiadas dificultades a las que no se puede hacer frente. Para continuar con el proyecto mitigando esta limitación se utiliza exclusivamente el ecosistema de *Overture Maps*. Al tratarse de datos abiertos respaldados por infraestructura de escala global, Overture proporciona réplicas espaciales optimizadas que integran los polígonos de OSM junto con detecciones automatizadas mediante inteligencia artificial y fotografía satelital.

Para ser más eficientes y conseguir un conjunto de datos más estable, se realiza un filtrado de edificios según su huella. La idea es eliminar aquellas edificaciones demasiado pequeñas que puedan corresponder a trasteros o garajes y aquellas demasiado grandes como estadios de fútbol, naves o recintos de eventos.

Una vez recuperados los polígonos vectoriales brutos (nativamente bajo el sistema de coordenadas geográficas WGS84, EPSG:4326), para poder calcular su área se aplica una reproyección hacia el sistema métrico local Transversa de Mercator (UTM) correspondiente a cada ciudad (Zona 30N para Madrid, Zona 31N para París y Ámsterdam, y Zona 18N para Nueva York). Esta transformación es un paso clave, ya que el cálculo directo de áreas sobre una proyección de curvatura terrestre puede inducir graves distorsiones geométricas.

Una vez proyectadas a unidades métricas reales, se calcula la superficie (m^2) de cada parcela y se aplica de forma inmediata el filtro:

$$30 \text{ m}^2 \leq \text{Área_edificio} \leq 15000 \text{ m}^2 \quad (1)$$

El límite inferior (30 m^2) descarta infraestructuras urbanas u objetos atípicos que no constituyen fachadas habitables (garajes, quioscos, marquesinas, casetas de ventilación). El límite superior (15000 m^2) excluye estructuras enormes (estadios, complejos industriales o ferroviarios). Adicionalmente, se elimina cualquier estructura catalogada explícitamente con el atributo *underground* (subterráneo).

Los polígonos que superan esta criba se exportan directamente a archivos estructurados GeoJSON, conformando el inventario base para la posterior ingesta de imágenes SVI.




Figura 1: Visualización de las huellas de edificios (*footprints*) extraídas mediante *Overture Maps* para las cuatro zonas de estudio: Madrid, París, Nueva York y Ámsterdam.

4.3. Recuperación de Imágenes a Nivel de Calle (SVI)

Una vez se tienen los polígonos que representan la base de las edificaciones, se inicia la fase de captura fotográfica interactuando con las APIs de plataformas de imágenes a nivel de calle.

4.3.1. De Mapillary a Google Street View

Uno de los mayores retos que presenta el trabajo es la integración de más plataformas SVI además de Mapillary, y así precisamente se especifica en el repositorio oficial [8]. Se ha tratado de realizar la mejora utilizando Google Street View, que dispone de una cantidad de imágenes infinitamente superior a Mapillary pero su implementación presenta barreras infranqueables asociadas a las políticas comerciales y de seguridad.

En primer lugar, el ecosistema de Google exige la vinculación de una cuenta de facturación y establece cuotas de peticiones muy restrictivas. La descarga de miles de panorámicas de alta resolución para ciudades como Nueva York o París, agotaba rápidamente los límites del nivel gratuito, convirtiendo esta vía en una opción inviable para este trabajo académico.

En segundo lugar, al intentar utilizar herramientas de extracción secundarias para mitigar las restricciones de la API oficial, surgieron problemas de conectividad. Los sistemas de seguridad de Google detectan el tráfico masivo automatizado proveniente de las direcciones IP de los centros de datos en la nube (como es el caso de las máquinas virtuales de Google Colab). Lo que da lugar al bloqueo intermitente de las conexiones y a la denegación del servicio, provocando errores críticos de ejecución (*dataframes* vacíos o interrupciones de red).

Ante la inviabilidad de esta mejora, se tomó la decisión de mantener **Mapillary** para la recuperación de imágenes. Al ser una plataforma de código abierto y mapeo colaborativo (actualmente bajo la infraestructura de Meta), su API permite la descarga intensiva de imágenes Street View mediante un único *token* de desarrollador, evitando el problema de los bloqueos por IP y las limitaciones de cuota. Aunque el volumen total de imágenes en Mapillary puede ser inferior al de Google en ciertas zonas, las imágenes extraídas fueron más que suficientes para llevar a cabo el proyecto ya que como se verá, no son necesarias una gran cantidad de estas debido a limitaciones computacionales que se han ido encontrando durante el proyecto.

4.3.2. Sistema de recuperación SVI

El algoritmo realiza una búsqueda en un radio de proximidad controlado alrededor del centroide de cada huella de edificio obtenida (Ver sección 4.2). El objetivo es identificar las coordenadas exactas de los puntos de imagen registrados en Mapillary. Al localizar la imagen con la menor distancia euclídea y mejor línea de visión hacia la estructura objetivo, el *framework* recupera la imagen junto con sus metadatos de posicionamiento y

orientación.

4.4. Procesamiento de las imágenes y extracción de fachadas

Una vez se tienen las huellas de los edificios, lo siguiente es asociar a cada parcela su correspondiente imagen. Para ello, se implementa un proceso secuencial de cuatro fases utilizando como se ha comentado, la API de Mapillary (*MLYDownloader*), y modelos de visión computacional avanzados.

4.4.1. Fase 1: Descarga de metadatos y cálculo del ángulo de Visión (AOV)

Para optimizar el almacenamiento, el sistema no descarga imágenes a ciegas, sino que realiza una consulta inicial para recuperar únicamente los metadatos de las imágenes disponibles dentro de la *bounding box* de cada ciudad. Estos metadatos incluyen las coordenadas de la cámara, el ángulo de la brújula (*compass angle*) y el nivel de calidad.

Con esta información, se ejecuta un algoritmo de cálculo del Ángulo de Visión (*Angle of View*, AOV) para determinar la idoneidad de cada punto de captura de imagen respecto a la fachada objetivo. Se estableció un *buffer* espacial de búsqueda de 60 metros alrededor del centroide de cada parcela, una distancia ampliada respecto a la documentación de prueba original para garantizar la captura en entornos de grandes bulevares (como el modelo Haussmann de París o las avenidas de Manhattan).

Posteriormente, se filtraron los puntos de captura aplicando las siguientes restricciones:

- **Restricción angular:** Se seleccionaron ángulos de visión entre 10° y 130°, descartando perspectivas excesivamente oblicuas o rasantes que deformarían la fachada y podrían confundir al modelo a la hora de realizar el análisis arquitectónico.
- **Límite por parcela:** Se restringió la selección a un máximo de 5 imágenes por edificio (elegidas de forma aleatoria entre las óptimas) para evitar una representación excesiva de estructuras muy fotografiadas.

4.4.2. Fase 2: Descarga de panorámicas

Utilizando el listado de metadatos filtrados (*pids_urls_select.csv*), se procede a la descarga física de las imágenes desde los servidores de Mapillary. Se configura una resolución de extracción de 2048 píxeles de ancho, un estándar que ofrece un equilibrio

entre la retención de detalles (necesarios para distinguir texturas como el ladrillo o la piedra) y la viabilidad computacional del almacenamiento en la nube.

4.4.3. Fase 3: Detección y recorte mediante GroundingDINO

Las imágenes panorámicas de SVI abarcan un campo visual de 360 grados que incluye cielo, asfalto, vehículos y múltiples edificios secundarios. Para aislar la fachada de interés, se integró el modelo **GroundingDINO** (con arquitectura *Swin-Transformer OGC*), un detector de objetos *Zero-Shot* que alinea características visuales con representaciones de texto.

Al modelo se le proporcionó el *prompt* textual "building" (edificio) junto con un umbral de confianza predictiva (*box threshold*) del 0,35. Basándose en las coordenadas proyectadas desde el SVI y el AOV previamente calculado, el detector enmarcó y recortó específicamente la región de la imagen que contenía el edificio correspondiente, descartando el resto de elementos urbanos que aparecen en la panorámica y ajustando dinámicamente las distorsiones de perspectiva en un 5 %.

4.4.4. Fase 4: Filtrado de calidad visual

Debido a la naturaleza colaborativa de Mapillary, una proporción de los recortes generados podía presentar una mala calidad y por tanto aumentar la dificultad para los análisis del modelo (por ejemplo, camiones bloqueando la fachada, farolas en de la trayectoria o defectos en la lente). Para limpiar el *dataset* de imágenes, se aplicó un filtro de calidad de imagen basado en características:

- **Tamaño mínimo de archivo:** 20 KB, eliminando recortes que consistieran en áreas uniformes vacías (como fragmentos de cielo o asfalto).
- **Nitidez (Desenfoque):** Se midió la varianza del Laplaciano sobre la imagen, estableciendo un umbral mínimo de 30 para descartar fotografías movidas o desenfocadas.
- **Proporción de área (*Ratios*):** Se impuso un *Building Ratio* mínimo de 0,15 y un *Wall Ratio* máximo de 0,3 para asegurar que el edificio ocupase una proporción central y sustancial del encuadre, sin ser un muro ciego y sin estar excesivamente alejado.

Las imágenes que superaron con éxito este proceso se guardaron en el directorio de cada ciudad, constituyendo un conjunto de datos listo para su análisis mediante los Modelos de Visión-Lenguaje (VLM).

4.5. Inferencia semántica mediante Visión-Lenguaje (VLM)

El siguiente paso en el proyecto es la extracción de características arquitectónicas a partir de los datos visuales de las fachadas. Para llevarlo a cabo se han utilizado Modelos de Visión y Lenguaje (VLM). A diferencia de los modelos tradicionales que se limitan a tareas de clasificación o detección de objetos, los VLMs unifican la comprensión visual y el razonamiento textual, extrayendo información mediante instrucciones en lenguaje natural.

En este trabajo se ha utilizado el modelo *seeshing/openfacades-internvl3-2b*, al igual que se documenta en el proyecto [8]. Este modelo representa una especialización de dominio basada en la arquitectura de código abierto *InternVL* (desarrollada por OpenGVLab). La arquitectura base de *InternVL* integra un codificador visual, con un modelo de lenguaje autorregresivo mediante un módulo de proyección lineal. El modelo cuenta con 2 mil millones de parámetros (2×10^9), un tamaño que mantiene una alta capacidad con la viabilidad computacional para su ejecución en entornos como Google Colab.

Aunque un VLM genérico posee una comprensión elemental del entorno, carece del vocabulario técnico y la precisión necesarios para una catalogación de arquitecturas rigurosa. Por este motivo, el modelo implementado no es la versión nativa de fábrica, sino que ha sido sometido a un proceso de *fine-tuning* por parte de los investigadores del proyecto **OpenFACADES** [8].

Este proceso de entrenamiento supervisado consistió en exponer a la arquitectura a un conjunto de datos especializado en morfología urbana y elementos de fachadas. Gracias a este proceso, el modelo ha aprendido a correlacionar patrones de píxeles específicos con conceptos avanzados de arquitectura.

4.5.1. Balanceo estadístico y deduplicación

Antes de proceder con la inferencia, la disparidad en el volumen de imágenes recopiladas (como se vió en la sección de resultados en la Tabla 2) resultaba un problema. Analizar conjuntos de datos desbalanceados, como las casi 4.000 imágenes de Ámsterdam frente a volúmenes extremadamente más pequeños en otras regiones, habría introducido

un sesgo en los resultados además de resultar un problema computacional debido a los altos requerimientos de procesamiento de los modelos VLM.

Para balancear la cantidad de imágenes, se implementó una fase de procesamiento basada en dos operaciones consecutivas:

1. **Deduplicación por parcela:** El solapamiento de panorámicas a nivel de calle (SVI) provocaba que un mismo edificio fuera detectado desde múltiples ángulos. Previamente se había establecido que no se identificara más de 5 veces al mismo edificio, sin embargo, debido a las limitaciones encontradas es necesario prescindir de los edificios duplicados utilizando el identificador único (`building_id`) de Overture Maps. Se conservó exclusivamente la primera aparición óptima de cada edificio.
2. **Límite máximo:** Tras la limpieza de duplicados, se obtuvo que la zona de Manhattan contaba con el menor número de parcelas únicas y válidas fotografiadas. Si tomaba este como el valor máximo para todas las ciudades, se reducía a apenas 112 la imágenes por ciudad. Para conseguir que todas las ciudades compitieran en condiciones similares, y estar dentro de la viabilidad computacional, se estableció el valor (254) como el límite máximo o tamaño de la muestra. Este valor corresponde al número de parcelas tras este último filtro de París Haussmann.

4.5.2. Ingeniería de *prompts* y extracción de atributos

Para extraer la información de cada fachada, el Modelo de Visión-Lenguaje (VLM) requiere instrucciones textuales precisas que guíen su atención visual. Se impuso una restricción de formato estricta, obligando a la IA a devolver sus respuestas exclusivamente en estructuras de datos JSON.

Durante la fase de calibración del modelo, se detectó una limitación computacional importante: al introducir un único *prompt* que abarcara todas las características deseadas, el modelo sufría de “alucinaciones” semánticas. La IA comenzaba a ignorar el formato JSON, generaba respuestas aleatorias o combinaba atributos de forma incoherente debido a la saturación de su ventana de contexto. Para mitigar este problema, se diseñó dividió la extracción en tres consultas (*prompts*) independientes por cada imagen.

Atributos estructurales base: La primera consulta corresponde al *prompt* original proporcionado por el repositorio de OpenFACADES [8].

```
question1 = ''' Provide concise labels for each category using the
following JSON format. Select appropriate values from the provided
options for each category:
{
    "building_type": "(choose one option from: 'apartments', 'house',
        'retail', 'office', 'hotel', 'industrial',
        'religious', 'education', 'public', 'garage')",
    "alternate_building_type": "(choose another option from the same list)",
    "building_age": "(a 4-digit year indicating the approximate date)",
    "surface_material": "(choose one option from: 'brick', 'wood',
        'concrete', 'metal', 'stone', 'glass', 'plaster')",
    "alternate_surface_material": "(choose another option from the same list)",
    "floors": "(a numeric value representing the total number of floors)",
    "construction_material": "(choose one option from: 'brick', 'wood',
        'concrete', 'steel', 'other')",
    "alternate_construction_material": "(choose another option)"
} '''
```

- **building_type:** Define el uso principal del edificio. El modelo debe elegir una opción entre: 'apartments' (residencial), 'house' (unifamiliar), 'retail' (comercial), 'office' (oficinas), 'hotel', 'industrial', 'religious', 'education', 'public' o 'garage'.
- **alternate_building_type:** Indica el uso secundario del inmueble en caso de fachadas mixtas (por ejemplo, comerciales con viviendas arriba), utilizando el mismo listado de opciones que el tipo principal.
- **building_age:** Estima el año aproximado de construcción del edificio expresado en un formato numérico de 4 dígitos (ej. 1920), basándose en los rasgos históricos y morfológicos visibles.
- **surface_material:** Determina el material predominante en el acabado exterior o revestimiento de la fachada. Las opciones son: 'brick' (ladrillo), 'wood' (madera), 'concrete' (hormigón), 'metal', 'stone' (piedra), 'glass' (vidrio) o 'plaster' (revoque/-yeso).
- **alternate_surface_material:** Identifica el segundo material más visible en el acabado de la superficie para fachadas combinadas, compartiendo las mismas opciones del material principal.

- **floors:** Representa un valor numérico entero que cuantifica el número total de plantas o pisos visibles en la sección de fachada analizada.
- **construction_material:** Clasifica el material estructural básico que aparenta sostener el edificio, seleccionando entre: 'brick', 'wood', 'concrete', 'steel' u 'other'.
- **alternate_construction_material:** Registra un material estructural secundario en caso de detectar sistemas constructivos híbridos, evaluado bajo las mismas categorías.

Expansión de características: La segunda consulta constituye una expansión diseñada específicamente para este proyecto. Su propósito es capturar matices arquitectónicos que permiten diferenciar las fachadas entre ciudades (como las escaleras de incendios neoyorquinas frente a los balcones parisinos):

```
question2 = ''' Provide concise labels for each category using the
following JSON format. Select appropriate values from the provided
options for each category:
{
  "singular_elements": "(choose one or more from: 'balconies',
                        'bay_windows', 'cornices', 'fire_escapes', 'none')",
  "architectural_style": "(choose one option from: 'classic', 'modern',
                        'industrial', 'traditional', 'brutalist')",
  "visible_condition": "(choose one option from: 'excellent', 'good',
                        'fair', 'poor', 'ruin')",
  "glazing_ratio": "(choose one option from: 'low', 'medium',
                    'high', 'fully_glazed')"
} '''
```

- **singular_elements:** Detecta la presencia de componentes arquitectónicos específicos y destacados en la fachada. Permite la selección de uno o varios elementos entre: 'balconies' (balcones), 'bay_windows' (miradores), 'cornices' (cornisas), 'fire_escapes' (escaleras de incendio) o 'none' si no se observa ninguno.
- **architectural_style:** Clasifica la corriente estética o el estilo formal del diseño arquitectónico global de la fachada entre las opciones: 'classic', 'modern', 'industrial', 'traditional' o 'brutalist'.
- **visible_condition:** Evalúa el estado de conservación física y mantenimiento que presenta la estructura a nivel exterior, categorizándolo como: 'excellent', 'good', 'fair' (aceptable), 'poor' (deteriorado) o 'ruin'.

- **glazing_ratio**: Mide cualitativamente la proporción de superficie acristalada (ventanas y vanos abiertos) en relación con la masa opaca del muro de la fachada. Las opciones son: 'low', 'medium', 'high' o 'fully_glazed'.

Métricas de percepción visual (Sentimiento): La tercera y última consulta busca emular las características perceptuales y de sentimiento descritas en el artículo de referencia [7]. Se pide al modelo que actúe como un observador humano y puntúe la estética de la fachada en una escala del 0 al 10.

Es importante destacar que el artículo original contemplaba una sexta métrica de sentimiento denominada *style* (evaluada como un espectro de histórico a moderno). Sin embargo, se ha tomado la decisión de eliminarla de este *prompt* ya que en la consulta anterior (*question2*) ya incorpora la variable *architectural_style*, la cual ofrece una clasificación categórica más detallada, sumado a que con 6 características el modelo proporcionaba demasiados errores de formato y comenzaba de nuevo a “alucinar”. El modelo evaluó las siguientes 5 métricas:

```
question3 = ''' Provide concise labels for each category using the
following strict JSON format. Select appropriate values using integers
from 0 to 10 where requested:
{
    "score_complex": "(an integer from 0 to 10 rating the visual
                      complexity and detail of the facade)",
    "score_original": "(an integer from 0 to 10 rating the originality
                      or uniqueness of the architectural design)",
    "score_boring": "(an integer from 0 to 10 rating how monotonous,
                    dull, or repetitive the facade is)",
    "score_ordered": "(an integer from 0 to 10 rating the symmetry,
                    rhythm, and geometric order of the windows)",
    "score_pleasing": "(an integer from 0 to 10 rating the overall
                      aesthetic appeal and visual harmony)"
} '''
```

- **score_complex**: Puntuación entera del 0 al 10 que califica la complejidad visual, la densidad de ornamentación, las texturas y el nivel de detalle presente en la superficie de la fachada.
- **score_original**: Puntuación entera del 0 al 10 que mide el grado de originalidad, singularidad y carácter único del diseño arquitectónico en comparación con la norma urbana común.

- **score_boring**: Puntuación entera del 0 al 10 que evalúa el nivel de monotonía, aburrimiento o pesadez visual debido a un diseño excesivamente plano, repetitivo o falta de estímulos.
- **score_ordered**: Puntuación entera del 0 al 10 que puntúa la regularidad geométrica, la simetría, el ritmo y el orden en la disposición espacial de las ventanas y demás elementos arquitectónicos.
- **score_pleasing**: Puntuación entera del 0 al 10 que valora de forma cualitativa el atractivo estético general, la armonía visual y el agrado que despierta la composición de la fachada.

4.5.3. Procesamiento de los resultados obtenidos del modelo

A pesar de haber establecido restricciones estrictas en la ingeniería de *prompts* para forzar al modelo a devolver exclusivamente estructuras de datos JSON, se han detectado tras las iteraciones de los 3 *prompts* a lo largo de las cuatro ciudades una serie de errores de formato en los resultados. Esto es debido a que los modelos VLM son generativos basados en probabilidades, además de que es un modelo no demasiado grande para que sea ejecutable en la GPU de Colab, nada comparable con un modelo de IA actual de billones de parámetros.

Estas anomalías no se refieren a errores del análisis, sino a errores del formato informático que impedían la lectura automatizada de los datos. Entre los errores más comunes originados por el VLM se encontraban la inclusión de texto conversacional previo o posterior, la omisión de comas separadoras, el uso incorrecto de comillas simples en lugar de dobles, y la generación de comas huérfanas al final de los diccionarios.

Dado que descartar las imágenes que presentaban estos errores de formato habría supuesto una pérdida inasumible de datos valiosos y un desperdicio de horas de ejecución GPU, se ha desarrollado e implementado un algoritmo de limpieza basado en expresiones regulares en Python. El flujo opera siguiendo siguiente lógica secuencial:

1. **Limpieza de envoltorios *Markdown***: Se eliminan las etiquetas de bloque de código (tales como “`json`” y “`”`) que el modelo añade por defecto.
2. **Evaluación de lectura primaria**: El sistema intenta decodificar el texto resultante. Si el formato es un JSON perfecto, el registro se cataloga como válido y se almacena. Si el analizador devuelve un error de formato, el texto se deriva a la parte de reparación de expresiones regulares.

3. **Reparación de expresiones regulares:** Más de 10 reglas sintácticas para corregir los fallos del modelo. Para la incorporación de estas reglas se fue limpiando poco a poco el archivo hasta que se encontrara un error. Una vez se encontraba, se añadía a la lista para solucionarlo.

- Eliminación de comentarios de código en línea (patrones iniciados con `//`), los cuales están prohibidos en la especificación JSON.
- Supresión de saltos de línea y elementos huérfanos, eliminando líneas que contenían de forma aislada una única comilla, o combinaciones sin sentido de comillas y comas.
- Inserción de saltos de línea y comas separadoras entre valores numéricos (con o sin comillas) que el modelo había concatenado erróneamente en una misma línea junto a la siguiente clave textual.
- Separación de propiedades unidas incorrectamente por secuencias continuas de dobles comillas (ej. `""`) sin separación estructural.
- Reconstrucción de estructuras, corrigiendo patrones defectuosos del tipo `“clave: valor”` donde se omitían las comillas internas.
- Corrección de claves que iniciaban con guiones bajos (`_`) en sustitución de las correspondientes comillas de apertura.
- Envoltura automática con comillas dobles (`""`) para todas aquellas claves alfanuméricas estándar que el modelo había generado incorrectamente como texto plano.
- Inserción de comas separadoras faltantes al final de líneas de propiedades válidas (cadenas de texto, valores numéricos, `true`, `false` o `null`) antes de la declaración de una nueva clave.
- Limpieza de redundancias de puntuación, reemplazando múltiples comas consecutivas duplicadas por un único separador válido.
- Limpieza de sintaxis de apertura, suprimiendo las comas inválidas generadas inmediatamente después de abrir llaves (`{`) o corchetes (`[`).
- Limpieza de sintaxis de cierre, eliminando cualquier coma residual o huérfana ubicada inmediatamente antes de cerrar llaves (`}`) o corchetes (`]`).
- Homogeneización global de caracteres, rastreando y transformando todas las comillas simples (`'`) utilizadas de forma aislada e incorrecta en comillas dobles estandarizadas (`"`).

4. **Evaluación secundaria:** Una vez aplicadas de forma secuencial las correcciones, se vuelve a intentar la decodificación. Si la estructura de datos había sido salvada exitosamente, se guarda en la carpeta, de lo contrario, se marcaba definitivamente como un registro insalvable.

Se ha aplicado la limpieza a los tres *prompts* en las cuatro ciudades. Finalmente, los diccionarios filtrados se unieron en un único archivo para cada ciudad, teniendo así por cada una de ellas todas las características extraídas por el modelo; las cuales no se habían podido obtener unidas desde el principio debido a las limitaciones comentadas del modelo con *prompts* muy largos. Por último se transformaron los datos finales a formato `.csv` para resultar más manejables en Python.

5. Resultados

5.1. Resultados de la extracción y filtrado

En la primera fase se consiguieron las huellas de los edificios para las cuatro zonas establecidas. La aplicación del filtro para excluir construcciones por su área y su categoría “subterránea” ha resultado ser un mecanismo eficaz para limpiar el conjunto de datos de estructuras innecesarias para el análisis.

En la Tabla 1 se detalla la cantidad de datos recuperados, las estructuras descartadas por el filtro y el número final de edificios válidos para la siguiente fase.

Zona de Estudio	Iniciales	Descartados	Válidos
Madrid Histórico	1000	25 (2,50 %)	975
Ámsterdam Centro	1035	99 (9,56 %)	936
Nueva York Manhattan	895	2 (0,22 %)	893
París Haussmann	536	61 (11,38 %)	475
Total Global	3466	187 (5,39 %)	3279

Tabla 1: Resumen del procesamiento de parcelas extraídas de *Overture Maps*, tras el filtrado (área $> 30m^2$ y $< 15000m^2$ y sin subterráneos).

El análisis de estos resultados muestra diferencias notables entre ciudades. Mientras que de *Manhattan* se descarta únicamente el 0,22 % (2 estructuras), lo que indica una urbanización basada casi exclusivamente en grandes bloques consolidados, en *París* y

Ámsterdam se registraron las tasas de exclusión más altas (11,38 % y 9,56 %, respectivamente). Esto puede explicarse por la complejidad europea, que posee una mayor densidad de quioscos, patios interiores, pequeñas casetas y elementos urbanos menores que han sido detectados y filtrados con éxito.

5.2. Resultados de la Captura SVI y la extracción de fachadas

La segunda fase del proyecto, enfocada en la descarga de imágenes a nivel de calle (SVI) mediante Mapillary y el recorte automatizado de fachadas utilizando *GroundingDINO*, generó un gran volumen de imágenes. El proceso empleado ha demostrado buena eficiencia al procesar panorámicas de 360 grados donde múltiples edificios y elementos urbanos coexisten y extraer fragmentos concretos de fachadas de este entorno.

En la Tabla 2 se desglosa el procesamiento de imágenes para cada caso de estudio: desde las panorámicas seleccionadas inicialmente por su ángulo de visión (AOV), pasando por los recortes brutos detectados por la Inteligencia Artificial, hasta las imágenes que superaron con éxito los filtros de calidad visual (nitidez, tamaño y proporción).

Zona	Panorámicas SVI	Recortes Brutos	Imágenes Válidas
Madrid Histórico	344	1277	1163
París Haussmann	620	2658	2568
N.Y. Manhattan	103	363	339
Ámsterdam Centro	1286	3962	3894
Total Global	2353	8260	7964

Tabla 2: Desglose del procesamiento de imágenes a nivel de calle (SVI). Se muestra la expansión de datos al recortar múltiples fachadas por panorámica, y la tasa de retención tras aplicar el filtro de calidad visual.

5.2.1. Análisis de la extracción visual

De estos datos se pueden extraer tres conclusiones sobre el comportamiento del *framework* y la estructura de las ciudades analizadas:

1. **Eficacia del modelo:** El modelo *GroundingDINO* ha demostrado una capacidad de extracción sobresaliente. A partir de 2.353 panorámicas esféricas, el sistema fue capaz de detectar y recortar 8.260 instancias de fachadas. Esto confirma la eficiencia

computacional del modelo, que logra extraer una media de 3 a 4 edificios distintos por cada fotografía de 360 grados, maximizando el aprovechamiento de los datos descargados.

2. **Robustez del filtro de calidad:** La tasa de supervivencia de las imágenes tras aplicar los filtros de desenfoque (*blur*) y oclusión espacial fue excepcionalmente alta (7.964 imágenes retenidas de 8.260, un 96,4 % de éxito). Esto evidencia que el *prompt* textual ("building") suministrado al detector fue muy preciso, evitando que la IA encuadrara elementos ruidosos como camiones, asfalto u otros elementos urbanos.
3. **Heterogeneidad de la cobertura y sesgo estadístico:** Como se anticipa en el diseño de la muestra, la dependencia de una plataforma colaborativa como Mapillary genera disparidades. La zona de Manhattan (*SoHo*) apenas ha reportado 103 panorámicas útiles, produciendo 339 fachadas. En el extremo opuesto, la red de canales estrechos de Ámsterdam, con una alta densidad de panorámicas y una fuerte superposición de capturas, ha generado casi 4.000 imágenes.

Esta última observación es clave para la viabilidad analítica del proyecto. Introducir 3.894 imágenes de Ámsterdam frente a las 339 de Nueva York en el Modelo de Visión-Lenguaje (VLM) habría inducido un sesgo muy grande, alterando el peso de los estilos arquitectónicos en las comparativas finales. Por consiguiente, estos resultados validaron de forma empírica la necesidad de implementar una fase de balanceo estadístico y deduplicación previa a la inferencia semántica.

5.3. Resultados de la inferencia

5.3.1. Resultados del balanceo estadístico y deduplicación

La implementación del módulo de preprocesamiento sobre las 7.964 imágenes válidas obtenidas en la fase anterior muestra la verdadera magnitud del solapamiento debido a las capturas panorámicas de Mapillary. Al agrupar las imágenes por su identificador único de edificio (*building_id*), se vió que una inmensa mayoría de las fotografías correspondían a perspectivas redundantes de las mismas fachadas.

En la Tabla 3 se presenta la evolución de la muestra tras aplicar el filtro de duplicados y la restricción dimensional a 254 imágenes por zona.

Los datos obtenidos en esta parte destacan la densidad de captura de las distintas ciudades:

Zona	Originales	Edificios Únicos	Muestra final
Madrid Histórico	1163	187	187
París Haussmann	2568	254	254
Nueva York Manhattan	339	112	112
Ámsterdam Centro	3894	509	254
Total Global	7964	1062	807

Tabla 3: Reducción por deduplicación y límite máximo.

1. **Colapso de redundancia:** El caso de Madrid y Ámsterdam es especialmente paradigmático. En Madrid, 1.163 recortes pertenecían en realidad a tan solo 187 edificios distintos (una ratio de 6 fotos por edificio). En Ámsterdam, el efecto fue aún más extremo, reduciéndose casi 4.000 imágenes a 509 parcelas únicas. Esto demuestra que pasar el volumen bruto de imágenes al modelo VLM habría supuesto un desperdicio de recursos computacionales analizando la misma fachada repetidas veces.
2. **Efecto del límite:** Al establecer el umbral máximo en 254 (marcado por la capacidad de retención de París), se logró contener la sobre-representación de Ámsterdam (que contaba con 509 edificios únicos). El algoritmo seleccionó 254 imágenes aleatorias de la capital neerlandesa, equilibrando su peso en la comparativa internacional.
3. **Zonas con menor representación:** En las zonas con menor densidad fotográfica, como Nueva York (112) y Madrid (187), se mantuvo la lista de edificios únicos al no superar el límite de corte.

Como resultado de esta arquitectura de preprocesamiento, se consolidó un *dataset* final de **807 imágenes de fachadas únicas, de alta calidad y no demasiado desbalanceadas**. Este volumen es idóneo para su procesamiento en la tarjeta gráfica (GPU) local de Google Colab, garantizando tiempos viables para el Modelo de Visión-Lenguaje.

5.4. Rendimiento del VLM y evaluación del procesamiento de los *outputs*

Una vez ejecutada la inferencia con el modelo *InternVL* sobre la muestra de 807 imágenes utilizando los tres *prompts* independientes, se generaron 2.421 respuestas en principio en formato JSON. A los resultados obtenidos se le tuvo que realizar un procesamiento debido a la cantidad de errores de formato y estructura que cometió el modelo, tal y

como se ha comentado en la sección 4.5.3. Los resultados de este procesamiento descrito en dicha sección son los siguientes:

En la Tabla 4 se resume el rendimiento del modelo de visión-lenguaje y la efectividad del algoritmo de contingencia implementado.

Métrica	Frecuencia absoluta	Porcentaje (%)
Respuestas procesadas (807×3)	2421	100,00 %
Respuestas sin fallos de origen	1991	82,24 %
Fallos detectados	430	17,76 %
Resultado del procesamiento		
Respuestas corregidas con éxito	409	95,12 %*
Respuestas insalvables (Descartadas)	21	4,88 %*
Dataset final	2400	99,13 %**

Tabla 4: Evaluación del rendimiento del modelo de visión-lenguaje y del procesamiento aplicado a los *outputs* del modelo).

Observando las métricas de la tabla 4 se pueden realizar las siguientes interpretaciones:

- El modelo *InternVL* dio una tasa de acierto al estructurar las respuestas del 82,24 % (1.991 respuestas perfectamente estructuradas). Si bien es un rendimiento elevado para un modelo generativo, el 17,76 % de fallos que depender exclusivamente de la capacidad del modelo para disponer de un formato rígido (como JSON) es un problema, ya que el modelo tiende a desviarse de la norma debido a su naturaleza probabilística.
- El procesamiento realizado a los *outputs* ha resultado ser muy importante para el proyecto ya que se han logrado reparar 409 de los 430 errores de formato, alcanzando una tasa de éxito del **95,12 %**.
- Únicamente 21 respuestas (un 0,87 % del total del *dataset* procesado) fueron catalogadas como completamente insalvables. Estas respuestas corresponden a aquellos casos en los que el modelo presenta alucinaciones y entra en un bucle repetitivo, generando secuencias de caracteres sin contenido semántico, como por ejemplo $\backslash n \backslash n \backslash n \dots$, sin llegar a completar correctamente la información.

Por otro lado, se identificaron algunos casos de falsos negativos, es decir, respuestas que eran correctas pero que el sistema no logró procesar adecuadamente en formato JSON, clasificándolas erróneamente como fallidas pese a que su estructura era válida.

Dado que estos casos fueron puntuales y de baja frecuencia, no se consideró necesario abordar este tipo de error en el presente análisis.

Gracias a este procesamiento hemos podido extraer 2.400 características de edificios estructuradas (alcanzando una retención de la información del 99,13%).

Una vez unidas todas las características extraídas por edificio en una misma estructura se tienen 4 archivos JSON distintos, uno para cada ciudad. Como se ha comentado en la sección 4.5.3 se transforman a formato `.csv` para trabajar más fácilmente con ellos en Python. Una vez se dispone de este formato se comienza con la fase del análisis y la visualización.

5.5. Análisis de los atributos estructurales base

En esta sección se da inicio al análisis exploratorio de los datos. Una vez finalizada la fase de recolección, limpieza, transformación y estructuración de los conjuntos de datos, se dispone de una base que permite extraer información relevante de manera que se pueda tanto realizar un análisis propio consistente en una mejora del trabajo original como una emulación de los resultados que se exponen en el artículo de referencia [7].

El objetivo principal de este análisis es estudiar el comportamiento y las características de las distintas ciudades. A través de estas visualizaciones, se pretende identificar patrones, distribuciones y posibles diferencias significativas entre ciudades.

Esta es la primera de las tres secciones destinadas al análisis y visualización de los datos. Cada sección corresponde a una categoría según el tipo de prompt utilizado.

5.5.1. Análisis de la distribución de los tipos de edificios

Comenzamos evaluando la funcionalidad de los edificios, para ello se ha dado la misma importancia tanto al tipo de edificio principal como al secundario detectado por el modelo. La Figura 2 presenta una los gráficos de barras que detallan la frecuencia absoluta de los distintos usos del suelo detectados por el modelo en cada una de las cuatro capitales.

El análisis muestra patrones de usos del suelo bastante distintos, reflejando las diferencias entre las ciudades:

- **Baja residencialidad de Manhattan:** El perfil de Nueva York difiere completamente del resto de la muestra. Mientras que en las ciudades europeas el uso residencial (`apartments`) es abrumadoramente mayoritario, en el sector analizado de




Figura 2: Distribución de los tipos de edificios en las cuatro zonas de estudio.

Manhattan (entorno del *SoHo*/Centro), el uso principal detectado es el corporativo (**office**), seguido muy de cerca por el comercial (**retail**). Esta distribución refleja las políticas típicas de las metrópolis norteamericanas, donde los distritos de negocios centrales desplazan casi por completo el uso residencial en favor de la alta concentración comercial y administrativa.

- **El modelo de ciudad europea:** Madrid, París y Ámsterdam presentan un perfil de “ciudad mixta”. En las tres capitales, la categoría predominante es la residencial (**apartments**), seguida por una fuerte presencia comercial en planta baja (**retail**). Se trata de una estructura de ciudad muy europea, heredada de un crecimiento histórico anterior a la estructuración funcional moderna, y se caracteriza por edificios que a menudo albergan ambos usos simultáneamente (comercio a pie de calle y viviendas en las plantas superiores).
- **Peculiaridad de Ámsterdam:** Cabe destacar una particularidad en la distribu-

ción de la capital neerlandesa. A diferencia de París o Madrid, donde la categoría *house* (vivienda unifamiliar/tradicional independiente) es escasa, en Ámsterdam esta tipología representa la tercera fuerza más importante. Este dato es coherente con la conservación de las “casas del canal” (*grachtenpand*) históricas, edificaciones estrechas y profundas concebidas originalmente como unidades independientes para comerciantes burgueses.

- **Edificios públicos y de servicios:** Finalmente, se observa que en Madrid se encuentra una cantidad notablemente mayor de edificios institucionales (*public*), superando a ciudades de mayor escala como París. Esto se debe a la selección específica de la región del “centro histórico” (zona de los Austrias/Palacio), un área caracterizada por una alta concentración histórica de ministerios, sedes gubernamentales e instituciones de la Corona.

5.5.2. Análisis de la antigüedad de los edificios

En esta sección se analizará la datación histórica de los edificios. La Figura 3 muestra la distribución del año aproximado de construcción inferido por el modelo VLM para cada construcción.




Figura 3: Diagrama de cajas que muestra la distribución del año de construcción estimado por el modelo VLM en las distintas zonas.

- **El sesgo y el año de referencia (Madrid y París):** El rasgo estadístico anómalo que más destaca de la gráfica es el colapso del rango intercuartílico en las muestras de Madrid y París, formando una línea plana exacta en el año 1900. Es completamente irreal que todos se construyera en ese año exacto (el Plan Haussmann parisino, por ejemplo, se ejecutó principalmente entre 1850 y 1870). Esto demuestra que el modelo VLM emplea el año 1900 como un año de referencia por defecto cuando detecta fachadas de estilo clásico, ecléctico o decimonónico europeo, pero carece de referencias visuales concretas (como placas conmemorativas) para afinar la década. Los valores atípicos (*outliers*) representan excepciones donde la IA logró identificar estilos preindustriales (1600-1800) o arquitecturas modernas (post-1950).
- **Siglo de Oro neerlandés:** En contraste con el sesgo anterior, Ámsterdam presenta la mayor dispersión del estudio. Su rango intercuartílico abarca un periodo desde 1700 hasta 1900, con bigotes que descienden hasta el año 1400. Esta altísima varianza indica que el modelo sí ha sido capaz de discriminar la evolución del *Grachtengordel* (el anillo de canales del siglo XVII), reconociendo las diferencias estéticas entre la arquitectura gótica tardía, el renacimiento holandés del Siglo de Oro y las reconstrucciones burguesas posteriores.
- **Contemporaneidad de Manhattan:** El perfil de Nueva York es el más compacto y coherente con la realidad histórica documentada. Su caja se concentra estrechamente entre las décadas de 1920 y 1960, con una mediana próxima a 1930. Este lapso temporal coincide perfectamente con la edad de oro del desarrollo de Manhattan, impulsado por el *Art Déco*, el desarrollo del acero estructural y el *boom* inmobiliario de entreguerras y postguerra. La ausencia casi total de registros anteriores a 1890 indica el proceso de destrucción creativa (*tabula rasa*) que caracteriza al urbanismo neoyorquino, donde las estructuras coloniales fueron sustituidas.

5.5.3. Análisis de materiales de las fachadas

En esta sección se aborda el estudio de la distribución de materiales en la fachada de los diferentes edificios. La Figura 4 muestra la frecuencia absoluta de los materiales de fachada principales detectados por el modelo en las cuatro ciudades.

El análisis de esta distribución de materiales se relaciona con los recursos geológicos de cada región históricamente, así como de las normativas estéticas y técnicas predominantes en cada ciudad:




Figura 4: Distribución de los materiales principales de fachada identificados.

- Dominio del ladrillo en Ámsterdam:** El gráfico de Ámsterdam revela una dominancia casi absoluta del ladrillo, superando los 200 registros y doblando a la siguiente categoría. Se trata de la firma inconfundible de la arquitectura holandesa, dictada históricamente por la escasez de canteras de piedra natural en los Países Bajos y la abundancia de arcilla fluvial. El yeso (**plaster**) aparece como material secundario, a menudo utilizado en zócalos o como revestimiento protector.
- La dualidad de Madrid y París:** Las gráficas de Madrid y París exhiben un comportamiento muy similar, dominado exclusivamente por el yeso/estuco (**plaster**) y la piedra (**stone**). En París, la gran presencia de piedra es el resultado directo de las ordenanzas del Segundo Imperio que obligaban al uso de sillería en las fachadas principales de los bulevares. En Madrid, la alta proporción de **plaster** refleja la tradición constructiva de los “revocos” madrileños, un revestimiento continuo utilizado históricamente para proteger fábricas de albañilería más pobres (ladrillo tosco) o para simular despieces de sillería en la arquitectura isabelina y ecléctica.
- Amplio espectro de Manhattan:** El sector analizado de Nueva York presenta

el espectro de materiales más equilibrado y diverso. Aunque la piedra y el ladrillo tienen una presencia notable (típica de los *brownstones* y lofts industriales del SoHo), destacan especialmente las categorías de hormigón, cristal y metal. Lo que ilustra la transición hacia la arquitectura corporativa moderna y el estilo internacional, donde las fachadas ligeras de vidrio y acero conviven con estructuras brutalistas de hormigón y reliquias industriales.

5.5.4. Análisis de la distribución del número de plantas

En esta sección se va a realizar una comparación del número total de plantas de las edificaciones. En la Figura 5 se presenta un diagrama de cajas (*boxplot*) que ilustra la dispersión estadística, las medianas y los valores atípicos de esta variable para cada una de las cuatro ciudades analizadas.




Figura 5: Diagrama de cajas comparativo de la distribución del número de plantas de los edificios en las cuatro zonas de estudio.

Observando la gráfica se pueden observar las diferencias entre el modelo urbanístico europeo y el norteamericano, así como las particularidades dentro de las propias capitales europeas:

- **La verticalidad y varianza de Manhattan:** Como era previsible, la zona de Nueva York presenta la mayor mediana del conjunto (situada en torno a las 8 plantas) y una dispersión intercuartílica (caja verde) excepcionalmente amplia, abarcando desde las 5 hasta las 12 plantas. Además, es la única región que registra valores atípicos (*outliers*) que se acerquen a las 30 plantas. Esta alta varianza refleja la arquitectura neoyorquina, donde rascacielos y torres modernas coexisten en la misma manzana con estructuras históricas de menor altura.
- **Homogeneidad de Ámsterdam y París:** En el extremo opuesto destaca el caso de Ámsterdam, cuyo rango intercuartílico colapsa casi por completo en una mediana estricta de 4 plantas, características de las tradicionales casas a lo largo de sus canales. Por su parte, el entorno Haussmanniano de París muestra también una mediana entre 4 y 5 plantas. Esto es una huella directa de las rígidas ordenanzas de altura del siglo XIX impuestas por el Barón Haussmann, cuyo objetivo era mantener una cornisa continua y monumental a lo largo de los bulevares.
- **La escala de Madrid:** El centro histórico de Madrid se consolida como la zona con alturas más moderada y compacta, concentrando el número de plantas entre 3 y 4, con una dispersión que apenas alcanza la quinta planta. Este comportamiento es coherente con la zona seleccionada, que tiene una tipología arquitectónica de los “Austrias” y un casco antiguo de baja altura, construido mayoritariamente antes de la llegada del ascensor y las grandes normativas de ensanche del siglo XX.

5.5.5. Análisis de los materiales de construcción estructurales

En esta sección se analiza la inferencia del modelo respecto a los materiales estructurales predominantes de las edificaciones, a diferencia del revestimiento de la fachada analizado anteriormente. La Figura 6 desglosa la frecuencia absoluta de los materiales de construcción detectados en las cuatro ciudades.

La comparativa de estos resultados revela las técnicas de ingeniería y la historia constructiva subyacente en cada tejido urbano:

- **El acero de Manhattan:** La ciudad de Nueva York destaca por el uso de acero (*steel*) y hormigón (*concrete*) como elementos estructurales mayoritarios. Este resultado refleja directamente la evolución de los sistemas de construcción norteamericanos basados en el armazón metálico (*steel frame*), una innovación para soportar




Figura 6: Distribución de los materiales estructurales de construcción inferidos por el modelo.

la gran cantidad de plantas, los rascacielos y el uso comercial/oficinas que se ha documentado en apartados anteriores.

- **Tradición de ladrillo y madera en Ámsterdam:** El perfil de Ámsterdam está dominado por el ladrillo acompañado de una notable y distintiva presencia de madera, material prácticamente residual en las demás ciudades. Esta combinación es totalmente coherente con la realidad histórica de los Países Bajos, donde los muros de carga de mampostería se asentaban sobre complejos sistemas de cimentación mediante pilotes de madera hincados en el suelo pantanoso, utilizando también forjados y entramados internos de este material.
- **Sistemas de mampostería en Madrid y París:** Ambas capitales muestran un comportamiento análogo, con una fuerte dependencia estructural del ladrillo y la piedra. En el caso de París, aunque las ordenanzas exigían revestimientos exteriores en piedra (como se vio en la fachada), el modelo infiere correctamente que la masa

estructural y los muros medianeros de la época dependían en gran medida de fábricas de ladrillo y mampostería mixta.

- **La transición al hormigón europeo:** Es importante notar que, junto a los materiales históricos, tanto Madrid como París y Ámsterdam registran una cantidad considerable de estructuras de hormigón. Esto evidencia la superposición de épocas en las ciudades consolidadas europeas, que cuentan con edificios modernos así como edificios clásicos con estructuras contemporáneas.

5.6. Análisis de las características extra

En esta sección, vamos a analizar los resultados obtenidos para el segundo prompt. Dado que `internvl3`, se ajustó mediante *fine-tuning* para resolver las cuestiones del primer *prompt*, se espera un menor rendimiento en esta sección.

5.6.1. Análisis de elementos singulares

En esta sección, analizaremos la cantidad identificada de elementos singulares presentes en las fachadas. Se realizó un filtrado previo, ya que a pesar de especificarle al modelo que eligiera entre balcón, ventanal, cornisas, escalera de incendios, y por último, en caso de no encontrar nada de lo anterior clasificar como *ninguno*. El modelo alucinó en algunos casos identificando elementos fuera del rango, por lo que se trataron y se añadieron a la clase *none*. En la siguiente tabla se resumen el total de elementos identificados, separados por ciudad:

City	Balconies	Bay Windows	Cornices	Fire Escapes	None
Amsterdam	71	4	7	0	172
Madrid	143	0	0	0	44
Manhattan	18	2	3	24	65
París	206	0	0	2	46

Tabla 5: Distribución de elementos singulares por ciudad

- **Dominancia de balcones en europa:** Tanto París como Madrid destacan por el elemento **balconies**, con valores muy elevados (206 y 143 respectivamente) frente al resto de categorías. Este patrón se debe a que los balcones constituyen el principal recurso compositivo en fachada. En el caso de París, esto es consistente con la

arquitectura haussmanniana, mientras que en Madrid refleja la tradición residencial con balcones como elemento funcional y estético predominante.

- **Variedad de Ámsterdam:** Ámsterdam muestra una distribución más diversificada, aunque con una clara mayoría de casos clasificados como `none` (172). Sin embargo, a diferencia del resto de ciudades europeas, sí aparecen elementos como `bay_windows` y `cornices`, típicos del país. Sin embargo, identifica una pequeña cantidad, en relación a otras ciudades de Holanda, posiblemente debido al estrechamiento de las fachadas en muchas calles.
- **Singularidad de Manhattan:** Manhattan destaca como el único caso donde el elemento `fire_escapes` aparece con una presencia significativa (24), siendo además un rasgo prácticamente exclusivo de este entorno urbano. A esto se suma una distribución más equilibrada entre categorías y una presencia notable de `none` (65), lo que refleja una alta variabilidad arquitectónica. Este comportamiento es coherente con la diversidad del distrito, donde conviven edificios históricos con estructuras modernas.
- **Alta proporción de valores nulos y robustez del modelo:** En todas las ciudades, especialmente en Ámsterdam y Manhattan, se observa una proporción considerable de la categoría `none`. Se debe mencionar que el modelo se salía de las reglas de análisis impuestas y añadía elementos que no se pedía identificar y que fueron filtrados como *None*. Esto puede indicar que muchas fachadas realmente carecen de los elementos definidos en el *prompt* y por eso el modelo proporciona resultados tan dispersos originalmente.

5.6.2. Análisis de la distribución de estilos arquitectónicos

En este apartado se evalúa la clasificación de las fachadas realizada por el modelo de visión-lenguaje según su estilo arquitectónico. La Figura 7 presenta mediante gráficos de barras la frecuencia absoluta de los distintos estilos arquitectónicos detectados en las cuatro capitales estudiadas.

Tras observar el gráfico se evidencia que existen contrastes estilísticos muy marcados que definen la identidad visual e histórica de cada ciudad:

- **El clasicismo de París:** La capital francesa destaca por una mayoría del estilo `classic`. El modelo de IA logra identificar con gran precisión las proporciones aca-




Figura 7: Distribución de los estilos arquitectónicos identificados en las cuatro zonas de estudio.

démicas, la simetría, las molduras y la ornamentación neoclásica que caracterizan a los bloques de viviendas de los bulevares.

- **La arquitectura tradicional de Madrid y Ámsterdam:** Ambas ciudades muestran un claro dominio de la categoría **traditional**. En el contexto del modelo VLM, esta etiqueta agrupa la arquitectura histórica que no presenta los rasgos del clasicismo puro. En Ámsterdam corresponde a las clásicas casas gremiales de ladrillo, mientras que en el centro histórico de Madrid refleja la arquitectura más sobria de los Austrias y los edificios residenciales populares de los siglos XVIII y XIX.
- **Modernidad e industria en Manhattan:** El perfil de Nueva York rompe por completo con el patrón europeo. Las categorías dominantes son **modern** e **industrial**, con una presencia casi nula de los estilos clásico o tradicional. Esto coincide a la perfección con la evolución de la zona analizada.

- **Presencia del estilo moderno:** Es destacable que el estilo *modern* aparece como una constante secundaria (o principal en el caso de Nueva York) en todas las ciudades. Esto demuestra la sensibilidad de la IA para captar la renovación de las ciudades, detectando rehabilitaciones de fachadas o edificios de nueva planta que se han ido construyendo progresivamente en las ciudades.

5.6.3. Análisis del estado de conservación visible

En este apartado se examina el estado de conservación aparente de las fachadas, evaluado por el modelo a partir de la imagen a nivel de calle. La Figura 8 muestra mediante gráficos de barras la frecuencia de las distintas categorías de conservación detectadas en las cuatro ciudades.




Figura 8: Distribución de la apariencia de conservación de los edificios en las cuatro zonas de estudio.

El análisis de estos gráficos revela el nivel de mantenimiento, así como ciertas tenden-

cias y sesgos en el criterio de evaluación del modelo VLM:

- **Excelencia en la conservación de Ámsterdam:** La capital neerlandesa destaca positivamente al ser la única ciudad seleccionada donde la categoría **excellent** (excelente) supera a la categoría **good** (bueno), presentando además unos niveles mínimos de deterioro. Esto es un reflejo del alto grado de mantenimiento, y protección que reciben las propiedades históricas de los canales.
- **El estándar histórico europeo (Madrid y París):** Ambas capitales muestran un perfil de conservación robusto y muy similar, con una alta concentración en la categoría **good**. Este resultado refleja el buen estado general de estas ciudades, impulsado por las normativas de rehabilitación de fachadas, manteniendo un nivel más que adecuado pero sin alcanzar el nivel de excelencia de Ámsterdam.
- **El deterioro de Manhattan:** El sector analizado de Nueva York presenta la proporción más alta de edificios en estado deficiente (**poor**) en relación con el tamaño de su muestra, igualando casi a su categoría principal (**good**). La IA penaliza la presencia de infraestructuras oxidadas (como las típicas escaleras de incendios exteriores), mampostería oscurecida por la polución o antiguas fachadas industriales pendientes de renovación.
- **Polarización del modelo:** Resulta llamativa la ausencia casi total de la categoría intermedia **fair** (regular/aceptable) en las cuatro ciudades. Se trata de un sesgo de polarización en la inferencia del VLM. Ante la evaluación del deterioro, el modelo tiende a clasificar de forma binaria, categorizando el edificio como dañado (**poor**) si detecta defectos evidentes, o saltando directamente a un buen estado (**good/excellent**).

5.6.4. Análisis de la proporción de acristalamiento

En esta sección se analiza la superficie acristalada de las fachadas, (*glazing ratio*). La Figura 9 muestra mediante gráficos de barras la frecuencia de las distintas categorías de acristalamiento detectadas por el modelo VLM en las cuatro ciudades.

El análisis revela adaptaciones climáticas evidentes y decisiones estilísticas propias de cada región:

- **La búsqueda de luz en Ámsterdam:** El gráfico de Ámsterdam muestra una dominancia de la categoría **high**. Esta enorme proporción de vidrio responde a una




Figura 9: Distribución de la proporción de vidrio en las fachadas de las zonas de estudio.

necesidad climática e histórica del norte de Europa: maximizar la entrada de la escasa luz solar natural. La arquitectura tradicional holandesa se caracteriza por grandes ventanales que ocupan gran parte de la anchura de las estrechas fachadas.

- **El equilibrio en Madrid y París:** En claro contraste, el centro histórico de Madrid presenta un predominio de la categoría **medium** (media), seguida muy de cerca por la **low** (baja) e incluso registrando valores notables en **none**. La muestra parisina exhibe una clara concentración en la categoría **medium**, con una presencia secundaria pero notable de **high**. Esta distribución ilustra a la perfección el equilibrio entre el “lleno y el vacío” dictado por la arquitectura clásica francesa. Los bloques de viviendas cuentan con grandes ventanales regulares (puertas ventana) para dar acceso a los balcones, pero siempre manteniendo una proporción estructurada y armónica.
- **El contraste de Manhattan:** Nueva York presenta el perfil más polarizado de la comparativa. Destaca fuertemente la categoría **high**, lo cual es coherente con

la arquitectura corporativa contemporánea y el uso extensivo del muro cortina de vidrio, prevalente en sus rascacielos. Sin embargo, también presenta un bloque considerable en **low**, correspondiente a las antiguas estructuras, demostrando de nuevo la variabilidad de arquitecturas en la ciudad.

5.7. Análisis de score (Sentimientos)

En esta sección, vamos a ver los ejemplos más y menos representativos de cada categoría puntuada (Aburrido, Agradable, Complejo, Ordenado y Original). Para ello, tomamos tres muestras aleatorias, de dimensiones similares, con la puntuación máxima (10.0) y la mínima (0.0):








Categoría	Más representativas	Menos representativas
Aburrido		
Agradable		
Complejo		
Ordenado		
Original		

Tabla 6: Ejemplos de fachadas más y menos representativas por categoría

Se observa que el modelo es capaz de diferenciar y asignar puntuaciones siguiendo un cierto criterio de consistencia, aunque los resultados obtenidos no alcanzan el nivel de

rendimiento reportado en el artículo [7]. Esta diferencia de desempeño puede atribuirse a diversos factores:

- En primer lugar, el modelo *internvl3* ha sido previamente ajustado mediante fine-tuning para responder a las preguntas definidas en el primer prompt. En consecuencia, desviarse de dicho esquema de entrada puede provocar una disminución en la tasa de acierto y en la precisión de las predicciones.
- Por otro lado, el conjunto de datos utilizado es considerablemente más reducido, lo que limita la variabilidad de los ejemplos disponibles. Esto puede dar lugar a una menor diferenciación entre imágenes asociadas a puntuaciones extremas.

5.7.1. Análisis individual

En esta sección se presentará, para cada ciudad, una fachada aleatoria acompañada de su correspondiente diagrama de radar, en el que se visualizarán los distintos indicadores con sus puntuaciones.





Figura 10: Muestra aleatoria de fachada de cada ciudad con su análisis score

El diagrama de radar constituye una representación especialmente adecuada para el análisis comparativo multivariante, ya que permite visualizar de forma simultánea el comportamiento de distintas métricas sobre una misma unidad de observación.


En este caso, lo aplicamos para sintetizar la información de las distintas puntuaciones, facilitando la identificación de patrones, equilibrios y discrepancias entre categorías. Además, este tipo de visualización ofrece una interpretación intuitiva de la estructura global de cada muestra.

5.7.2. Análisis de la percepción estética y visual


En esta sección se evalúan las métricas subjetivas o de “sentimiento” inferidas por el modelo *internvl3*, las cuales puntúan del 0 al 10 diferentes características estéticas de las fachadas. La Figura 11 agrupa los diagramas de cajas correspondientes a la distribución de estas cinco puntuaciones (*complex*, *original*, *boring*, *ordered*, *pleasing*) para las cuatro ciudades.




(a) Distribución de scores, Madrid



(b) Distribución de scores, París



(c) Distribución de scores, Manhattan



(d) Distribución de scores, Ámsterdam

Figura 11: Distribución de scores de cada ciudad

La comparativa de estos diagramas revela cómo el modelo cuantifica el impacto visual

de las diferentes capitales:

- **Consenso estético en París y Ámsterdam:** Ambas ciudades muestran un perfil casi idéntico y altamente positivo. Las métricas de complejidad, originalidad, orden y atractivo presentan medianas muy elevadas (en torno a 8) y cajas intercuartílicas compactas. En ambas gráficas, la puntuación de monotonía (**boring**) se desploma, con una mediana de 1 y un rango prácticamente nulo, en el caso de Ámsterdam, y con cierta variabilidad para París, aunque también presenta valores inferiores. Esto indica que *internvl3* percibe la arquitectura histórica de estas capitales como visualmente rica, armónica y poco repetitiva.
- **La polarización de Manhattan:** Nueva York presenta una anomalía muy llamativa en la métrica de monotonía (**boring**). Aunque sus puntuaciones positivas se mantienen altas, la caja intercuartílica de la variable **boring** abarca todo el espectro posible (del 1 al 10, con una mediana en 5). Esta extrema varianza refleja el fuerte contraste de arquitecturas del distrito analizado.
- **Centro histórico de Madrid:** El centro histórico de Madrid muestra el perfil más discreto de la muestra europea. Aunque métricas como originalidad y atractivo se mantienen en niveles notables, con medianas de 7, la complejidad visual cae significativamente hasta una mediana de 5, mostrando además una gran dispersión. Esto es plenamente coherente con la arquitectura tradicional y las construcciones residenciales madrileñas, caracterizadas por fachadas más planas y con una menor cantidad de elementos decorativos salientes en comparación con el resto de ciudades.

5.7.3. Matrices de correlación

Esta fase final del estudio está dedicada a la exposición y contraste de las matrices de correlación de las distintas ciudades. Mediante este análisis, se busca determinar las relaciones existentes entre las variables y las interpretaciones del modelo *InternVL*:

Vamos a abordar los resultados de la Figura 12 desde dos puntos totalmente distintos:

- Desde esta perspectiva vamos a suponer que el modelo ha sido capaz de generalizar y los resultados son fiables. En tal caso, vemos como, en todas las ciudades, las características de complejo, original, agradable y ordenado, están altamente correlacionadas, se le puede atribuir cierto sentido, ya que por lo general, una fachada con muchos detalles (compleja) también se tiene una percepción de original, además de




Figura 12: Matrices de correlación de las 4 ciudades.

agradable, y una original también puede ser agradable. Por otro lado, la característica de ordenado con complejo puede depender de la fachada, al igual que ordenado y original. El sentido que le damos es personal y puede estar sesgado o no ser del todo correcto. La última característica a comentar (aburrido) vemos que no tiene relación lineal con ninguna otra.

- Otra posible interpretación de nuestro resultados es cuestionarnos la capacidad de nuestro modelo para identificar y puntuar dichas características, es decir, como ya se ha comentado, al modelo le hemos encargado tareas para las cuales no ha sido entrenado, por lo que es posible que su rendimiento disminuya. En este caso en

concreto, es posible que el modelo confunda, o entienda de manera muy similar, el significado de complejo, original, agradable y ordenado, en términos de fachadas. Un estudio futuro de este comportamiento sería de gran ayuda para la fiabilidad de nuestros resultados.

6. Conclusiones

En este trabajo se ha escalado y expandido con éxito el *framework* de *OpenFACADES*. A partir de la delimitación de regiones geográficas (*bounding boxes*) y la combinación de Sistemas de Información Geográfica, imágenes a nivel de calle (SVI) y Modelos de Visión-Lenguaje (VLM), se ha logrado extraer, depurar y analizar información de las fachadas de cuatro capitales (Madrid, París, Ámsterdam y Nueva York) a gran escala, cumpliendo de forma satisfactoria la mayoría de los objetivos planteados.

El uso de bases de datos vectoriales como *Overture Maps* junto con filtros geométricos ha sido importante para limpiar la muestra de estructuras irrelevantes. Asimismo, la captura SVI mediante la API de Mapillary y el recorte con *GroundingDINO* permitieron aislar las fachadas del ruido del entorno urbano.

Se validó la necesidad de deduplicar y balancear la muestra para evitar que ciudades como Ámsterdam sesgaran la comparativa además de requerir horas e incluso días de procesamiento. El desarrollo del sistema de corrección de las salidas del modelo en formato JSON fue también un éxito para poder realizar el estudio adecuadamente.

El modelo de Inteligencia Artificial (*internvl*) cumplió su función al identificar de forma general los patrones urbanos requeridos. Gracias a la expansión de la ingeniería de *prompts*, las extracciones coincidieron con la realidad histórica y normativa de cada región.

En cuanto a la evaluación subjetiva (*scores*), aunque el modelo *InternVL* no estaba específicamente entrenado para esta tarea, fue capaz de cuantificar atributos estéticos abstractos, logrando puntuar de forma coherente los atributos que se le pidieron.

Líneas futuras de investigación y mejora

A pesar de los avances logrados en este proyecto, la aplicación de la Inteligencia Artificial al análisis urbano es un campo en constante evolución. A partir de las limitaciones identificadas durante el desarrollo de este trabajo, se proponen las siguientes vías de me-

jora e investigación futura:

- **Integración con Google Street View y plataformas alternativas:** Aunque Mapillary ofrece un entorno colaborativo abierto, su cobertura en ciertas áreas urbanas es irregular. Una futura línea de desarrollo prioritario es la integración y adaptación del código para consumir la API de Google Street View (GSV). Como se ha comentado, en este trabajo se ha tratado de realizar esta integración sin embargo como se comentó no fue posible debido a la limitación de recursos.
- ***Fine-Tuning* del modelo de Visión-Lenguaje:** Para corregir algunos sesgos detectados en los resultados, se propone abandonar el enfoque *Zero-Shot* (modelo preentrenado general) y realizar un *fine-tuning* del modelo VLM utilizando *datasets* específicos de historia de la arquitectura, mejorando así su precisión en la datación y la detección de estilos concretos.
- **Análisis de vistas cruzadas (*Cross-View Analysis*):** Ampliar el ecosistema de datos cruzando la información obtenida a pie de calle (SVI) con imágenes satelitales o de drones de alta resolución. Esto permitiría evaluar no solo la fachada, sino el volumen de las edificaciones, el uso de patios interiores y otras características.

A. Anexo

A continuación y por simplicidad, se adjunta el enlace de Google Colab, donde se ha realizado toda la parte de Python del trabajo:

`https://colab.research.google.com/drive/1TpR1v6hQUKxQ8Dqk5dmgPqvQsp\_TtaZh?usp=sharing`

Referencias

- [1] Filip Biljecki and Kohei Ito. Street view imagery in urban analytics and gis: A review. *Landscape and Urban Planning*, 215:104217, 2021.
- [2] Filip Biljecki, Jantien Stoter, Hugo Ledoux, Sisi Zlatanova, and Arzu Çöltekin. Applications of 3d city models: State of the art review. *ISPRS International Journal of Geo-Information*, 4(4):2842–2889, 2015.
- [3] B. Lei, X. Liang, and F. Biljecki. Integrating human perception in 3d city models and urban digital twins. *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, 10:211–218, 2024.
- [4] Xiaojiang Li, Chuanrong Zhang, Weidong Li, Robert Ricard, Qingmin Meng, and Weixing Zhang. Assessing street-level urban greenery using google street view and a modified green view index. *Urban Forestry & Urban Greening*, 14(3):675–685, 2015.
- [5] X. Liang, S. Cheng, and F. Biljecki. Decoding characteristics of building facades using street view imagery and vision-language model. In *19th International Conference on Computational Urban Planning & Urban Management (CUPUM 2025)*, June 2025.
- [6] X. Liang, W. Yap, and F. Biljecki. Heterogeneous graph neural networks for building attribute prediction from hierarchical urban features and cross-view imagery. *ISPRS Journal of Photogrammetry and Remote Sensing*, 234:185–204, 2026.
- [7] Xiucheng Liang, Jiat Hwee Chang, Song Gao, Tianhong Zhao, and Filip Biljecki. Evaluating human perception of building exteriors using street view imagery. *Building and Environment*, 263:111875, 9 2024.
- [8] Xiucheng Liang, Jinheng Xie, Tianhong Zhao, Rudi Stouffs, and Filip Biljecki. Open-facades: An open framework for architectural caption and attribute data enrichment via street view imagery. *ISPRS Journal of Photogrammetry and Remote Sensing*, 230:918–942, 2025.
- [9] Shilong Liu, Zhaoshui Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, et al. Grounding dino: Marrying dino with grounded pre-training for open-set object detection. *arXiv preprint arXiv:2303.05499*, 2023.
- [10] Vítor Oliveira. *Urban Morphology: An Introduction to the Study of the Physical Form of Cities*. Springer, 2016.

- [11] Fan Zhang, Bolei Zhou, Lin Liu, Yu Liu, Helene H Fung, Hui Lin, and Carlo Ratti. Measuring human perceptions of a large-scale urban region using machine learning. *Landscape and Urban Planning*, 180:148–160, 2018.