

Práctica 9.2. Calibración Parte II

Carlos Sanchiz Pérez

Nicolás Vives Vicente

Escuela Politécnica Superior

Máster Universitario en Ciencia de Datos

Machine Learning

Curso académico [2025-2026]



Universitat d'Alacant
Universidad de Alicante

Índice

1. Experimentos	3
1.1. Conjunto de datos	3
1.2. Modelo base	3
1.3. Estudio 1: Temperature Scaling	3
1.4. Estudio 2: Focal Loss	4
2. Resultados	4
2.1. Resultados del Estudio 1: Temperature Scaling	4
2.2. Resultados del Estudio 2: Focal Loss	5
3. Extensión opcional	7
4. Conclusiones	7

1. Experimentos

1.1. Conjunto de datos

El conjunto de datos seleccionado es CIFAR-10. Este conjunto consta de 60,000 imágenes a color (RGB) de 32x32 píxeles, divididas equitativamente en 10 clases: aviones, automóviles, barcos, camiones, pájaros, gatos, ciervos, perros, ranas y caballos. Para adaptarlo al modelo, las imágenes han sido sometidas a una fase de preprocesamiento. En primer lugar, se han convertido a escala de grises, reduciendo la dimensionalidad de los datos de tres canales de color a un único canal. Además, los valores de los píxeles han sido normalizados, escalándolos para que la red procese las características de manera más eficiente, contribuyendo a una convergencia más rápida y estable durante el entrenamiento.

1.2. Modelo base

Para la realización de los experimentos se ha empleado la Red Neuronal Convolutiva (CNN) incluida en el código base y que consta de las siguientes componentes:

- Dos bloques de extracción de características, cada uno compuesto por una capa convolutiva 2D (de 32 y 64 filtros respectivamente, con tamaño de kernel 3x3 y activación ReLU), seguida de una reducción de dimensionalidad mediante *MaxPooling* (2x2) y regularización *Dropout* con una tasa del 10%.
- Un bloque de clasificación compuesto por una capa *Flatten*, una capa *Dense* oculta de 128 neuronas (activación ReLU) y una capa de salida (*logits*) con el número de clases correspondientes, seguida de una *Softmax* para transformar en probabilidades.

El entrenamiento del *baseline* se configuró con el optimizador Adam y la función de pérdida *Sparse Categorical Crossentropy*. El entrenamiento se ejecutó durante 20 épocas, con un *batch size* de 128 y una semilla fija para la reproducibilidad de los resultados.

1.3. Estudio 1: Temperature Scaling

El primer estudio tiene como objetivo analizar el efecto del método *post-hoc Temperature Scaling* sobre la calibración del modelo base. Para ello, tras el entrenamiento inicial del modelo con *Cross-Entropy*, se procedió a ajustar el parámetro de temperatura (T).

Este ajuste se realizó únicamente sobre el conjunto de validación para evitar *overfitting* sobre el conjunto de test. Se utilizó la función `fit_temperature` proporcionada en el *notebook* para encontrar el valor de T que minimiza la pérdida *Negative Log-Likelihood* en validación. Una vez obtenida la T óptima, se escalaron los *logits* del conjunto de test con el parámetro encontrado para evaluar de nuevo con la función `predict_tscaling`.

1.4. Estudio 2: Focal Loss

El segundo estudio tiene como objetivo analizar cómo afecta el uso de la función de pérdida *Focal Loss* a la calibración del modelo durante su fase de entrenamiento y si supone una mejora frente a la *Cross-Entropy*. Para llevar a cabo este experimento, se utilizó la misma arquitectura base descrita anteriormente, pero modificando la función de pérdida. La *Focal Loss* introduce un parámetro γ que reduce el peso de los ejemplos fáciles de clasificar, centrando la atención de la red en los ejemplos más difíciles. Se entrenaron tres modelos independientes variando este hiperparámetro con los valores $\gamma \in \{1, 2, 5\}$.

El entrenamiento de estos modelos se configuró con un tamaño de *batch* de 128 y 20 *epochs*. Finalmente, se evaluó cada configuración directamente sobre el conjunto de test, sin aplicar *Temperature Scaling*, para observar el efecto aislado de la *Focal Loss* en el *accuracy* y en el Error Esperado de Calibración (ECE).

2. Resultados

2.1. Resultados del Estudio 1: Temperature Scaling

Al aplicar la función de optimización sobre el conjunto de validación, se encontró un valor de temperatura óptima de $T = 1,80$. Puesto que este valor es mayor que 1, indica que el modelo original estaba ligeramente sobreconfiado, y la temperatura actúa “suavizando” la distribución de probabilidades de salida para hacerlas menos extremas.

En la evaluación final sobre el conjunto de test, se obtuvieron las siguientes métricas:

Modelo	Accuracy	ECE
Base (Sin calibrar)	0.5237	0.1713
Calibrado ($T = 1.80$)	0.5237	0.0224

Tabla 1: Comparativa de métricas en test (Estudio 1)

Como se puede observar en la Tabla 1, el ECE se ha reducido de forma notable, pasando de 0.1713 a 0.0224. Esto demuestra una clara mejora en la calibración del modelo. Al mismo tiempo, se observa que el *accuracy* se mantiene exactamente igual en 0.5237. Este comportamiento es coherente con el método ya que *Temperature Scaling* aplica una transformación escalar constante a todos los *logits* antes de la función *Softmax*, por lo que no altera el orden de las predicciones ni la clase mayoritaria, logrando mejorar la calibración sin sacrificar en absoluto la capacidad predictiva del modelo. En la Figura 1 se puede apreciar esta mejora de la calibración.




Figura 1: Diagramas de fiabilidad en Test. Izquierda: Modelo base ($ECE = 0.1713$). Derecha: Modelo calibrado con $T = 1,80$ ($ECE = 0.0224$).

Los diagramas de fiabilidad (Figura 1) respaldan esta mejora. En el diagrama del modelo base se aprecia cómo la curva de confianza media se sitúa por encima del acierto real. Tras la calibración, la brecha entre la confianza y el acierto real se reduce notablemente, acercándose de manera mucho más fiel a la diagonal discontinua de calibración perfecta.

2.2. Resultados del Estudio 2: Focal Loss

Tras evaluar los diferentes modelos entrenados con *Focal Loss* sobre el conjunto de test, se obtuvieron los resultados resumidos en la Tabla 2, donde se comparan con el modelo de referencia entrenado con *Cross-Entropy* (equivalente a $\gamma = 0$).

Analizando la Tabla 2, se observa que el *accuracy* se mantiene muy estable en todas

Configuración	Accuracy	ECE
Cross-Entropy ($\gamma = 0$)	0.5237	0.1713
Focal Loss ($\gamma = 1.0$)	0.5292	0.1028
Focal Loss ($\gamma = 2.0$)	0.5233	0.0862
Focal Loss ($\gamma = 5.0$)	0.5312	0.0453

Tabla 2: Comparativa de métricas en Test para distintas configuraciones de Focal Loss.

las configuraciones, oscilando entre el 52.3% y el 53.1%. Vemos una clara tendencia, a medida que aumentamos γ , el valor del ECE disminuye. Con $\gamma = 5$, conseguimos el mejor ECE de la comparativa (0.0453) y la mejor precisión (0.5312).

Estas observaciones numéricas se reflejan de forma clara en los diagramas de fiabilidad de la Figura 2.




Figura 2: Comparativa de Diagramas de Fiabilidad. De izquierda a derecha: Cross-Entropy, Focal Loss ($\gamma = 1.0$), Focal Loss ($\gamma = 2.0$) y Focal Loss ($\gamma = 5.0$).

En las tres primeras gráficas se aprecia un claro problema de sobreconfianza: la curva que une los puntos de confianza media se sitúa muy por encima del acierto real en casi todos los *bins*. El modelo predice con mucha seguridad, pero acierta menos de lo que cree.

Por el contrario, el diagrama de la derecha ($\gamma = 5.0$) muestra un comportamiento mucho más equilibrado. Las alturas de las barras se ajustan casi a la perfección con la confianza media de las predicciones, quedándose cerca de la diagonal de calibración ideal.

En cuanto a la existencia de un compromiso entre calibración y *accuracy*, en este experimento concreto no se ha manifestado de forma negativa. Principalmente la configuración con $\gamma = 5.0$ demuestra que es posible mejorar simultáneamente ambas métricas durante el entrenamiento, sin necesidad de sacrificar capacidad predictiva para obtener probabilidades más fiables.

3. Extensión opcional

Para este apartado opcional se pretende aplicar también *Temperature Scaling* a los modelos entrenados con *Focal Loss* y analizar si la combinación de ambas estrategias mejora aún más los resultados. Una vez aplicado *Temperature Scaling*, obtenemos los resultados resumidos en la Tabla 3.

Configuración	ECE sin TS	ECE con TS
Cross-Entropy ($\gamma = 0$)	0.1713	0.0224
Focal Loss ($\gamma=1.0$)	0.1028	0.0175
Focal Loss ($\gamma=2.0$)	0.0862	0.0114
Focal Loss ($\gamma=5.0$)	0.0453	0.0274

Tabla 3: Diferencia de ECE en los modelos según *Temperature Scale*.

Analizando la Tabla 3, vemos como el *Temperature Scaling* reduce significativamente el ECE en todos los modelos, confirmando su eficacia como método de calibración *post-hoc*. La mejor combinación observada es *Focal Loss* con $\gamma = 2$ junto con *Temperature Scaling*, logrando el menor ECE (0.0114).




Figura 3: Comparativa de Diagramas de Fiabilidad, con *Temperature Scaling*.

En la Figura 3, vemos también cómo tras la calibración, la brecha entre la confianza (puntos) y el acierto real (barras) se reduce significativamente, acercándose de manera mucho más fiel a la diagonal discontinua de calibración perfecta.

4. Conclusiones

A lo largo de este ejercicio se ha analizado el impacto de dos aproximaciones distintas para mitigar los problemas de calibración en redes neuronales: un método *post-hoc* (*Tem-*

perature Scaling) y un método basado en la modificación de la función de pérdida durante el entrenamiento (*Focal Loss*).

Del primer estudio se concluye que *Temperature Scaling* es una técnica efectiva y computacionalmente muy eficiente. Al ajustar el parámetro de temperatura T sobre el conjunto de validación, se logró reducir significativamente el Error Esperado de Calibración (ECE) del modelo sobreconfiado inicial, suavizando sus predicciones. Su mayor ventaja es que, al ser una transformación monótona que afecta por igual a todos los *logits*, preserva intacto el *accuracy* del modelo, garantizando que no exista un compromiso negativo entre el acierto y la calibración.

Del segundo estudio se extrae que el uso de *Focal Loss* tiene un impacto en la calibración del modelo, a medida que aumentaba el parámetro γ en $\gamma \in \{0, 1.0, 2.0\}$ disminuía el ECE. Con un mayor valor ($\gamma = 5.0$) se consiguió guiar a la red para que prestara más atención a los ejemplos difíciles, logrando no solo el mejor ECE de todas las pruebas realizadas, sino también una ligera mejora en el *accuracy* final.

Por último, gracias a la extensión opcional, hemos podido comprobar como una combinación de ambas técnicas estrategias mejora aún más los resultados.

Como líneas de trabajo futuro para ampliar este estudio, se proponen las siguientes extensiones:

- **Mayor variación de los parámetros T y γ :** Estudiar más posibilidades de ambos parámetros podría quizá mejorar aún más la calibración y los resultados.
- **Evaluación en arquitecturas complejas:** Replicar el experimento utilizando arquitecturas más profundas (como ResNet o VGG), ya que el problema de la mala calibración tiende a acentuarse a medida que aumenta la profundidad y la capacidad de la red.
- **Ampliación de métricas:** Incorporar métricas adicionales como el *Brier Score* o evaluar directamente la pérdida *Negative Log-Likelihood* (NLL) en el conjunto de test para tener una visión más completa sobre la incertidumbre del modelo.