

Práctica 9.1. Calibración Parte I

Carlos Sanchiz Pérez

Nicolás Vives Vicente

Escuela Politécnica Superior

Máster Universitario en Ciencia de Datos

Machine Learning

Curso académico [2025-2026]



Universitat d'Alacant
Universidad de Alicante

Índice

1. Introducción	3
1.1. Conjunto de datos	3
1.2. Modelo base elegido	3
1.3. Escenarios de desequilibrio	3
2. Estudios	4
2.1. Estudio 1: Aumento de datos	4
2.2. Estudio 2: Label Smoothing	4
3. Resultados	5
3.1. Impacto del desequilibrio de clases (Baseline)	5
3.2. Estudio 1: Efectividad del Aumento de Datos	6
3.3. Estudio 2: Efectividad del <i>Label Smoothing</i>	6
4. Conclusiones	7

1. Introducción

1.1. Conjunto de datos

El conjunto de datos seleccionado es CIFAR-10. Este conjunto consta de 60,000 imágenes a color (RGB) de 32x32 píxeles, divididas equitativamente en 10 clases: aviones, automóviles, barcos, camiones, pájaros, gatos, ciervos, perros, ranas y caballos. Para adaptarlo a las necesidades del modelo elegido, las imágenes han sido sometidas a una etapa de preprocesamiento. En primer lugar, se han convertido a escala de grises, reduciendo la dimensionalidad de los datos de tres canales de color a un único canal. Adicionalmente, los valores de los píxeles han sido normalizados, escalándolos para asegurar que la red procese las características de manera más eficiente, lo que contribuye a una convergencia más rápida y estable durante el entrenamiento.

1.2. Modelo base elegido

Para llevar a cabo los experimentos, se ha seleccionado como modelo base la arquitectura proporcionada en la función `createModel3`, que consiste en una Red Neuronal Convolutiva (CNN). Se ha elegido este modelo frente a los basados en capas densas (perceptrones multicapa de `createModel1` y `createModel2`) debido a la naturaleza del conjunto de datos utilizado, CIFAR-10. Al tratarse de un problema de clasificación de imágenes complejas, una arquitectura convolutiva es capaz de extraer y preservar las características del espacio (mediante el uso de capas convolucionales y de *Max Pooling*), mientras que los modelos densos las ignorarían al aplanar la entrada desde el primer momento.

Se realizará el entrenamiento con un total de 20 *epochs* y un tamaño de *batch* de 128.

1.3. Escenarios de desequilibrio

Para evaluar el impacto del desbalanceo de clases en la calibración predictiva del modelo, se han utilizado dos escenarios de experimentación distintos:

- **Escenario Original (Control):** Se utiliza la distribución natural del conjunto de datos CIFAR-10, donde las diez clases están perfectamente equilibradas. Este escenario sirve como línea base (*baseline*) para conocer el error de calibración del modelo en condiciones ideales.

- **Escenario Severo:** Se induce un desequilibrio extremo en el conjunto de entrenamiento. Concretamente, se elimina el 99.9 % de las muestras de las clases 0 a 5, el 70 % de las muestras de las clases 6 a 8, y el 50 % de la clase 9. Este escenario simula un entorno real de escasez severa de datos para ciertas categorías, lo que fuerza al modelo a sesgar sus predicciones hacia las clases mayoritarias.

2. Estudios

2.1. Estudio 1: Aumento de datos

El propósito de este primer estudio es analizar si las técnicas de aumento de datos (*data augmentation*) pueden actuar como un mecanismo regularizador que reduzca la pérdida de calibración provocada por el desequilibrio de clases. Para ello, se comparará el modelo base (entrenado sin aumento) frente a dos configuraciones de parámetros distintas durante la etapa de entrenamiento:

- **Configuración Suave:** Aplica transformaciones espaciales conservadoras, permitiendo únicamente rotaciones aleatorias de hasta 10 grados y volteo horizontal (*horizontal flip*). Su objetivo es aportar una ligera variabilidad sin deformar en exceso las características originales de las imágenes.
- **Configuración Agresiva:** Introduce un nivel de distorsión mucho mayor. Además del volteo horizontal, permite rotaciones de hasta 20 grados, desplazamientos tanto horizontales como verticales del 20 %, variaciones de cizallamiento (*shear*) del 20 % y un zoom aleatorio del 20 %. El objetivo es forzar al modelo a extraer patrones invariantes mucho más robustos, evaluando si esta configuración extrema penaliza o beneficia la confianza de sus predicciones.

2.2. Estudio 2: Label Smoothing

Como mecanismo adicional para reducir el error de calibración provocado por el desequilibrio de clases, se ha elegido la técnica de *Label Smoothing*. Consiste en actuar directamente sobre la función de pérdida (*Categorical Crossentropy*), sustituyendo los vectores de etiquetas *One-Hot* por distribuciones de probabilidad más suaves. Esta técnica penaliza la sobreconfianza extrema, obligando a la red neuronal a mantener un margen de duda razonable en sus predicciones. Para este estudio, se evaluarán dos configuraciones

y se compararán con el modelo base original: un suavizado leve con factor $\alpha = 0,1$ y un suavizado más restrictivo con factor $\alpha = 0,2$.

3. Resultados

3.1. Impacto del desequilibrio de clases (Baseline)

Para establecer una línea base, se evalúa el modelo *createModel3* sin aumento de datos en ambos escenarios sobre el conjunto de validación. En el **Escenario Original**, el modelo alcanza una exactitud (*accuracy*) del 71.25 % y un error de calibración (ECE) excelente de 0.014. Sin embargo, al introducir el **Escenario Severo**, el rendimiento general cae: la exactitud se reduce al 33.95 % y el ECE se dispara hasta 0.459.

Al observar el diagrama de confiabilidad de la Figura 1, se evidencia que para el escenario severo el modelo se vuelve extremadamente sobreconfiado. La falta de datos en las clases minoritarias provoca que la red sesgue sus predicciones hacia las clases mayoritarias, asignando probabilidades cercanas a 1.0 a predicciones que resultan ser incorrectas en la mayoría de los casos.




Figura 1: Diagrama de confiabilidad de los dos escenarios sin aumento de datos.

3.2. Estudio 1: Efectividad del Aumento de Datos

Al introducir técnicas de aumento de datos, se observan comportamientos distintos dependiendo del nivel de desequilibrio:

- **Escenario Original:** El aumento de datos actúa penalizando ligeramente la exactitud (cayendo al 64.64 % con aumento suave y 57.74 % con agresivo). Sin embargo, la configuración suave logra mejorar levemente la calibración, reduciendo el ECE de 0.014 a 0.008.
- **Escenario Severo:** Es aquí donde el aumento de datos demuestra ser útil. Aunque la exactitud general no mejora, el aumento suave logra reducir el ECE a 0.391 (desde el 0.459 del modelo base), y el aumento agresivo consigue una mayor reducción, bajando el ECE hasta **0.332**.




Figura 2: Variación del diagrama de confiabilidad de los dos escenarios en el estudio 1.

Estos resultados nos indican que, cuando tenemos una gran escasez de datos, aplicar transformaciones espaciales agresivas impide que el modelo memorice las probabilidades *a priori* de las clases mayoritarias. Aunque el modelo duda más a la hora de predecir (menor *accuracy*), la confianza de sus predicciones se vuelve mucho más realista y alineada con la realidad (mejor ECE).

3.3. Estudio 2: Efectividad del *Label Smoothing*

La implementación del *label smoothing* proporciona resultados contrastantes dependiendo de la naturaleza del conjunto de entrenamiento:

- **Escenario original:** La aplicación de esta técnica resulta contraproducente para la calibración. Aunque la exactitud mejora ligeramente (alcanzando el 73.09 %), obligar a la red a distribuir su confianza en un escenario donde los datos ya son representativos la vuelve subconfiada de forma artificial, aumentando el ECE desde 0.014 hasta 0.166.
- **Escenario severo:** La técnica de *label smoothing* demuestra ser un mecanismo corrector excepcional. La configuración fuerte (factor 0.2) no solo logra retener y mejorar ligeramente la exactitud obtenida por el modelo base (subiendo al 34.73 %), sino que consigue la mejor mitigación de calibración de todo el experimento, reduciendo el ECE a **0.234** (frente al 0.459 del modelo desbalanceado original y el 0.332 logrado por el aumento de datos agresivo).




Figura 3: Variación del diagrama de confiabilidad de los dos escenarios en el estudio 2.

El diagrama de confiabilidad muestra cómo la curva se aproxima significativamente a la diagonal de calibración perfecta. Al inyectar incertidumbre directamente en la función de pérdida, se contrarresta eficazmente la tendencia natural del modelo a sobreajustarse a la distribución sesgada de las clases mayoritarias.

4. Conclusiones

A partir de los resultados obtenidos en ambos estudios bajo los dos escenarios, se extraen las siguientes conclusiones:

- **La sobreconfianza en datos desbalanceados:** Como se observa en el modelo base (ECE de 0.459), cuando una red neuronal se entrena en un escenario de escasez severa de datos para ciertas clases, no solo pierde capacidad predictiva (*accuracy*), sino que se reduce su calibración. El modelo asume erróneamente las probabilidades del conjunto de entrenamiento sesgado, volviéndose extremadamente sobreconfiado.
- **La regularización mejora la fiabilidad:** Ambos mecanismos evaluados funcionan como regularizadores efectivos frente a la sobreconfianza. El aumento de datos (especialmente en la configuración más agresiva) dificulta la memorización de las clases mayoritarias, reduciendo el ECE a 0.332.
- **Utilidad del *Label Smoothing*:** Demuestra ser un método eficaz para ayudar a reducir el problema de calibración. Al aplicar un suavizado fuerte (0.2), se obliga a la red a mantener incertidumbre en la función de pérdida, logrando el mejor resultado en el conjunto de validación (ECE de 0.234 y un ligero incremento en *accuracy*).

Evaluación Final: Tras la etapa de experimentación, se evalúa el modelo que más mejora la calibración (*Label Smoothing* con $\alpha = 0,2$) sobre el conjunto de *test*.




Figura 4: Resultados en el conjunto de *test* del modelo con *Label Smoothing* Fuerte (0.2) bajo el escenario de desbalanceo de clases severo.

El modelo ha conseguido una exactitud final del **34.30 %** y un *Expected Calibration Error* (ECE) de **0.238**. Estos valores son consistentes con los obtenidos durante la fase de validación y confirman la solidez y capacidad de generalización de la técnica elegida para reducir la sobreconfianza en un conjunto de datos no vistos en entrenamiento.