

Práctica Machine Learning. Graph Neural Networks

Nicolás Vives Vicente

Escuela Politécnica Superior

Máster Universitario en Ciencia de Datos

Machine Learning

Curso académico [2025-2026]



Universitat d'Alacant
Universidad de Alicante

Índice

1. Introducción	7
2. MUTAG	8
2.1. Experimento 1: Evaluación de arquitecturas base	9
2.1.1. Configuración experimental	9
2.1.2. Descripción de las Arquitecturas	9
2.1.3. Análisis de resultados	10
2.2. Experimento 2: Impacto de <i>Global Add Pool</i>	10
2.2.1. Configuración Experimental	10
2.2.2. Justificación teórica	11
2.2.3. Análisis de Resultados	11
2.3. Experimento 3: Agregación por máximo (<i>Max Pooling</i>)	12
2.3.1. Configuración experimental	12
2.3.2. Justificación teórica	12
2.3.3. Análisis de Resultados	13
2.4. Experimento 4: Reducción de la profundidad	13
2.4.1. Configuración experimental	13
2.4.2. Justificación teórica	13
2.4.3. Ajustes de arquitectura	14
2.4.4. Análisis de resultados	14
2.5. Experimento 5: Optimización de los <i>Hidden Channels</i>	15
2.5.1. Justificación	15
2.5.2. Análisis de Resultados	16
2.6. Experimento 6: <i>Positional Encoding</i>	16
2.6.1. Configuración experimental	17
2.6.2. Análisis de resultados	17
2.7. Evaluación del modelo Net	18
2.7.1. Configuración del modelo	18

2.7.2.	Análisis de resultados	18
2.8.	Conclusiones y comparación con la referencia de la tesis	19
2.8.1.	Análisis Visual del Espacio Latente (t-SNE)	19
2.8.2.	Conclusión final y comparación con la tesis	20
3.	ENZYMES	20
3.1.	Experimento 1: Evaluación de Arquitecturas Base	22
3.1.1.	Configuración experimental	22
3.1.2.	Descripción de las arquitecturas	23
3.1.3.	Análisis de resultados	23
3.2.	Experimento 2: Impacto de Global Max Pool	24
3.2.1.	Justificación Teórica	24
3.2.2.	Análisis de Resultados	25
3.3.	Experimento 3: <i>Hidden Channels</i>	25
3.3.1.	Justificación Teórica	26
3.3.2.	Análisis de Resultados	26
3.4.	Experimento 4: <i>Positional Encoding</i> (k)	27
3.4.1.	Justificación Teórica	27
3.4.2.	Análisis de Resultados	27
3.5.	Evaluación del modelo Net	28
3.5.1.	Configuración del modelo	29
3.5.2.	Análisis de resultados	29
3.6.	Conclusiones y comparación con la referencia de la tesis	30
3.6.1.	Análisis Visual del Espacio Latente (t-SNE)	30
3.6.2.	Conclusión final y comparación con la tesis	31
4.	PROTEINS	32
4.1.	Experimento 1: Evaluación de arquitecturas base	34
4.1.1.	Configuración experimental	34
4.1.2.	Descripción de las arquitecturas	34
4.1.3.	Análisis de resultados	35

4.2.	Experimento 2: Impacto de Global Max Pool	35
4.2.1.	Justificación teórica	36
4.2.2.	Análisis de resultados	36
4.3.	Experimento 3: <i>Hidden Channels</i>	37
4.3.1.	Justificación Teórica	37
4.3.2.	Análisis de Resultados	37
4.4.	Experimento 4: <i>Positional Encoding (k)</i>	38
4.4.1.	Justificación Teórica	38
4.4.2.	Análisis de Resultados	39
4.5.	Evaluación del modelo Net	40
4.5.1.	Configuración del modelo	40
4.5.2.	Análisis de resultados	40
4.6.	Resultados finales y conclusiones: PROTEINS	41
4.6.1.	Análisis visual del espacio latente (t-SNE)	42
4.6.2.	Comparación con la tesis de referencia	43
5.	IMDB-BINARY	43
5.1.	Experimento 1: Evaluación de arquitecturas base	44
5.1.1.	Configuración experimental	44
5.1.2.	Descripción de las arquitecturas	45
5.1.3.	Análisis de resultados	46
5.2.	Experimento 2: Impacto de Global Max Pool	47
5.2.1.	Justificación teórica	47
5.2.2.	Análisis de resultados	47
5.3.	Experimento 3: Impacto de Global Add Pool	48
5.3.1.	Justificación teórica	48
5.3.2.	Análisis de resultados	48
5.4.	Experimento 4: <i>Hidden Channels</i>	49
5.4.1.	Justificación Teórica	50
5.4.2.	Análisis de Resultados	50

5.5.	Experimento 5: <i>Positional Encoding</i> (k)	51
5.5.1.	Justificación Teórica	51
5.5.2.	Análisis de Resultados	51
5.6.	Evaluación del modelo Net	52
5.6.1.	Configuración del modelo	52
5.6.2.	Análisis de resultados	53
5.7.	Conclusiones y comparación con la tesis	53
5.7.1.	Análisis visual del espacio latente (t-SNE)	54
5.7.2.	Conclusión final y comparación con la tesis	55
6.	REDDIT-BINARY	55
6.1.	Experimento 1: Evaluación de arquitecturas base	57
6.1.1.	Configuración experimental	57
6.1.2.	Descripción de las arquitecturas	58
6.1.3.	Análisis de resultados	58
6.2.	Experimento 2: Impacto de Global Max Pool	59
6.2.1.	Análisis de resultados	59
6.3.	Experimento 3: <i>Hidden Channels</i>	60
6.3.1.	Justificación Teórica	60
6.3.2.	Análisis de Resultados	61
6.4.	Experimento 4: Profundidad de la red (<i>Num. Layers</i>)	62
6.4.1.	Justificación Teórica	62
6.4.2.	Análisis de Resultados	62
6.5.	Experimento 5: <i>Positional Encoding</i> (k)	63
6.5.1.	Justificación teórica	63
6.5.2.	Análisis de Resultados	64
6.6.	Evaluación del modelo Net	64
6.6.1.	Configuración del modelo	65
6.6.2.	Análisis de resultados	65
6.7.	Conclusiones	66

6.7.1.	Análisis visual del espacio latente (t-SNE)	66
6.7.2.	Conclusión final	67
7.	COLLAB	68
7.1.	Experimento 1: Evaluación de arquitecturas base	70
7.1.1.	Configuración experimental	70
7.1.2.	Descripción de las arquitecturas	70
7.1.3.	Análisis de resultados	71
7.2.	Experimento 2: Impacto de las capas de agregación (Max y Add Pool) . . .	71
7.2.1.	Análisis de resultados	72
7.3.	Experimento 3: <i>Hidden Channels</i>	73
7.3.1.	Justificación Teórica	73
7.3.2.	Análisis de Resultados	73
7.4.	Experimento 4: Profundidad de la red (<i>Num. Layers</i>)	74
7.4.1.	Justificación Teórica	74
7.4.2.	Análisis de Resultados	75
7.5.	Experimento 5: <i>Positional Encoding</i> (k)	75
7.5.1.	Justificación teórica	76
7.5.2.	Análisis de Resultados	76
7.6.	Evaluación del modelo Net	77
7.6.1.	Configuración del modelo	77
7.6.2.	Análisis de resultados	77
7.7.	Conclusiones y comparación con la tesis	78
7.7.1.	Análisis visual del espacio latente (t-SNE)	79
7.7.2.	Conclusión final y comparación con la tesis	80

1. Introducción

En esta práctica se pretende determinar la utilidad de usar la información espectral en las redes neuronales de grafos. Esto va a depender del conjunto de datos y en principio será más decisiva en los datasets únicamente topológicos. En este último caso al no tener atributos a priori solo podríamos utilizar GCNEig y GCNEigDecoupled y no la GCN estándar, sin embargo, gracias a la creación de características sintéticas hemos conseguido resultados muy cercanos o iguales a los de la tesis [1].

Los conjuntos pertenecen a TUDataset de Pytorch geometric. Estos conjuntos son MUTAG, ENZYMES, PROTEINS, IMDB-BINARY, REDDIT BINARY y COLLAB.

Antes de comenzar con el entrenamiento y evaluación de los modelos conviene mencionar que se han detectado algunos problemas en el código proporcionado para la práctica y se han solucionado de la siguiente forma:

- Cálculo aislado del Laplaciano (*Graph-by-Graph*):
 - **Problema:** Calcular el Laplaciano sobre el *batch* completo genera un grafo enorme, con tantas componentes desconectadas como moléculas haya en el lote. Matemáticamente, esto produce un autovalor igual a cero por cada componente. Al seleccionar los k primeros, estos ceros acaparan la selección, entregando a la red autovectores vacíos que hacen inútil la geometría espacial y disparan el coste computacional al operar sobre una matriz gigante.
 - **Solución implementada:** Se ha aplicado una estrategia de “divide y vencerás”, modificando la función para que desempaque el lote y calcule el Laplaciano molécula por molécula de forma individual. Esto garantiza un único autovalor cero por grafo, reduciendo la complejidad computacional.
- Corrección del Bucle de Validación (*DataLoaders*):
 - **Problema:** La evaluación de modelos (incluyendo la red base *Net*) estaba consumiendo *DataLoaders* instanciados globalmente al inicio del *notebook*. Esto provocaba que, aunque los modelos variaran sus pesos iniciales y por tanto sí daban resultados distintos, no se estaba respetando la semilla de reproducibilidad para la partición de datos en las distintas iteraciones.
 - **Solución implementada:** Se ha reestructurado el bucle principal de evaluación. Ahora, la división del *dataset* y la generación de los *train_loader* y *test_loader* se ejecutan internamente en cada iteración, garantizando que los

datos de entrenamiento y prueba cambien respetando la partición de los datos según la semilla activa.

2. MUTAG

El conjunto de datos **MUTAG** es uno de los *datasets* más utilizados en la literatura de *Graph Deep Learning*, y pertenece a la colección TUDataset. Consiste en una colección de compuestos químicos nitroaromáticos clasificados según su efecto mutagénico en la bacteria *Salmonella typhimurium*.

Desde el punto de vista del aprendizaje supervisado, el objetivo es realizar una clasificación binaria de grafos para predecir si una molécula tiene o no propiedades mutagénicas. En esta representación, cada molécula es un grafo donde los nodos corresponden a los átomos y las aristas representan los enlaces químicos entre ellos.

A continuación se detallan las características principales del conjunto de datos:

- **Número total de grafos:** 188.
- **Número de características de nodo:** 7 (representan los tipos de átomos).
- **Número de clases:** 2 (mutagénico frente a no mutagénico).
- **Distribución de clases:** El conjunto presenta un ligero desequilibrio:
 - **Clase 0:** 63 muestras.
 - **Clase 1:** 125 muestras.

Tras inspeccionar el primer objeto de grafo del conjunto de datos, podemos ver que cuenta con **17 nodos (con vectores de características de 7 dimensiones)** y **38 aristas**, lo que resulta en un grado promedio de nodo de 2.24. Además, el conjunto de datos cuenta con exactamente **una etiqueta de grafo** ($y = [1]$) y proporciona **características de arista de 4 dimensiones** adicionales (`edge_attr=[38, 4]`). Sin embargo, no haremos uso de estas últimas en este estudio, centrando el análisis en las características de los nodos. A continuación, en la Figura 1 se muestra un ejemplo de molécula para cada una de las dos clases disponibles en el conjunto.




Figura 1: Moléculas de clase 0 (izquierda) y clase 1 (derecha) del dataset MUTAG.

2.1. Experimento 1: Evaluación de arquitecturas base

En esta primera fase, se establecen las líneas base para el dataset MUTAG. El objetivo es realizar la clasificación de las moléculas con los parámetros base del *notebook* original.

2.1.1. Configuración experimental

Se utilizarán los hiperparámetros de la Tabla 1. Esta configuración busca un equilibrio en un dataset cuyas dimensiones son reducidas.

Hiperparámetro	Valor
Canales Ocultos (<i>Hidden Channels</i>)	64
Número de Capas Convolucionales	3
Resolución Espectral (k)	4
Tipo de Agregación (<i>Pooling</i>)	Global Mean Pool

Tabla 1: Configuración inicial de los modelos para MUTAG.

2.1.2. Descripción de las Arquitecturas

A continuación se justifican las tres variantes implementadas basándose en su estructura de capas:

GCN (Control): Modelo de referencia que procesa únicamente las 7 características químicas de los nodos. Utiliza tres capas **GCNConv** de 64 canales para la propagación de mensajes, ignorando la geometría global del grafo.

GCNEig (Fusión Temprana): Integra la geometría desde la entrada aumentando la dimensión de los nodos a 11 (7 químicas + 4 espectrales). La red aprende correlaciones entre la química y la estructura espacial desde el primer nivel de convolución.

GCNEigDecoupled (Fusión Tardía): Mientras las convoluciones operan sobre la química (entrada dim 7), una rama lineal independiente (`lin2`) proyecta los 4 auto-vectores a un espacio de 32 dimensiones. Ambas señales se fusionan en la segunda profundidad de la red.

2.1.3. Análisis de resultados

Tras la evaluación de la configuración base, se obtuvieron las métricas detalladas en la Tabla 2. La precisión media tanto en el conjunto de entrenamiento (*Train Accuracy*) como en validación (*Test Accuracy*) han sido calculadas tras la prueba de 10 semillas aleatorias.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Mean	0	76.88 $\pm$ 1.74	74.04 $\pm$ 5.19
GCNEig	64	3	Mean	4	92.62 $\pm$ 2.12	80.21 $\pm$ 5.94
GCNEigDec.	64	3	Mean	4	86.38 $\pm$ 3.53	78.72 $\pm$ 5.40

Tabla 2: Resultados predictivos y configuración del Experimento 1 (Línea Base).

Bajo esta configuración se observa como el modelo **GCNEig** ofrece mejores resultados que el modelo **GCNEigDecoupled**, superando el 80 % de *accuracy* en el conjunto de validación.

A continuación, en el **Experimento 2**, se iterará sobre la *Readout Layer*, en el apartado 2.2.2 se justifica el por qué de este experimento.

2.2. Experimento 2: Impacto de *Global Add Pool*

Tras establecer la línea base, el segundo experimento se centra en optimizar la capa de lectura final (*Readout Layer*). Para ello, se modifica la función de agrupamiento de un promedio a una suma global.

2.2.1. Configuración Experimental

Se mantienen las arquitecturas del experimento anterior, variando únicamente el criterio de agregación, tal como se detalla en la Tabla 3.

Hiperparámetro	Valor
Canales Ocultos (<i>Hidden Channels</i>)	64
Número de Capas Convolucionales	3
Resolución Espectral (k)	4
Tipo de Agregación (<i>Pooling</i>)	Global Add Pool

Tabla 3: Configuración de los modelos empleando agregación aditiva.

2.2.2. Justificación teórica

La decisión de probar el agrupamiento por suma (**Global Add Pool**) se debe a la propia naturaleza del dataset MUTAG. En química, la mutagenicidad de una molécula suele estar condicionada por la presencia de subestructuras o grupos funcionales específicos (como un anillo aromático o un grupo nitro), y no por el comportamiento “promedio” de sus átomos.

Matemáticamente, al aplicar una función de media, la alta activación de un único nodo (que representa un átomo altamente tóxico) corre el riesgo de diluirse al dividirse entre la cardinalidad total del grafo. Por el contrario, la aplicación de una agregación por suma (**Global Add Pool**) acumula evidencias permitiendo a la red clasificar la molécula como mutagénica si detecta la presencia de los grupos en cualquier región de la estructura.

2.2.3. Análisis de Resultados

La utilización de la (**Global Add Pool**) proporcionó los resultados presentados en la Tabla 4.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Add	0	79.71 $\pm$ 1.99	76.17 $\pm$ 5.19
GCNEig	64	3	Add	4	94.76 $\pm$ 2.64	78.51 $\pm$ 4.16
GCNEigDec.	64	3	Add	4	86.60 $\pm$ 3.21	80.00 $\pm$ 4.58

Tabla 4: Resultados predictivos del Experimento 2 (**Global Add Pool**).

Tanto el modelo GCN como en el GCNEigDecoupled han experimentado una mejora, alcanzando un 76,17 % y 80,00 % de precisión en prueba, respectivamente. De acuerdo con la hipótesis, la suma ha beneficiado la detección de toxicidad, confirmando que la mutagenicidad depende de la presencia asilada de ciertas subestructuras.

Sin embargo, el modelo de fusión temprana (GCNEig) ha reducido su capacidad con el

uso de esta capa. Estos resultados podrían explicarse si se tiene en cuenta que mezclar coordenadas geométricas y propiedades químicas en un mismo espacio latente desde la primera capa puede requerir un filtro de suavizado como **Mean Pool** para mantener la estabilidad.

Estos resultados motivan el **Experimento 3**, donde se evaluará si un filtro completamente selectivo como **Global Max Pool** logra aislar la señal de toxicidad de una mejor manera que **Global Add Pool**, ya que esta última depende también del tamaño de la molécula.

2.3. Experimento 3: Agregación por máximo (*Max Pooling*)

En este tercer experimento se utiliza una función de agrupamiento basada en el valor máximo de las características.

2.3.1. Configuración experimental

Se mantienen constantes los parámetros estructurales y espectrales de las fases anteriores, modificando exclusivamente la capa de lectura final (Tabla 5).

Hiperparámetro	Valor
Canales Ocultos (<i>Hidden Channels</i>)	64
Número de Capas Convolucionales	3
Resolución Espectral (k)	4
Tipo de Agregación (<i>Pooling</i>)	Global Max Pool

Tabla 5: Configuración de los modelos empleando agregación por máximo.

2.3.2. Justificación teórica

Al igual que la agregación por suma, la **Global Max Pool** busca evitar la posible dilución de la señal química que se puede dar con el promedio.

Mientras que la suma acumula evidencias, el máximo retiene únicamente la activación más fuerte detectada en cualquier nodo del grafo. En términos bioquímicos, esto permite a la red identificar si existe al menos una subestructura cuya toxicidad sea suficiente como para determinar la mutagenicidad de la molécula completa, sin depender del tamaño del grafo o de la presencia de otros átomos que podrían actuar como ruido.

2.3.3. Análisis de Resultados

Los resultados obtenidos mediante la agregación por máximo (**Global Max Pool**) se presentan en la Tabla 6.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Max	0	77.80 $\pm$ 2.22	74.68 $\pm$ 4.41
GCNEig	64	3	Max	4	93.83 $\pm$ 2.39	78.51 $\pm$ 4.41
GCNEigDec.	64	3	Max	4	91.84 $\pm$ 2.44	76.38 $\pm$ 5.90

Tabla 6: Resultados predictivos del Experimento 3 (**Global Max Pool**).

Si bien el **Global Max Pool** ofrece un rendimiento superior al promedio en el modelo **GCN**, no consigue alcanzar la precisión lograda mediante la suma en los modelos espectrales. Este estudio sugiere que, la identificación de la mutagenicidad se beneficia más de la acumulación de evidencias (**Add**) que de la detección de una la mayor característica (**Max**). Especialmente en el modelo **GCNEigDecoupled**, se observa una caída de casi 4 puntos porcentuales respecto a suma.

2.4. Experimento 4: Reducción de la profundidad

A partir de los resultados previos, se establecen dos caminos: los modelos **GCN** y **GCNEigDecoupled** adoptan **Global Add Pool** (al proporcionar unos mejores resultados y confirmando que la suma favorece la detección de la toxicidad), mientras que **GCNEig** mantiene **Global Mean Pool**.

Este experimento evalúa el impacto de la profundidad de la red, reduciendo la arquitectura de 3 a 2 capas convolucionales.

2.4.1. Configuración experimental

Las redes se ajustan para cada modelo, tal como se especifica en la Tabla 7.

2.4.2. Justificación teórica

La decisión de aplicar una arquitectura de 2 capas corresponde a las limitaciones propias de las GNNs. Al operar sobre moléculas de pequeña escala como las del dataset **MUTAG**, si una red es demasiado profunda respecto al diámetro del grafo puede sufrir un fenómeno conocido como *oversmoothing* (sobre-suavizado). Al ejecutar múltiples

Modelo	Capas	Agregación (<i>Pooling</i>)	k
GCN	2	Global Add Pool	0
GCNEig	2	Global Mean Pool	4
GCNEigDecoupled	2	Global Add Pool	4

Nota: Todos los modelos mantienen una salida latente de 64 dimensiones.

Tabla 7: Configuración de los modelos adaptada a 2 capas de profundidad.

saltos de propagación, la información de todos los nodos termina mezclándose de forma redundante, haciendo que sus representaciones latentes converjan hacia un mismo vector e impidiendo a la red distinguir las partes de la molécula. Reducir la profundidad busca evitar que se diluya la información y facilitar entonces el aprendizaje.

2.4.3. Ajustes de arquitectura

Las arquitecturas se han modificado eliminando la capa intermedia `conv2` del diseño original. En el caso del modelo `GCNEigDecoupled`, la rama convolucional (`conv1`) comprime la química a 32 dimensiones, y la rama lineal (`lin2`) proyecta la geometría a otras 32. Ambas se concatenan directamente formando un tensor de 64 dimensiones que alimenta a la capa final `conv2`, logrando así que tanto la química como la posición espacial sean igual de relevantes.

2.4.4. Análisis de resultados

Los resultados obtenidos tras reducir la profundidad de las redes a 2 capas se detallan en la Tabla 8.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	2	Add	0	80.78 $\pm$ 1.99	74.89 $\pm$ 4.83
GCNEig	64	2	Mean	4	89.93 $\pm$ 2.16	77.45 $\pm$ 4.87
GCNEigDec.	64	2	Add	4	87.52 $\pm$ 2.48	77.87 $\pm$ 4.87

Tabla 8: Resultados predictivos del Experimento 4 (Reducción a 2 capas).

Se han obtenido peores resultados en el *test accuracy* para todos los modelos en comparación con sus versiones de 3 capas. El modelo `GCNEig` desciende de un 80,21 % a un 77,45 %, y el `GCNEigDecoupled` cae del 80,00 % al 77,87 %, contradiciendo la hipótesis de la mitigación del *oversmoothing*.

Pasar a 4 capas supone que la información viaje más veces por la red, lo que puede provocar que la información se propague de un extremo de la molécula al otro y vuelva, implicando que todos los nodos empiecen a recibir la misma información repetida del resto de nodos y sus vectores se vuelvan idénticos. Por tanto, se concluye que la profundidad de 3 capas es el punto óptimo de equilibrio para este dataset.

Tras reestablecer la profundidad de 3 capas como estándar, el **Experimento 5** se enfocará en la capacidad de memoria de la red, evaluando cómo afecta la variación de la dimensión oculta (*Hidden Dimensions*) de 32 a 128 canales.

2.5. Experimento 5: Optimización de los *Hidden Channels*

Tras consolidar la profundidad de 3 capas y las funciones de *pooling* óptimas, este experimento aborda la capacidad de representación de los modelos mediante el ajuste de la dimensión oculta (*hidden channels*). El objetivo es tanto dotar de mayor expresividad al modelo GCN como regularizar las variantes espectrales.

2.5.1. Justificación

La mejor versión de cada modelo se muestra a continuación en la Tabla 9 junto a sus métricas obtenidas.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Add	0	79.71 $\pm$ 1.99	76.17 $\pm$ 5.19
GCNEig	64	3	Mean	4	92.62 $\pm$ 2.12	80.21 $\pm$ 5.94
GCNEigDec.	64	3	Add	4	86.60 $\pm$ 3.21	80.00 $\pm$ 4.58

Tabla 9: Mejores resultados hasta el experimento 4.

Si se analiza la Tabla 9 se puede observar lo siguiente:

- **GCN:** La brecha entre entrenamiento ($\sim 79\%$) y prueba ($\sim 76\%$) sugiere que el modelo tiene margen para capturar patrones más complejos por lo que en este experimento se incrementa la dimensión a **128 canales** para potenciar su capacidad de extracción de características.
- **GCNEig y GCNEigDecoupled:** Se observa un marcado *overfitting* (precisión en entrenamiento $>90\%$ frente a un $\sim 80\%$ en prueba). Se propone ahora reducir la dimensión a **32 canales**, actuando como una técnica de regularización que obligue a la red a comprimir la información y generalizar mejor.

2.5.2. Análisis de Resultados

Los resultados de este ajuste dimensional se presentan en la Tabla 10.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	128	3	Add	0	80.63 $\pm$ 1.46	77.23 $\pm$ 4.26
GCNEig	32	3	Mean	4	91.42 $\pm$ 2.33	80.64 $\pm$ 3.08
GCNEigDec.	32	3	Add	4	86.52 $\pm$ 2.14	79.57 $\pm$ 3.71

Tabla 10: Resultados tras ajustar la dimensionalidad oculta (Experimento 5).

El ajuste de la capacidad latente ha resultado ser una técnica efectiva:

Al subir a 128 canales, el modelo mejora su precisión en prueba hasta el 77,23 % y reduce su variabilidad, confirmando que la red requería un mayor número de parámetros para procesar la información.

La reducción a 32 canales en GCNEig no solo mantiene el rendimiento en la barrera del 80 %, sino que logra la **desviación estándar más baja** registrada hasta el momento (3,08). Esto valida la hipótesis de que una red más simple en términos de canales es más robusta y menos sensible al ruido.

Aunque ligeramente por debajo en cuanto a precisión con un 79,57 % en el conjunto de validación, GCNEigDecoupled mantiene sus resultados al reducir bastante la desviación estándar, de 4.58 a 3.71. Mantemos esta la mejor configuración de este modelo hasta el momento ya que tiene una estructura más sencilla con 32 canales totales, donde la química y la geometría se proyectan a sub-espacios de 16 dimensiones cada uno.

Fijadas las dimensiones óptimas (128 para GCN y 32 para modelos espectrales), el **Experimento 6** concluirá la fase de MUTAG evaluando el *Positional Encoding* mediante la variación del parámetro k .

2.6. Experimento 6: *Positional Encoding*

Una vez fijadas las arquitecturas óptimas (3 capas, 32 canales ocultos y *poolings* específicos), la fase final de experimentación sobre MUTAG se centra en evaluar la cantidad de información geométrica necesaria para maximizar la capacidad predictiva. Para ello, prueban diferentes valores del hiperparámetro k (número de autovectores del Laplaciano).

2.6.1. Configuración experimental

Debido al reducido tamaño de las moléculas de MUTAG, se evalúan únicamente tres niveles de resolución geométrica:

- **$k = 2$ (Baja resolución):** Considera únicamente la información más importante.
- **$k = 4$ (Resolución media):** El estándar evaluado hasta ahora.
- **$k = 6$ (Alta resolución):** Introduce información posicional que en grafos pequeños, podría actuar como ruido.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
Resolución Baja ($k = 2$)						
GCNEig	32	3	Mean	2	89.79 $\pm$ 2.37	81.70 $\pm$ 5.96
GCNEigDec.	32	3	Add	2	83.48 $\pm$ 1.77	76.38 $\pm$ 3.36
Resolución Media ($k = 4$)						
GCNEig	32	3	Mean	4	91.42 $\pm$ 2.33	80.64 $\pm$ 3.08
GCNEigDec.	32	3	Add	4	86.52 $\pm$ 2.14	79.57 $\pm$ 3.71
Resolución Alta ($k = 6$)						
GCNEig	32	3	Mean	6	94.61 $\pm$ 3.70	76.81 $\pm$ 4.70
GCNEigDec.	32	3	Add	6	89.50 $\pm$ 2.67	79.36 $\pm$ 5.47

Tabla 11: Impacto de la resolución del *Positional Encoding* en modelos espectrales.

2.6.2. Análisis de resultados

Cambiar el valor de k muestra cómo cada modelo reacciona al ruido geométrico:

- **GCNEig (Fusión Temprana):** Consigue su mejor precisión con $k = 2$ (81,70 %), lo que indica que solo necesita una idea muy básica de la geometría. Si subimos a $k = 6$, el rendimiento cae y el modelo se sobreajusta mucho (Train: 94,61 %). Como mezcla la geometría y la química desde la primera capa, no es capaz de ignorar el ruido.
- **GCNEigDecoupled (Fusión Tardía):** Su comportamiento es el contrario. Con $k = 2$ le falta información y obtiene peores resultados (76,38 %). Sin embargo, al probar con $k = 6$, no se consigue mejorar la precisión en validación de $k = 4$ (79,57 %) y además se tiene una mayor desviación estándar, de casi 2 puntos.

2.7. Evaluación del modelo Net

Para terminar con el análisis del dataset MUTAG, y siguiendo las indicaciones del enunciado, se ha ejecutado una *run* del modelo Net utilizando la semilla de reproducibilidad 12345. El objetivo de esta prueba es tener una referencia de un modelo que debería a priori dar mejores clasificaciones y comprobar cómo de lejos (o de cerca) estamos de estos resultados.

2.7.1. Configuración del modelo

Este modelo incorpora una técnica de agrupamiento más avanzada (MinCut Pool) y se configuró con los siguientes hiperparámetros:

- **Canales Ocultos (*Hidden Dim*):** 32
- **Número de Capas:** 2
- **Pooling:** MinCut Pool
- **Resolución Espectral (k):** 10

2.7.2. Análisis de resultados

Al ejecutar el modelo con la semilla indicada, se han obtenido los siguientes resultados:

- **Precisión en Entrenamiento (Train Accuracy):** 85,82 %
- **Precisión en Prueba (Test Accuracy):** 87,23 %

Este 87,23 % es el mejor resultado obtenido en todo el conjunto de datos MUTAG. Nos sirve para confirmar que existe margen de mejora respecto al ~ 80 % que logramos con nuestras redes anteriores.

A diferencia de nuestros modelos (que usan capas simples y aplastan toda la información al final en un solo paso), Net utiliza una arquitectura guiada por MinCut Pool. El modelo está diseñado específicamente para ir agrupando los nodos paso a paso y cuenta con funciones de pérdida adicionales durante el entrenamiento para asegurar que esos grupos tienen sentido químico.

2.8. Conclusiones y comparación con la referencia de la tesis

Tras completar la fase de experimentación, en esta sección se resumen los hallazgos principales y se analiza el comportamiento de las arquitecturas mediante la visualización de sus espacios latentes.

En la Tabla 12 se presentan las configuraciones óptimas alcanzadas para cada tipo de red. Estas representan el equilibrio más avanzado entre capacidad de aprendizaje y generalización.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	128	3	Add	0	80.63 $\pm$ 1.46	77.23 $\pm$ 4.26
GCNEig	32	3	Mean	2	89.79 $\pm$ 2.37	81.70 $\pm$ 5.96
GCNEigDec.	32	3	Add	4	86.52 $\pm$ 2.14	79.57 $\pm$ 3.71

Tabla 12: Comparativa de los mejores modelos por arquitectura para el dataset MUTAG.

Justificación de la selección: Para el modelo con información espectral GCNEig, se ha seleccionado la versión con $k = 2$. Aunque en el experimento con $k = 4$ se obtuvo más estabilidad al tener una desviación típica menor, se optó por coger el que tenía mayor *accuracy*. Por tanto, el modelo con $k = 2$ se considera superior. Como se comenta, también se podrían escoger los resultados para $k = 4$ que son estables y robustos frente a diferentes inicializaciones, manteniendo una precisión sólida por encima del 80 %.

2.8.1. Análisis Visual del Espacio Latente (t-SNE)

Para validar la calidad de estas representaciones, se ha proyectado el espacio latente de la última capa de cada modelo mediante el algoritmo t-SNE (Figura 2). Destacar que para los modelos con geometría se ha utilizado $k=4$.

De la Figura 2 podemos extraer la siguiente información:

- **GCN (Izquierda):** La distribución de las moléculas mutagénicas y no mutagénicas aparece muy mezclada. La falta de información geométrica impide a la red crear una frontera de decisión clara, lo que explica por qué este modelo tiene el rendimiento más bajo.
- **GCNEig (Centro):** Se observa una mejor agrupación de las clases, especialmente en las zonas periféricas. Añadir la geometría permite que la red identifique patrones estructurales, aunque todavía existe solapamiento en la región central del gráfico.




Figura 2: Evolución del Espacio Latente *t*-SNE para los tres mejores modelos.

- **GCNEigDecoupled (Derecha):** Es la representación más limpia y polarizada. Las clases están mejor separadas en el espacio, lo que demuestra que procesar la química y la geometría de forma desacoplada permite a la red generar características mucho más discriminativas y precisas.

2.8.2. Conclusión final y comparación con la tesis

Como conclusión general, en MUTAG hemos visto que la molécula es tan importante como su composición química. Mientras que una red convencional (GCN) se ve limitada, la incorporación de autovectores del Laplaciano permite superar la barrera del 80 % de precisión.

Por último, la arquitectura GatedGCN combinada con el método de codificación posicional profundo propuesto en la tesis da un *accuracy* en validación de $87.80\% \pm 2.78$ del cual nos quedamos muy cerca con la run del modelo **Net** (87,23 %) aunque algo más lejos con nuestras arquitecturas. Siendo nuestro mejor resultado la GCNEig de 32 canales ocultos con 3 capas, global mean pool y $k = 2$ que nos da 81.70 ± 5.96 , nos quedamos a menos de 6 puntos porcentuales de la referencia.

3. ENZYMES

El conjunto de datos **ENZYMES** es otro referente clásico en la literatura de aprendizaje automático sobre grafos, perteneciente a la colección TUDataset. Este conjunto contiene representaciones de estructuras terciarias de proteínas correspondientes a enzimas, extraídas de la base de datos BRENDA. El objetivo de la tarea es realizar una clasificación

multiclase para predecir a cuál de las 6 clases principales del sistema de la Comisión de Enzimas (EC, por sus siglas en inglés) pertenece cada molécula.

A diferencia de otros conjuntos de datos moleculares que suelen presentar desequilibrios, ENZYMES destaca por su simetría. A continuación se detallan sus características principales:

- **Número total de grafos:** 600.
- **Número de características de nodo:** 3.
- **Número de clases:** 6 (clasificación multiclase).
- **Distribución de clases:** Perfectamente equilibrada, contando con exactamente 100 muestras para cada una de las 6 clases (Clase 0 a Clase 5).
- **Estadísticas de tamaño por molécula:**
 - **Media de nodos:** 32.63.
 - **Mínimo de nodos:** 2.
 - **Máximo de nodos:** 126.

Al inspeccionar el primer objeto de grafo del conjunto de datos, podemos ver que cuenta con **37 nodos (con vectores de características de 3 dimensiones)** y **168 aristas** (lo que resulta en un grado promedio de nodo de 4.54). También cuenta con exactamente **una etiqueta de grafo** ($y = [1]$).

El análisis topológico de este primer grafo (`Data(edge_index=[2, 168], x=[37, 3], y=[1])`) muestra propiedades estructurales importantes que nos ayudan a entender la naturaleza de los datos:

- **Naturaleza de las conexiones:** Es un grafo no dirigido (`Is undirected: True`), lo que significa que las relaciones espaciales o estructurales entre los elementos son bidireccionales.
- **Conectividad:** La estructura no presenta nodos aislados (`Has isolated nodes: False`), asegurando que todos los elementos forman parte de la topología principal del grafo.
- **Bucles:** No existen conexiones de un nodo consigo mismo (`Has self-loops: False`).

A continuación, en la Figura 3 se muestra un ejemplo de molécula para cada una de las seis clases disponibles en el conjunto.




Figura 3: Moléculas de las seis diferentes clases del conjunto de ENZYMES.

3.1. Experimento 1: Evaluación de Arquitecturas Base

Comenzamos el análisis del *dataset* ENZYMES estableciendo las líneas base. Al igual que en el caso anterior, el objetivo es realizar una clasificación de las moléculas, en este caso en 6 clases.

3.1.1. Configuración experimental

En este primer experimento se utilizará la configuración que se detalla en la Tabla 13. Se trata de las versiones predeterminadas del *notebook*, que comprobaremos cómo se

comportan a la hora de clasificar ENZYMES.

Hiperparámetro	Valor
Canales Ocultos (<i>Hidden Channels</i>)	64
Número de Capas Convolucionales	3
Resolución Espectral (k)	4
Tipo de Agregación (<i>Pooling</i>)	Global Mean Pool

Tabla 13: Configuración inicial de los modelos para ENZYMES.

3.1.2. Descripción de las arquitecturas

Las arquitecturas se han adaptado a la dimensionalidad de este nuevo problema:

1. **GCN (Control):** Su primera capa (`conv1`) recibe **3 dimensiones**, correspondientes a las características bioquímicas de los nodos en ENZYMES. Tras 3 capas de 64 canales, finaliza en una capa lineal que emite una predicción sobre **6 clases posibles** e ignora completamente la geometría global del grafo.
2. **GCNEig (Fusión Temprana):** Añade la codificación espectral desde el inicio y su entrada se amplía a **7 dimensiones** (3 bioquímicas + 4 espaciales). La red procesa simultáneamente las características del nodo y su posición global en la estructura desde el primer salto de mensaje.
3. **GCNEigDecoupled (Fusión Tardía):** Analiza las características iniciales en la rama convolucional (entrada de 3 dimensiones) y la geometría espacial en una proyección lineal independiente (`lin2` proyecta los 4 autovectores a 32 canales). Ambas señales se concatenan en la profundidad de la red (`conv3`) antes de emitir la clasificación en 6 salidas.

3.1.3. Análisis de resultados

Tras la evaluación de esta configuración base, se obtuvieron las métricas detalladas en la Tabla 14.

Al observar las métricas, destaca una gran caída en la precisión respecto al dataset MUTAG (donde rondábamos el 80 %). Esto se debe a la naturaleza de ENZYMES: es un problema mucho más complejo de clasificación multiclase (6 tipos de enzimas), donde

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Mean	0	25.49 $\pm$ 2.18	26.80 $\pm$ 3.69
GCNEig	64	3	Mean	4	31.85 $\pm$ 4.46	25.20 $\pm$ 3.92
GCNEigDecoupled	64	3	Mean	4	27.51 $\pm$ 3.06	24.27 $\pm$ 4.13

Tabla 14: Resultados predictivos del Experimento 1 en ENZYMES.

una elección aleatoria daría un $\sim 16,6\%$ de precisión. Nuestros modelos superan este umbral aleatorio (alcanzando un $\sim 26\%$), lo que demuestra que están aprendiendo, pero se enfrentan a un desafío complicado.

Del análisis comparativo extraemos dos conclusiones clave:

1. Sorprendentemente, el modelo **GCN** obtiene el mejor resultado en validación (26,80 %), superando a las variantes espectrales.
2. El modelo **GCNEig** logra casi un 32 % en entrenamiento, pero cae al 25,20 % en validación. Esto indica que al usar **Global Mean Pool**, añadir autovectores en proteínas complejas está generando un “ruido” que la red memoriza, pero que no le sirve para generalizar en datos nuevos.

Al igual que ocurrió en las etapas iniciales de MUTAG, sospechamos que hacer un promedio (**Mean Pool**) de todos los nodos de una proteína destruye la información de las regiones activas. Esto justifica avanzar al **Experimento 2**, donde cambiaremos la función de agregación a para ver si se pueden mejorar los resultados.

3.2. Experimento 2: Impacto de Global Max Pool

En este experimento decidimos variar sobre la *readout layer* tras observar el bajo rendimiento con el promedio (**Mean Pool**).

3.2.1. Justificación Teórica

La estructura de las moléculas en el dataset ENZYMES presenta grafos notablemente más grandes que las moléculas pequeñas de MUTAG. Utilizar un promedio tiende a diluir las características locales, mientras que aplicar una suma haría que el vector final dependiera demasiado del tamaño de la proteína. Por ello, se plantea el uso de *Global Max Pool* como un detector de características relevantes. En teoría de grafos aplicada a la bioquímica, esta agregación permite capturar las activaciones más altas de la red,

las cuales suelen corresponderse con las regiones activas sin importar el tamaño total del resto de la estructura de la proteína.

3.2.2. Análisis de Resultados

Las métricas obtenidas con esta configuración se detallan en la Tabla 15.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Max	0	28.27 ± 1.83	26.73 ± 2.12
GCNEig	64	3	Max	4	37.73 ± 3.68	28.73 ± 4.38
GCNEigDec.	64	3	Max	4	39.56 ± 3.16	29.27 ± 3.62

Tabla 15: Resultados predictivos del Experimento 2 (*Max Pool*) en ENZYMES.

El cambio de agregación ha tenido un impacto positivo evidente. La extracción de características máximas permite a los modelos espectrales superar al modelo base (GCN):

- El modelo GCNEigDecoupled se posiciona como el mejor, alcanzando un 29,27 % en validación. La separación de la química y la geometría resulta vital para no difuminar las señales clave de las proteínas complejas.
- Sin embargo, surge un problema de *overfitting*. Las precisiones en entrenamiento para los modelos espectrales se disparan casi al 40 %, mientras que en prueba no logran pasar del 29 %. La red está memorizando los grafos de entrenamiento, pero le cuesta generalizar.

Esta diferencia entre *Train* y *Test* podría indicarnos que estamos ante un caso de *overfitting*. Sin embargo, al tratarse de macromoléculas con 6 clases enzimáticas posibles, una dimensión de 64 canales podría resultar insuficiente para clasificar correctamente las moléculas, forzando a la red a “memorizar” el conjunto de entrenamiento ya que podría ser incapaz de captar la información necesaria. Esto motiva el **Experimento 3**, donde alteraremos la capacidad de representación (*Hidden Channels*), evaluando dimensiones superiores (128 canales) para dotar al modelo de la expresividad computacional necesaria, y dimensiones inferiores (32 canales) como medida de regularización.

3.3. Experimento 3: *Hidden Channels*

Para resolver el posible sobreajuste y mejorar la clasificación con respecto al experimento anterior, procedemos a evaluar cómo afecta la variación de los *hidden channels* de

32 a 128 en nuestra arquitectura. Sería conveniente quizá probar alguna dimensión mayor pero por limitación de recursos computacionales no ha sido posible.

3.3.1. Justificación Teórica

La clasificación en 6 clases diferentes con grafos de gran tamaño eleva la complejidad del problema. El sobreajuste observado en el experimento anterior nos plantea que 64 canales puedan dar demasiada libertad al modelo, permitiéndole memorizar los datos de entrenamiento. Sin embargo, también cabe la posibilidad de que la red esté memorizando precisamente porque el espacio latente es demasiado pequeño para trazar fronteras de decisión tan complejas, obligándola a aprender el camino fácil. Evaluar los extremos de 32 y 128 canales nos permite comprobar si el problema requiere una regularización o si, por el contrario, demanda una mayor capacidad de memoria.

3.3.2. Análisis de Resultados

Las métricas comparativas para las dimensiones ocultas de 32 y 128 canales se presentan en la Tabla 16.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
32 canales						
GCN	32	3	Max	0	29.88 $\pm$ 4.38	25.47 $\pm$ 2.95
GCNEig	32	3	Max	4	36.16 $\pm$ 3.22	25.93 $\pm$ 5.04
GCNEigDec.	32	3	Max	4	34.49 $\pm$ 1.66	29.00 $\pm$ 1.69
128 canales						
GCN	128	3	Max	0	28.31 $\pm$ 1.73	25.53 $\pm$ 3.58
GCNEig	128	3	Max	4	39.22 $\pm$ 2.35	28.93 $\pm$ 4.08
GCNEigDec.	128	3	Max	4	43.49 $\pm$ 1.84	31.07 $\pm$ 3.57

Tabla 16: Impacto de la dimensionalidad oculta en el rendimiento para ENZYMES.

Los resultados confirman que la clasificación de las 6 enzimas es un problema de alta complejidad computacional que requiere una mayor dimensión del espacio latente.

Cabe destacar que aunque el modelo GCNEigDecoupled con 32 canales se queda corto en capacidad predictiva (29,00 %), logra la varianza más baja de todo el experimento ($\pm 1,69$). Sin embargo, al aumentar la memoria de la red a 128 canales, el modelo GCNEigDecoupled experimenta un salto de calidad, rompiendo por primera vez la barrera del 30 % y alcanzando un **31,07 %** en validación (con un 43,49 % en entrenamiento). Esto

demuestra que las proteínas necesitan un espacio latente mucho más amplio para que la red pueda clasificar entre las 6 clases.

A diferencia de las redes con geometría, dotar al modelo base de la GCN de 128 canales no mejora prácticamente su precisión en validación, manteniéndose en un $\sim 25,5\%$. Esto nos dice que si la red no tiene la información de la estructura de la molécula, añadirle más parámetros matemáticos no ayuda, siendo la limitación de información y no de memoria.

Consideramos a partir de ahora 128 canales para los 3 modelos. Entendemos que la profundidad de 3 capas de la red es adecuada para propagar la señal en grafos de este tamaño. El **Experimento 4** se centrará exclusivamente en aumentar la resolución espacial, incrementando el número de autovectores del Laplaciano ($k \in \{6, 8, 10\}$).

3.4. Experimento 4: *Positional Encoding* (k)

Para finalizar la optimización de las arquitecturas, procedemos a evaluar cómo afecta el aumento de la resolución espacial mediante la variación del número de autovectores del Laplaciano (k). Incrementamos el parámetro a $k = 6$, $k = 8$ y $k = 10$ para comprobar si proporcionar un mayor contexto estructural ayuda a la red a clasificar mejor las moléculas.

3.4.1. Justificación Teórica

Los autovectores del Laplaciano funcionan como frecuencias espaciales del grafo, donde los primeros valores describen la forma global y los valores más altos capturan los detalles locales más finos. Al tratar con proteínas, que son estructuras tridimensionales enormes y complejas, una resolución de $k = 4$ podría quedarse corta. Incrementar el parámetro a $k = 6, 8, 10$ busca dotar a la red de coordenadas espaciales con mayor definición estructural. En teoría, esto debería permitir a los modelos espectrales localizar con precisión la configuración geométrica exacta de las subestructuras activas.

3.4.2. Análisis de Resultados

Las métricas obtenidas tras aumentar la resolución espectral se presentan en la Tabla 17. Se omite el modelo base GCN ya que no hace uso de este hiperparámetro.

Los resultados muestran una tendencia clara respecto al caso con mayor información geométrica. En el modelo GCNEig, aumentar k no se traduce en mejoras en validación, estancándose en torno al $27,5\%$. Al concatenar directamente más autovectores en la capa de entrada, la red asume un exceso de información que actúa como ruido. Esto provoca

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
k = 6						
GCNEig	128	3	Max	6	41.02 $\pm$ 4.52	27.40 $\pm$ 4.59
GCNEigDec.	128	3	Max	6	47.65 $\pm$ 3.05	29.93 $\pm$ 4.17
k = 8						
GCNEig	128	3	Max	8	43.65 $\pm$ 4.11	27.53 $\pm$ 3.66
GCNEigDec.	128	3	Max	8	56.31 $\pm$ 4.41	31.00 $\pm$ 3.54
k = 10						
GCNEig	128	3	Max	10	44.80 $\pm$ 4.58	27.47 $\pm$ 4.49
GCNEigDec.	128	3	Max	10	61.40 $\pm$ 3.58	30.67 $\pm$ 4.60

Tabla 17: Impacto de la alta resolución geométrica (k) en el rendimiento para ENZYMES.

que el modelo se dedique a memorizar los grafos, elevando el sobreajuste de forma notable hasta casi un 45 % en entrenamiento.

Por su parte, el modelo `GCNEigDecoupled` maneja mejor este incremento de dimensionalidad geométrica gracias a su arquitectura de vías separadas. Alcanza su mejor valor en esta serie con $k = 8$ (31,00 %), aunque sigue sin superar el 31,07 % que se obtuvo en el experimento anterior utilizando $k = 4$. Resulta especialmente llamativo el drástico aumento del sobreajuste en esta arquitectura a medida que crece k , disparándose hasta un 61,40 % de precisión en entrenamiento para $k = 10$.

Esto nos indica que proporcionar demasiados autovectores a la red termina forzando al modelo a memorizar los detalles topológicos específicos del conjunto de entrenamiento en lugar de aprender patrones generales de las moléculas. Considerando las limitaciones de recursos y el aumento en los tiempos de ejecución que supone calcular tensores más grandes, concluimos que incrementar la resolución espectral por encima de $k = 4$ añade un coste computacional innecesario que no se ve recompensado con una mejora real en la precisión de validación.

3.5. Evaluación del modelo Net

Para terminar con el análisis del dataset ENZYMES, en este caso se han ejecutado dos *runs* del modelo `Net` utilizando la semilla de reproducibilidad 12345. El objetivo de esta prueba es tener una referencia que nos muestre hasta que punto llega a clasificar el conjunto de datos un modelo a priori más avanzado, y comprobar cómo de lejos (o de cerca) estamos de estos resultados.

3.5.1. Configuración del modelo

Este modelo incorpora una técnica de agrupamiento más avanzada (`MinCut Pool`) y se configuró con los siguientes hiperparámetros, evaluando dos capacidades distintas para comprobar su tolerancia al sobreajuste:

- **Canales Ocultos (*Hidden Dim*):** 32 y 64
- **Número de Capas:** 2
- **Pooling:** `MinCut Pool`
- **Resolución Espectral (k):** 10

3.5.2. Análisis de resultados

Al ejecutar el modelo con la semilla indicada, se han obtenido los siguientes resultados:

- **Modelo con 32 canales:**
 - **Precisión en Entrenamiento (Train Accuracy):** 40,89 %
 - **Precisión en Validación (Test Accuracy):** 34,00 %
- **Modelo con 64 canales:**
 - **Precisión en Entrenamiento (Train Accuracy):** 45,78 %
 - **Precisión en Validación (Test Accuracy):** 32,00 %

Este 34,00 % (obtenido con 32 canales) es el mejor resultado en todo el conjunto de datos ENZYMES. Nos sirve para confirmar la enorme dificultad de este *dataset* y pone en valor nuestra propia arquitectura optimizada (`GCNEigDecoupled`), que logró llegar hasta un 31,07 %, quedándose a menos de tres puntos porcentuales de la referencia.

El éxito de este resultado no se debe a un único parámetro, sino a la complejidad del propio modelo `Net`. A diferencia de nuestros modelos (que usan capas simples, `Net` utiliza una arquitectura jerárquica guiada por `MinCut Pool`). Además, los resultados de la variante con 64 canales confirman de forma paralela nuestras conclusiones previas: ENZYMES es extremadamente propenso al sobreajuste. Al aumentar los parámetros, la red eleva su rendimiento en entrenamiento ($\sim 46\%$) pero empeora en validación (32 %), demostrando que incluso este modelo se ve forzado a memorizar si no se regula adecuadamente.

3.6. Conclusiones y comparación con la referencia de la tesis

Tras completar la fase de experimentación, en esta sección se resumen los hallazgos principales, se analiza el comportamiento de las arquitecturas mediante la visualización de sus espacios latentes y se compara con el modelo de referencia de la tesis.

En la Tabla 18 se presentan las mejores configuraciones alcanzadas para cada tipo de red.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Max	0	28.27 $\pm$ 1.83	26.73 $\pm$ 2.12
GCNEig	128	3	Max	4	39.22 $\pm$ 2.35	28.93 $\pm$ 4.08
GCNEigDec.	128	3	Max	4	43.49 $\pm$ 1.84	31.07 $\pm$ 3.57

Tabla 18: Comparativa de los mejores modelos por arquitectura para el dataset ENZYMES.

Justificación de la selección: Para el modelo GCN, se seleccionó la configuración con 64 canales, ya que aumentar la dimensionalidad no aportó mejoras reales y solo incrementaba el coste computacional. Para los modelos con información espectral, la configuración con 128 canales y $k = 4$ resultó ser la óptima. Aunque en el Experimento 4 se probaron resoluciones geométricas mayores ($k = 8$ o 10), estas disparaban drásticamente el sobreajuste (llegando a más de un 60 % en entrenamiento) sin traducirse en una mejora significativa en validación, por lo que $k = 4$ se mantiene como la opción más estable, eficiente y menos propensa a la memorización.

3.6.1. Análisis Visual del Espacio Latente (t-SNE)

Para validar la calidad de estas representaciones y entender la dificultad del problema multiclase, se ha proyectado el espacio latente de la última capa de cada modelo mediante el algoritmo t-SNE (Figura 4).

Al tratarse de un problema de 6 clases, es esperable no encontrar una separación binaria perfecta, pero de la Figura 4 podemos extraer la siguiente información:

- **GCN (Izquierda):** Se observa una nube de puntos altamente dispersa donde los 6 colores (clases enzimáticas) están completamente mezclados. La carencia de coordenadas espaciales impide a la red encontrar patrones consistentes, reflejando visualmente por qué el modelo sufre para superar el 26 % de precisión en validación.
- **GCNEig (Centro):** Comienza a apreciarse una ligera estructuración en el espacio. Algunos colores tienden a acercarse en pequeños grupos, pero el solapamiento global




Figura 4: Evolución del Espacio Latente *t-SNE* para los tres mejores modelos en ENZYMES.

sigue siendo enorme. Esto muestra el problema de la fusión temprana en grafos complejos: la red intenta procesar características bioquímicas y ruido geométrico en la misma capa, lo que dificulta trazar fronteras de decisión limpias.

- **GCNEigDecoupled (Derecha):** Es la representación más estructurada. Aunque sigue existiendo mezcla (lógico dado el 31,07 % de precisión), se aprecian agrupaciones locales mucho más marcadas (micro-clústeres de puntos amarillos, rosas o morados en zonas concretas). Incorporar la información geométrica en la segunda capa con la mitad de dimensión permite a la red identificar mejor las estructuras que definen a cada tipo de enzima.

3.6.2. Conclusión final y comparación con la tesis

Como conclusión general, el dataset ENZYMES ha puesto de manifiesto la enorme diferencia de complejidad entre analizar moléculas pequeñas (MUTAG) y macromoléculas biológicas. En proteínas, el problema principal es el sobreajuste. Dotar a la red de *positional encoding* y utilizar detectores de características como **max pool** es necesario para aislar las regiones activas, pero requiere una gestión cuidadosa de la capacidad de la red para que no acabe memorizando el grafo.

Finalmente, en la tesis, la arquitectura base GatedGCN combinada con el método de codificadores posicionales profundos (DPE, marcados como “Our” en las tablas) ha obtenido un $39.40\% \pm 2.80$ de *accuracy*. Si comparamos nuestro mejor modelo sin tener en cuenta el modelo Net, estamos a más de 8 puntos porcentuales, lo que nos indica que el modelo todavía tiene margen de mejora e incita a probar arquitecturas más complejas.

4. PROTEINS

El conjunto de datos PROTEINS es otro referente clásico en la literatura de aprendizaje automático sobre grafos, también perteneciente a la colección TUDataset. Este conjunto contiene representaciones de estructuras proteicas donde los nodos representan aminoácidos y las aristas indican si están espacialmente cercanos (a menos de una distancia umbral). El objetivo de la tarea es realizar una clasificación binaria para predecir si una proteína dada es una enzima o no.

A diferencia del conjunto ENZYMES, que presentaba una simetría perfecta, PROTEINS cuenta con un ligero desequilibrio entre sus clases. A continuación se detallan sus características principales:

- **Número total de grafos:** 1113.
- **Número de características de nodo:** 3.
- **Número de clases:** 2 (clasificación binaria).
- **Distribución de clases:** Ligeramente desequilibrada, contando con 663 muestras para la Clase 0 y 450 muestras para la Clase 1.
- **Estadísticas de tamaño por molécula:**
 - **Media de nodos:** 39.06
 - **Mínimo de nodos:** 4
 - **Máximo de nodos:** 620


Al inspeccionar el primer objeto de grafo del conjunto de datos, podemos ver que cuenta con **42 nodos (con vectores de características de 3 dimensiones)** y **162 aristas** (lo que resulta en un grado promedio de nodo de 3.86). También cuenta con exactamente **una etiqueta de grafo** ($y = [1]$).

Además, el análisis topológico de esta primera muestra (`Data(edge_index=[2, 162], x=[42, 3], y=[1])`) revela propiedades estructurales idénticas a las observadas en el conjunto anterior, lo que nos ayuda a entender la naturaleza de los datos:


- **Naturaleza de las conexiones:** Es un grafo no dirigido (`Is undirected: True`), lo que significa que las relaciones espaciales o estructurales entre los aminoácidos son bidireccionales.

- **Conectividad:** La estructura no presenta nodos aislados (`Has isolated nodes: False`), asegurando que todos los elementos forman parte de la topología principal del grafo.
- **Bucles:** No existen conexiones de un nodo consigo mismo (`Has self-loops: False`).


A continuación, en la Figura 5 se muestran varios ejemplos de moléculas para cada una de las dos clases disponibles en el conjunto.




(a) Clase 0 (No Enzima)




(b) Clase 1 (Enzima)




(c) Clase 0 (No Enzima)



(d) Clase 1 (Enzima)



(e) Clase 0 (No Enzima)



(f) Clase 1 (Enzima)

Figura 5: Ejemplos de estructuras proteicas de las dos clases del conjunto de *PROTEINS*.

4.1. Experimento 1: Evaluación de arquitecturas base

Comenzamos el análisis del *dataset* PROTEINS estableciendo las líneas base. Al igual que en los casos anteriores, el objetivo es evaluar el impacto de la información geométrica en la clasificación de las moléculas, que recordamos, en este conjunto se reduce a un problema binario (enzima o no enzima).

4.1.1. Configuración experimental

En este primer experimento se utilizará la configuración que se detalla en la Tabla 19. Se trata de las versiones predeterminadas del *notebook* de clasificación, con las que comprobaremos el comportamiento inicial de las redes al enfrentarse a este conjunto.

Hiperparámetro	Valor
Canales Ocultos (<i>Hidden Channels</i>)	64
Número de Capas Convolucionales	3
Resolución Espectral (k)	4
Tipo de Agregación (<i>Pooling</i>)	Global Mean Pool

Tabla 19: Configuración inicial de los modelos para PROTEINS.

4.1.2. Descripción de las arquitecturas

Las arquitecturas se han adaptado a la dimensionalidad de este nuevo problema:

1. **GCN:** Actúa como línea base. Su primera capa (`conv1`) recibe **3 dimensiones**, correspondientes a las características de los nodos. Tras 3 capas de 64 canales, finaliza en una capa lineal que emite una predicción sobre **2 clases posibles** e ignora completamente la geometría global del grafo.
2. **GCNEig (Fusión temprana):** Añade la codificación espectral desde el inicio. Su entrada se amplía a **7 dimensiones** (3 características + 4 espaciales). La red procesa simultáneamente los atributos del nodo y su posición global en la estructura desde el primer salto de mensaje.
3. **GCNEigDecoupled (Fusión tardía):** Analiza las características iniciales en la rama convolucional (entrada de 3 dimensiones) y la geometría espacial en una proyección lineal independiente (`lin2` proyecta los 4 autovectores a 32 canales). Ambas

señales se concatenan en la profundidad de la red (**conv3**) antes de emitir la clasificación binaria en la capa final.

4.1.3. Análisis de resultados

Tras la evaluación de esta configuración base, se obtuvieron las métricas detalladas en la Tabla 20.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Mean	0	68,66 $\pm$ 1,94	68.42 $\pm$ 2.74
GCNEig	64	3	Mean	4	75,54 $\pm$ 0,96	72.54 $\pm$ 2.64
GCNEigDecoupled	64	3	Mean	4	74,27 $\pm$ 1,35	71.97 $\pm$ 2.26

Tabla 20: Resultados predictivos del Experimento 1 en PROTEINS.

Al observar las métricas, notamos una recuperación significativa en los porcentajes de precisión respecto a ENZYMES. Esto es lógico, ya que al tratarse de una clasificación binaria el problema matemático se simplifica, partiendo de un umbral aleatorio del $\sim 50\%$.

Impacto positivo de la geometría: A diferencia del inicio en ENZYMES, aquí añadir autovectores del Laplaciano demuestra ser útil desde el primer momento. Tanto el modelo GCNEig (72,54 %) como el GCNEigDecoupled (71,97 %) superan con claridad a la GCN (68,42 %), logrando un incremento de unos 4 puntos porcentuales en validación.

Estabilidad inicial: Los modelos espectrales no solo mejoran la precisión absoluta, sino que mantienen desviaciones estándar bajas (en torno a $\pm 2,5$), lo que indica una buena robustez frente a diferentes inicializaciones.

A pesar de estos buenos resultados iniciales debemos considerar que estamos trabajando de nuevo con macromoléculas (proteínas de gran tamaño), existe el riesgo de que el promedio global esté diluyendo señales importantes de la estructura. Esto justifica avanzar al **Experimento 2**, donde exploraremos otras funciones de agregación para comprobar si aislando características clave podemos mejorar el rendimiento de las redes.

4.2. Experimento 2: Impacto de Global Max Pool

En este experimento decidimos variar la *readout layer* tras observar que el promedio (Mean Pool) podría estar ocultando información valiosa en las estructuras proteicas más complejas.

4.2.1. Justificación teórica

El tamaño de los grafos del *dataset* PROTEINS varía drásticamente, desde pequeñas estructuras de 4 nodos hasta moléculas de 620 nodos. Aplicar una suma (*Add Pool*) en este contexto es inviable, ya que la magnitud del vector resultante dependería casi exclusivamente del tamaño de la proteína, confundiendo a la red. Por otro lado, utilizar un promedio tiende a diluir las características locales importantes en los grafos más grandes. Por ello, se plantea el uso de *Global Max Pool*, que es invariante al tamaño y puede ser capaz de detectar características relevantes, permitiendo capturar si existe una región activa en alguna parte de la estructura.

4.2.2. Análisis de resultados

Las métricas obtenidas con esta configuración se detallan en la Tabla 21.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Max	0	73.63 $\pm$ 1.70	71.47 $\pm$ 2.30
GCNEig	64	3	Max	4	77.69 $\pm$ 1.10	72.97 $\pm$ 3.06
GCNEigDec.	64	3	Max	4	76.99 $\pm$ 1.24	72.22 $\pm$ 2.87

Tabla 21: Resultados predictivos del Experimento 2 (*Max Pool*) en PROTEINS.

- El modelo base (GCN) es el gran beneficiado de este cambio, subiendo su precisión en validación desde el 68,42 % (con *Mean Pool*) hasta 71,47 %.
- Los modelos espectrales mantienen su superioridad. El modelo GCNEig se posiciona ligeramente por encima con un 72,97 % en validación, seguido muy de cerca por el *GCNEigDecoupled* (72,22 %). La presencia de geometría sigue aportando información para clasificar correctamente estas estructuras.
- Observamos un comportamiento de aprendizaje mucho más sano que en ENZYMES. Las precisiones en entrenamiento se sitúan entre el 73 % y el 77 %, mostrando que la red aprende los patrones sin llegar a memorizar el *dataset*.

A pesar de que el modelo se muestra estable, existe una ligera diferencia de entre 4 y 5 puntos porcentuales entre *Train* y validación en las redes espectrales, lo que indica un leve *overfitting*. Al ser PROTEINS un problema de clasificación binaria (más sencillo analíticamente que las 6 clases de ENZYMES), es posible que 64 *hidden channels* impliquen que la red tenga demasiados parámetros innecesarios. Sin embargo, la extrema diferencia

en el tamaño de los grafos también podría requerir una mayor estructura. Esto motiva el **Experimento 3**, donde alteraremos la capacidad de representación (*Hidden Channels*), evaluando dimensiones inferiores (32 canales) y dimensiones superiores (128 canales) para explorar el límite de aprendizaje de la red.

4.3. Experimento 3: *Hidden Channels*

Para resolver la ligera brecha de sobreajuste observada en el experimento anterior, procedemos a evaluar cómo afecta la variación de los *hidden channels* de 32 a 128 en nuestra arquitectura. Al igual que en casos anteriores, sería conveniente quizá probar alguna dimensión mayor, pero por limitación de recursos computacionales y tiempos de entrenamiento, no ha sido posible.

4.3.1. Justificación Teórica

La clasificación binaria (enzima o no enzima) presenta una complejidad matemática menor que la clasificación multiclase vista en conjuntos anteriores. El leve sobreajuste observado con 64 canales nos plantea la posibilidad de que la red esté sobre-parametrizada. Sin embargo, la variabilidad extrema en el tamaño de las proteínas (de 4 a 620 nodos) también podría requerir una gran capacidad de memoria para entender los grafos más grandes. Evaluar los extremos de 32 y 128 canales nos permite comprobar si el problema requiere una regularización dimensional o si, por el contrario, demanda una mayor capacidad de memoria.

4.3.2. Análisis de Resultados

Las métricas comparativas para las dimensiones ocultas de 32 y 128 canales se presentan en la Tabla 22.

Los resultados confirman que, al tratarse de un problema de clasificación binaria, aumentar demasiado la capacidad de la red resulta contraproducente.

Cabe destacar que al incrementar la memoria de la red a 128 canales, los modelos espectrales experimentan un descenso generalizado en su precisión de validación, cayendo hasta un $\sim 72,0\%$. La red se vuelve demasiado grande para la tarea asignada, lo que fomenta el sobreajuste al aumentar la distancia respecto a la precisión de entrenamiento (la cual roza el $77,5\%$ en GCNEig).

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
32 canales						
GCN	32	3	Max	0	73.26 $\pm$ 1.46	72.26 $\pm$ 2.59
GCNEig	32	3	Max	4	76.86 $\pm$ 1.60	72.87 $\pm$ 3.16
GCNEigDec.	32	3	Max	4	76.45 $\pm$ 1.61	73.48 $\pm$ 2.57
128 canales						
GCN	128	3	Max	0	73.25 $\pm$ 1.71	72.33 $\pm$ 2.08
GCNEig	128	3	Max	4	77.57 $\pm$ 1.75	72.11 $\pm$ 3.51
GCNEigDec.	128	3	Max	4	76.34 $\pm$ 1.09	72.01 $\pm$ 2.93

Tabla 22: *Impacto de la dimensionalidad oculta en el rendimiento para PROTEINS.*

Por el contrario, reducir el espacio latente a 32 canales actúa como un excelente regularizador. Al asfixiar ligeramente la capacidad de la red, obligamos a los modelos a centrarse en los patrones bioquímicos esenciales en lugar de memorizar el ruido. Bajo esta configuración, el modelo **GCNEigDecoupled** experimenta un salto de calidad, alcanzando un **73,48 %** en validación, la mejor métrica registrada hasta ahora para este conjunto de datos, manteniendo además una desviación estándar muy estable ($\pm 2,57$).

Consideramos a partir de ahora 32 canales como la configuración óptima para los modelos espectrales en este problema binario. Entendemos que la profundidad de 3 capas de la red es adecuada para propagar la señal. El **Experimento 4** se centrará exclusivamente en incrementar el número de autovectores del Laplaciano ($k \in \{6, 8, 10\}$) para comprobar si proporcionar mayor información estructural ayuda a clasificar de forma definitiva estas proteínas.

4.4. Experimento 4: *Positional Encoding* (k)

Para finalizar la optimización de las arquitecturas, procedemos a evaluar cómo afecta el aumento de la resolución espacial mediante la variación del número de autovectores del Laplaciano (k). Incrementamos el parámetro a $k = 6$, $k = 8$ y $k = 10$ para comprobar si proporcionar mayor información de la estructura ayuda a la red a clasificar mejor las macromoléculas.

4.4.1. Justificación Teórica

Los autovectores del Laplaciano funcionan como frecuencias espaciales del grafo, donde los primeros valores describen la forma global y los valores más altos capturan los detalles locales más finos. Al tratar con proteínas, que son estructuras tridimensionales enormes

y complejas, una resolución de $k = 4$ podría quedarse corta. Incrementar el parámetro a $k = 6, 8, 10$ busca proporcionar a la red de coordenadas espaciales con mayor información estructural. En teoría, esto debería permitir a los modelos espectrales mejorar la localización de la configuración geométrica exacta de las subestructuras activas que determinan si una proteína actúa como enzima o no.

4.4.2. Análisis de Resultados

Las métricas obtenidas tras aumentar la resolución espectral se presentan en la Tabla 23.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
k = 6						
GCNEig	32	3	Max	6	77.29 ± 2.07	72.47 ± 2.85
GCNEigDec.	32	3	Max	6	77.23 ± 1.71	72.69 ± 2.85
k = 8						
GCNEig	32	3	Max	8	78.12 ± 1.90	73.08 ± 2.57
GCNEigDec.	32	3	Max	8	76.92 ± 2.28	71.58 ± 2.65
k = 10						
GCNEig	32	3	Max	10	78.32 ± 1.97	71.15 ± 3.44
GCNEigDec.	32	3	Max	10	78.56 ± 1.73	71.51 ± 1.85

Tabla 23: Impacto de la alta resolución geométrica (k) en el rendimiento para *PROTEINS*.

Los resultados muestran que incrementar la información geométrica no se traduce en una mejora del rendimiento general. Para el modelo **GCNEig**, aumentar $k = 8$ produce un ligero repunte en validación alcanzando un 73,08 %, pero cae de nuevo al 71,15 % cuando se utilizan 10 autovectores. Al mismo tiempo, su precisión en entrenamiento sigue una ligera tendencia al alza, rozando el 78,5 %, lo que evidencia que el modelo empieza a utilizar esta información espacial para memorizar los grafos de entrenamiento en lugar de aprender sus características.

Por otra parte, el modelo **GCNEigDecoupled** se ve claramente perjudicado por el incremento de dimensionalidad geométrica. Su precisión en validación desciende progresivamente desde el 73,48 % obtenido con $k = 4$ en el experimento anterior, hasta estancarse en torno al 71,5 % para las resoluciones más altas. Este modelo parece saturarse al proyectar un número elevado de autovectores, provocando un aumento del sobreajuste (llegando al 78,56 % en entrenamiento para $k = 10$).

Esto nos indica que, aunque la topología global ayude a clasificar correctamente los grafos, proporcionar demasiados detalles termina forzando a aprender el conjunto de en-

trenamiento. Puesto que ninguna configuración logra mejorar significativamente los resultados obtenidos para $k = 4$, sumado a las limitaciones computacionales, establecemos este como el punto óptimo de información espacial. Con esta configuración (32 canales ocultos y $k = 4$), el modelo `GCNEigDecoupled` del Experimento 3 resulta ser la mejor arquitectura y más estable encontrada para este conjunto de datos.

4.5. Evaluación del modelo Net

Para terminar con el análisis del dataset PROTEINS, en este caso se han ejecutado dos *runs* del modelo Net utilizando la semilla de reproducibilidad 12345. El objetivo de esta prueba es tener una referencia en el propio *notebook* y comprobar cómo de lejos (o de cerca) estamos de estos resultados.

4.5.1. Configuración del modelo

Este modelo incorpora una técnica de agrupamiento más avanzada (`MinCut Pool`) y aunque se pedía ejecutar una única run, se probó tanto con 32 como con 64 *hidden channels*.

- **Canales Ocultos (*Hidden Dim*):** 32 y 64
- **Número de Capas:** 2
- **Pooling:** MinCut Pool
- **Resolución Espectral (k):** 10

4.5.2. Análisis de resultados

Al ejecutar el modelo con la semilla indicada, se han obtenido los siguientes resultados:

- **Modelo con 32 canales:**
 - **Precisión en Entrenamiento (Train Accuracy):** 76,26 %
 - **Precisión en Validación (Test Accuracy):** 73,12 %
- **Modelo con 64 canales:**
 - **Precisión en Entrenamiento (Train Accuracy):** 77,22 %

• **Precisión en Validación (Test Accuracy): 74,19 %**

Este 74,19 % (obtenido con 64 canales) es el mejor resultado en todo el conjunto de datos PROTEINS. Nos sirve para confirmar el límite superior de este *dataset* y pone en gran valor la arquitectura **GCNEigDecoupled**, que conseguimos que llegara hasta un 73,48 % en el Experimento 3, quedándose a menos de un punto porcentual del modelo **Net**.

A diferencia de nuestros modelos (que usan capas simples y extraen una única característica máxima global), **Net** utiliza una arquitectura jerárquica guiada por **MinCut Pool**. Además, los resultados de la variante con 64 canales nos ofrecen un contraste muy interesante respecto a nuestras conclusiones previas. Mientras que en nuestros modelos simples un exceso de capacidad fomentaba la memorización del conjunto de entrenamiento, la arquitectura **Net** sí logra traducir el aumento de parámetros en una mejora real de validación (pasando del 73,12 % al 74,19 %).

4.6. Resultados finales y conclusiones: PROTEINS

Tras completar la fase de experimentación, en esta sección se resumen los hallazgos principales y se analiza el comportamiento de las arquitecturas mediante la visualización de sus espacios latentes.

En la Tabla 24 se presentan las mejores configuraciones alcanzadas para cada tipo de red.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	32	3	Max	0	73.26 $\pm$ 1.46	72.26 $\pm$ 2.59
GCNEig	64	3	Max	4	77.69 $\pm$ 1.10	72.97 $\pm$ 3.06
GCNEigDec.	32	3	Max	4	76.45 $\pm$ 1.61	73.48 $\pm$ 2.57

Tabla 24: Comparativa de los mejores modelos por arquitectura para el dataset PROTEINS.

Justificación de la selección: Para los modelos GCN y GCNEigDecoupled, la configuración óptima resultó ser la de 32 canales ocultos y **Global Max Pool**, mientras que para GCNEig los 64 canales ocultos le ayudaban a conseguir una décima más. Al tratarse de un problema de clasificación binaria, comprobamos en el Experimento 3 que dotar a la red de 128 canales generaba una sobre-parametrización que no mejoraba la validación. Para los modelos con información espectral, se seleccionó $k = 4$. Como vimos en el Experimento 4, incrementar la resolución espacial a $k = 8$ o 10 introducía ruido y fomentaba el sobreajuste, por lo que $k = 4$ se mantiene como la opción más estable y eficiente.

4.6.1. Análisis visual del espacio latente (t-SNE)

Para validar la calidad de estas representaciones y entender cómo los modelos separan las enzimas de las que no lo son, se ha proyectado el espacio latente de la última capa mediante el algoritmo t-SNE (Figura 6).




Figura 6: Evolución del Espacio Latente t-SNE para los tres mejores modelos en PROTEINS.

Al ser un problema de clasificación binaria, buscamos observar una polarización clara entre los puntos rojos y grises. De la Figura 6 podemos extraer la siguiente información:

- **GCN (Izquierda):** Se observa una distribución donde las dos clases están fuertemente mezcladas, especialmente en la región central y superior. Aunque hay una ligera tendencia a agrupar ciertos puntos, la falta de contexto geométrico impide trazar una frontera de decisión nítida.
- **GCNEig (Centro):** El espacio latente se muestra más disperso y fragmentado. Se empiezan a apreciar pequeñas agrupaciones locales más homogéneas, pero sigue existiendo un solapamiento considerable. Añadir la geometría desde el primer salto de mensaje añade información útil, pero también cierto ruido que dificulta una separación limpia.
- **GCNEigDecoupled (Derecha):** Es la representación que muestra una mejor estructuración. Se distinguen clústeres mucho más puros (por ejemplo, concentraciones claras de puntos rojos en los extremos superior derecho e inferior, separados de los grises).

4.6.2. Comparación con la tesis de referencia

El modelo ganador absoluto en este conjunto de datos es el **GCNEigDecoupled con 32 canales y $k = 4$** , logrando una precisión en validación del **73,48 %** y demostrando una gran estabilidad ($\pm 2,57$). Si comparamos el resultado obtenido con el de la tesis notamos que para este conjunto de datos no estamos nada lejos de la referencia, donde se obtuvo un $76,14 \pm 1,80$ utilizando la arquitectura base GatedGCN combinada con el método propuesto en la tesis, lo que nos sitúa a menos de 3 puntos porcentuales, poniendo en valor la arquitectura desarrollada en esta práctica.

5. IMDB-BINARY

El conjunto de datos IMDB-BINARY es otro referente clásico en la literatura de aprendizaje automático sobre grafos, perteneciente a la colección TUDataset. A diferencia de los conjuntos bioquímicos anteriores, este contiene representaciones de redes sociales de actores extraídas de IMDb. Los nodos representan actores o actrices y las aristas indican si han aparecido juntos en una misma película. El objetivo de la tarea es realizar una clasificación binaria para predecir el género cinematográfico del que se extrajo el grafo (acción frente a romance).

El cambio respecto a los experimentos anteriores se encuentra en cómo se procesan los datos iniciales. Originalmente, este *dataset* no posee características en los nodos (*node features*). Dado que las redes neuronales de grafos requieren obligatoriamente una matriz de características de entrada x para poder operar, ha sido necesario crear estas características de forma artificial. Para ello, se ha hecho uso del módulo de transformaciones de PyTorch Geometric, cargando el conjunto con `T.OneHotDegree(max_degree=135)`. Al ser 135 el grado máximo detectado en todo el *dataset*, esta transformación dota a cada nodo de un vector de características sintéticas de 136 dimensiones (representando los grados del 0 al 135 mediante codificación *one-hot*).

A continuación se detallan sus características principales:

- **Número total de grafos:** 1000.
- **Número de características de nodo:** 136 (generadas sintéticamente mediante el grado del nodo).
- **Número de clases:** 2 (clasificación binaria).

- **Distribución de clases:** Perfectamente equilibrada, contando con exactamente 500 muestras para la Clase 0 y 500 muestras para la Clase 1.
- **Estadísticas de tamaño por red (grafo):**
 - **Media de nodos:** 19.77
 - **Mínimo de nodos:** 12
 - **Máximo de nodos:** 136

Al inspeccionar el primer objeto de grafo del conjunto de datos, podemos ver que cuenta con **20 nodos (con vectores de características artificiales de 136 dimensiones)** y **146 aristas** (lo que resulta en un grado promedio de nodo de 7.30). También cuenta con exactamente **una etiqueta de grafo** ($y = [1]$).

Además, con el análisis topológico del primer grafo (`Data(edge_index=[2, 146], x=[20, 136], y=[1], num_nodes=20)`) observamos propiedades que nos ayudan a entender la naturaleza de estas redes sociales:

- **Naturaleza de las conexiones:** Es un grafo no dirigido (`Is undirected: True`), lo que significa que la relación de haber actuado juntos es bidireccional.
- **Conectividad:** La estructura no presenta nodos aislados (`Has isolated nodes: False`), asegurando que todos forman parte de la topología principal del grafo.
- **Bucles:** No existen conexiones de un nodo consigo mismo (`Has self-loops: False`).


A continuación, en la Figura 7 se muestran varios ejemplos de las redes sociales para cada una de las dos clases disponibles en el conjunto.

5.1. Experimento 1: Evaluación de arquitecturas base


Comenzamos el análisis del *dataset* IMDB-BINARY estableciendo las líneas base. El objetivo es evaluar el comportamiento de las redes de clasificación de grafos y el impacto de la información geométrica al clasificar las mismas en género de acción o romance.

5.1.1. Configuración experimental


En este primer experimento se utilizará la configuración que se detalla en la Tabla 25. Se trata de las versiones predeterminadas del *notebook* de clasificación, adaptadas a las nuevas dimensiones del problema.




(a) Clase 0 (Género A)




(b) Clase 1 (Género B)




(c) Clase 0 (Género A)



(d) Clase 1 (Género B)



(e) Clase 0 (Género A)



(f) Clase 1 (Género B)

Figura 7: Ejemplos de las redes de actores extraídas de las dos clases del conjunto *IMDB-BINARY*.

5.1.2. Descripción de las arquitecturas

Las arquitecturas se han adaptado a la alta dimensionalidad de entrada de este conjunto:

1. **GCN:** Actúa como línea base. Su primera capa (*conv1*) recibe **136 dimensiones**, correspondientes a la codificación *one-hot* del grado de los nodos. Tras 3 capas de 64 canales, finaliza en una capa lineal que emite una predicción sobre **2 clases posibles** e ignora la topología espacial.

Hiperparámetro	Valor
Canales Ocultos (<i>Hidden Channels</i>)	64
Número de Capas Convolucionales	3
Resolución Espectral (k)	4
Tipo de Agregación (<i>Pooling</i>)	Global Mean Pool

Tabla 25: Configuración inicial de los modelos para IMDB-BINARY.

2. **GCNEig (Fusión temprana):** Inyecta la codificación espectral desde el inicio. Su entrada se amplía a **140 dimensiones** (136 sintéticas + 4 espaciales). La red procesa simultáneamente el grado del nodo y su posición global en la red social desde el primer salto.
3. **GCNEigDecoupled (Fusión tardía):** Analiza el vector de grados en la rama convolucional (entrada de 136 dimensiones) y la geometría espacial en una proyección lineal independiente (`lin2` proyecta los 4 autovectores a 32 canales). Ambas señales se concatenan en la profundidad de la red (`conv3`) antes de emitir la clasificación binaria.

5.1.3. Análisis de resultados

Tras la evaluación de esta configuración base, se obtuvieron las métricas detalladas en la Tabla 26.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Mean	0	82.51 $\pm$ 1.82	72.28 $\pm$ 3.14
GCNEig	64	3	Mean	4	88.75 $\pm$ 0.92	69.68 $\pm$ 2.39
GCNEigDecoupled	64	3	Mean	4	83.80 $\pm$ 1.30	73.68 $\pm$ 1.79

Tabla 26: Resultados predictivos del Experimento 1 en IMDB-BINARY.

Al observar las métricas, observamos que la forma de procesar la información marca una notable diferencia.

El problema de la fusión temprana: El modelo GCNEig sufre una caída de rendimiento en validación (69,68 %) respecto al modelo base GCN (72,28 %). Sin embargo, su precisión en entrenamiento se dispara casi al 89 %. Esto indica un claro caso de sobreajuste (*overfitting*): concatenar directamente 136 variables sintéticas con 4 autovectores genera un vector de entrada tan grande y ruidoso que la red memoriza los grafos en lugar de aprender patrones generales.

Superioridad de GCNEigDecoupled: Por el contrario, el modelo GCNEigDecoupled maneja esta dimensionalidad a la perfección. Al procesar los grados por un lado y la geometría por otro, logra el mejor resultado en validación (**73,68 %**) y mantiene la varianza más baja del experimento ($\pm 1,79$). Esto demuestra que la geometría es útil para clasificar este tipo de grafos pero solo si se añade con las mismas dimensiones a la red.

A pesar de que este último modelo logra buenos resultados, utilizar un promedio (**Global Mean Pool**) en una red social puede estar diluyendo la importancia de los actores centrales. Esto justifica avanzar al **Experimento 2**, donde exploraremos el uso de **Global Max Pool** para comprobar si aislar la activación más alta (el actor más influyente) mejora el rendimiento. Sumar las características podría ser útil para representar el “volumen total” de la red, ya que pueden haber diferencias según el género de la película, por ello, plantearemos también un **Experimento 3** evaluando **Global Add Pool**.

5.2. Experimento 2: Impacto de Global Max Pool

En este experimento decidimos variar la *readout layer* tras observar que el promedio (**Mean Pool**) podría estar diluyendo la importancia de los actores centrales.

5.2.1. Justificación teórica

Utilizar un promedio pondera a todos los miembros del reparto por igual, lo que puede difuminar las características de los protagonistas o actores más conectados. Por ello, se plantea el uso de *Global Max Pool*.

5.2.2. Análisis de resultados

Las métricas obtenidas con esta configuración se detallan en la Tabla 27.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Max	0	82.60 $\pm$ 1.74	72.88 $\pm$ 2.17
GCNEig	64	3	Max	4	88.12 $\pm$ 1.72	70.80 $\pm$ 2.64
GCNEigDec.	64	3	Max	4	85.37 $\pm$ 0.98	72.52 $\pm$ 2.33

Tabla 27: Resultados predictivos del Experimento 2 (*Max Pool*) en IMDB-BINARY.

Al analizar las métricas, observamos que aislar las características máximas produce resultados mixtos dependiendo de la arquitectura:

- El modelo base (GCN) y el modelo de fusión temprana (GCNEig) experimentan una ligera mejoría en validación respecto al experimento anterior (alcanzando 72,88 % y 70,80 % respectivamente).
- Sin embargo, el modelo GCNEigDecoupled, que era nuestro claro ganador con Mean Pool (73,68 %), sufre un retroceso al bajar su precisión en validación al 72,52 %. Para esta arquitectura, ignorar la información del resto del reparto y quedarse solo con el rasgo máximo empobrece las predicciones.
- El problema más crítico sigue siendo el severo *overfitting*. Todos los modelos presentan diferencias de entre 10 y 17 puntos porcentuales entre la precisión de entrenamiento y la de validación. La red está memorizando estructuras específicas de los actores en lugar de generalizar los patrones del género de la película.

Considerando el contexto cinematográfico, es muy probable que las películas de acción y las de romance difieran en el volumen total de su reparto. Esto motiva el **Experimento 3**, donde evaluaremos Global Add Pool. Al sumar todas las características, esperamos que la red capture el “volumen total” y la densidad de las conexiones, ayudando a discriminar el género de la película.

5.3. Experimento 3: Impacto de Global Add Pool

Tras probar el promedio (Mean Pool) y el máximo (Max Pool) y no lograr reducir el sobreajuste que sufre la red, en este experimento buscamos comprobar si el “volumen total” de la red aporta información valiosa.

5.3.1. Justificación teórica

En el ámbito cinematográfico, sumar las características de todos los nodos proporciona a la red una estimación de cómo de conectada y grande es la red del actor principal, lo cual podría ser un factor discriminativo clave entre una película de acción (quizás con grupos más interconectados) y una de romance.

5.3.2. Análisis de resultados

Las métricas obtenidas con esta configuración se detallan en la Tabla 28.

Al analizar las métricas, observamos que sumar las características, en general no parece ser mejor que el promedio, aunque proporciona resultados interesantes:

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Add	0	83.13 $\pm$ 2.16	72.92 $\pm$ 2.32
GCNEig	64	3	Add	4	88.79 $\pm$ 1.82	69.52 $\pm$ 3.03
GCNEigDec.	64	3	Add	4	84.95 $\pm$ 1.12	73.20 $\pm$ 2.60

Tabla 28: Resultados predictivos del Experimento 3 (Add Pool) en IMDB-BINARY.

- El modelo base (GCN) mejora ligeramente respecto a los experimentos anteriores, alcanzando un 72,92 % en validación. Sumar el grado de los nodos parece ayudar a la red ciega a estimar mejor el tamaño del grafo.
- El modelo de fusión temprana (GCNEig) sigue colapsando (69,52 %). Con casi un 89 % en entrenamiento, se observa un gran *overfitting*. De nuevo, concatenar directamente 136 variables sintéticas con 4 autovectores provoca que la red memorice los grafos en lugar de aprender patrones generales.
- El modelo GCNEigDecoupled se recupera (73,20 %) frente a los resultados de Max Pool, pero no logra superar el 73,68 % que obtuvo en el Experimento 1 con Mean Pool.

A pesar de haber evaluado las tres funciones de agregación el problema del *overfitting* se mantiene. Existe una gran diferencia de entre 10 y 19 puntos porcentuales entre *train* y validación en todos los modelos. Al ser IMDB-BINARY un problema de clasificación binaria basado en características sintéticas *one-hot*, es muy probable que 64 *hidden channels* implique que la red tenga una sobre-parametrización excesiva. Esto motiva el **Experimento 4**, donde reduciremos los *hidden channels*. Cada uno de los modelos se quedará con la *readout layer* que mejor le ha funcionado, Global Add Pool para GCN, Global Max Pool para GCNEig y Global Mean Pool para GCNEigDecoupled.

5.4. Experimento 4: *Hidden Channels*

Para intentar resolver la enorme brecha de sobreajuste observada en los experimentos anteriores, procedemos a evaluar cómo afecta la reducción de la capacidad latente de la red, variando los *hidden channels* de 64 a 32. A partir de ahora, en lugar de utilizar la misma capa de agregación para todas las arquitecturas, cada modelo se ha configurado con la función *readout* que mejor rendimiento obtuvo en sus respectivas pruebas previas (Add Pool para GCN, Max Pool para GCNEig, y Mean Pool para GCNEigDecoupled).

5.4.1. Justificación Teórica

La clasificación de los grafos de IMDB-BINARY sufre de *overfitting*. Al haber generado 136 características sintéticas con *one-hot degree* para la capa de entrada, proyectarlas sobre 64 canales ocultos genera una matriz de pesos enorme. Esto plantea la posibilidad de que la red esté sobre-parametrizada, disponiendo de demasiada libertad y utilizándola para memorizar el conjunto de entrenamiento. Reducir el espacio latente a 32 canales busca regularizar a la red obligándola a comprimir la información y forzándola a extraer únicamente los patrones esenciales que definen el género cinematográfico, evitando memorizar el ruido.

5.4.2. Análisis de Resultados

Las métricas obtenidas tras reducir la capacidad de las redes a 32 canales se presentan en la Tabla 29.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
32 canales						
GCN	32	3	Add	0	84.36 $\pm$ 2.18	72.64 $\pm$ 3.33
GCNEig	32	3	Max	4	87.68 $\pm$ 1.91	71.20 $\pm$ 3.39
GCNEigDec.	32	3	Mean	4	83.02 $\pm$ 1.40	71.48 $\pm$ 2.65

Tabla 29: Impacto de la reducción de la dimensionalidad oculta en el rendimiento para IMDB-BINARY.

Los resultados demuestran que, a diferencia de otros conjuntos de datos, reducir la capacidad de representación resulta contraproducente para IMDB-BINARY.

Cabe destacar que al reducir la memoria de la red a 32 canales, todos los modelos experimentan un descenso en su precisión de validación respecto a sus mejores marcas con 64 canales. Por ejemplo, el modelo **GCNEigDecoupled** cae del 73,68% (obtenido en el Experimento 1) a un 71,48%. Además, esta regularización no logra reducir el problema principal que era el *overfitting*, sino que sigue siendo notable, con precisiones en entrenamiento entre el 83% y el 87%.

A la vista de estos resultados, descartamos la configuración de 32 dimensiones y restauramos los **64 canales ocultos** como el estándar óptimo para este conjunto de datos, manteniendo las capas de agregación personalizadas para cada modelo. Con la arquitectura base ya establecida, el **Experimento 5** se centrará exclusivamente en variar el número de autovectores del Laplaciano ($k \in \{6, 8, 10\}$) para comprobar si proporcionar un mapa

estructural de mayor resolución ayuda a superar la barrera del 73 % en validación.

5.5. Experimento 5: *Positional Encoding* (k)

Para finalizar la experimentación, y habiendo fijado el uso de 64 *hidden channels* con la capa de agregación óptima para cada modelo, procedemos a evaluar cómo afecta el aumento de la resolución espacial mediante la variación del número de autovectores del Laplaciano (k). Incrementamos el parámetro a $k = 6$, $k = 8$ y $k = 10$ para comprobar si proporcionar mayor información de la topología ayuda a la red a clasificar mejor.

5.5.1. Justificación Teórica

Los autovectores del Laplaciano funcionan como frecuencias espaciales del grafo, donde los primeros valores describen la forma global (comunidades amplias de actores) y los valores más altos capturan los detalles locales más finos (pequeños grupos de actores muy interconectados). Al tratar con redes sociales cinematográficas, una resolución de $k = 4$ nos proporciona una visión general, pero podría quedarse corta para identificar pequeñas comunidades específicas. Incrementar el parámetro a $k = 6, 8, 10$ busca dotar a la red de coordenadas espaciales con mayor densidad de información estructural. En teoría, esto debería permitir a los modelos espectrales mejorar la localización de agrupaciones específicas de actores que determinan si la red pertenece a una película de acción o de romance.

5.5.2. Análisis de Resultados

Las métricas obtenidas tras aumentar la resolución espectral se presentan en la Tabla 30. Se omite el modelo base GCN ya que no hace uso de este hiperparámetro.

Los resultados muestran que incrementar la información geométrica en este conjunto de datos tampoco se traduce en una mejora del rendimiento general que supere nuestra línea base inicial. Para el modelo GCNEig, aumentar la resolución no estabiliza la validación, que fluctúa entre el 70 % y el 71.92 % (obtenido con $k = 8$). Al mismo tiempo, su precisión en entrenamiento sigue una clara tendencia al alza constante, con 88.57 % para $k = 10$. El modelo está utilizando la información extra para memorizar la topología exacta de las redes de entrenamiento en lugar de aprender sus características.

Por otra parte, el modelo GCNEigDecoupled maneja mejor la alta resolución geométrica, alcanzando un pico de 73.24 % en validación con $k = 8$. Sin embargo, este resultado

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
k = 6						
GCNEig	64	3	Max	6	87.81 $\pm$ 1.67	70.72 $\pm$ 2.21
GCNEigDec.	64	3	Mean	6	83.09 $\pm$ 1.01	71.20 $\pm$ 2.55
k = 8						
GCNEig	64	3	Max	8	88.19 $\pm$ 1.58	71.92 $\pm$ 2.44
GCNEigDec.	64	3	Mean	8	84.27 $\pm$ 1.31	73.24 $\pm$ 2.70
k = 10						
GCNEig	64	3	Max	10	88.57 $\pm$ 1.52	70.68 $\pm$ 2.42
GCNEigDec.	64	3	Mean	10	85.07 $\pm$ 1.55	72.00 $\pm$ 2.94

Tabla 30: Impacto de la alta resolución geométrica (k) en el rendimiento para IMDB-BINARY.

sigue sin superar el 73.68 % que se obtuvo en el Experimento 1 utilizando $k = 4$. Además, se observa claramente cómo, al forzar la entrada a $k = 10$, el rendimiento en validación vuelve a descender (72.00 %) mientras que el sobreajuste aumenta, elevando la precisión de entrenamiento por encima del 85 %.

Esto nos indica que, aunque la topología global de la red ayude a clasificar correctamente los grafos, proporcionar demasiados detalles espaciales termina forzando al modelo a sobre-ajustarse. Puesto que ninguna configuración logra mejorar los resultados obtenidos para $k = 4$, sumado a las limitaciones computacionales y al aumento de *overfitting*, establecemos este valor como el punto óptimo de información espacial. Con esta configuración (64 canales ocultos, Global Mean Pool y $k = 4$), la arquitectura GCNEigDecoupled del Experimento 1 se confirma, de manera definitiva, como el mejor modelo de nuestras propuestas para este conjunto de datos.

5.6. Evaluación del modelo Net

Para terminar con el análisis del dataset IMDB-BINARY, en este caso se han ejecutado dos *runs* del modelo Net utilizando la semilla de reproducibilidad 12345. Veamos cómo de lejos (o de cerca) estamos de estos resultados.

5.6.1. Configuración del modelo

Este modelo incorpora una técnica de agrupamiento más avanzada (MinCut Pool) y aunque se pedía ejecutar una única run, se probó tanto con 32 como con 64 *hidden channels*, al igual que los experimentos realizados.

- **Canales Ocultos (*Hidden Dim*):** 32 y 64
- **Número de Capas:** 2
- **Pooling:** MinCut Pool
- **Resolución Espectral (k):** 10

5.6.2. Análisis de resultados

Al ejecutar el modelo con la semilla indicada, se han obtenido los siguientes resultados:

- **Modelo con 32 canales:**
 - **Precisión en Entrenamiento (Train Accuracy):** 86,53 %
 - **Precisión en Validación (Test Accuracy):** 72,80 %
- **Modelo con 64 canales:**
 - **Precisión en Entrenamiento (Train Accuracy):** 86,93 %
 - **Precisión en Validación (Test Accuracy):** 74,00 %

Este 74,00 % (obtenido con 64 canales) es el mejor resultado en todo el conjunto de datos IMDB-BINARY. Nos sirve para confirmar el límite superior de este *dataset* y pone en enorme valor la arquitectura GCNEigDecoupled, que conseguimos que llegara hasta un 73,68 % en el Experimento 1, quedándose a apenas unas décimas del modelo **Net**.

Los resultados respaldan nuestras conclusiones previas. Por un lado, confirman que reducir la capacidad a 32 canales penaliza el rendimiento (bajando al 72,80 %), validando nuestra decisión de mantener 64 canales. Por otro lado, observamos que incluso esta red con regularización sufre el mismo problema de *overfitting* que nuestras arquitecturas llegando su precisión en entrenamiento casi al 87 %. Esto demuestra de forma definitiva que la tendencia a memorizar los grafos es una dificultad de este conjunto de datos.

5.7. Conclusiones y comparación con la tesis

Tras completar la fase de experimentación, en esta sección se resumen los hallazgos principales y se analiza el comportamiento de las arquitecturas mediante la visualización de sus espacios latentes.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Add	0	83.13 ± 2.16	72.92 ± 2.32
GCNEig	64	3	Max	4	88.12 ± 1.72	70.80 ± 2.64
GCNEigDec.	64	3	Mean	4	83.80 ± 1.30	73.68 ± 1.79

Tabla 31: Comparativa de los mejores modelos por arquitectura para el dataset IMDB-BINARY.

En la Tabla 31 se presentan las mejores configuraciones alcanzadas para cada tipo de red tras evaluar todas las variables.

Justificación de la selección: A diferencia de los conjuntos anteriores, la experimentación muestra que cada arquitectura requería una función de agregación distinta para maximizar su rendimiento (**Add Pool** para la red base, **Max** para la fusión temprana y **Mean** para promediar las influencias en la red desacoplada). El número de canales se mantuvo en 64, ya que reducirlo a 32 suponía una pérdida de información al comprimir las 136 características de entrada. Finalmente, se seleccionó una resolución espacial de $k = 4$, ya que aumentar este valor solo incrementaba el *overfitting*.

5.7.1. Análisis visual del espacio latente (t-SNE)

Para validar la calidad de estas representaciones y entender cómo los modelos separan las redes de actores según el género cinematográfico, se ha proyectado el espacio latente de la última capa mediante el algoritmo t-SNE (Figura 8).




Figura 8: Evolución del Espacio Latente t-SNE para los tres mejores modelos en IMDB-BINARY.

Al ser un problema de clasificación binaria, buscamos observar una polarización clara entre los puntos rojos y grises. De la Figura 8 podemos extraer la siguiente información:

- **GCN (Izquierda):** Se observa una estructura dispersa. Aunque el modelo logra agrupar algunos puntos rojos en la parte inferior, la gran mayoría de las redes están mezcladas en la región superior derecha. La falta de contexto geométrico le impide detectar regiones locales del grafo.
- **GCNEig (Centro):** El espacio latente se muestra como una nube dispersa, aunque parecen agruparse los puntos grises en la parte inferior. Esto ilustra visualmente el problema del sobreajuste de inyectar la geometría junto con los 136 grados sintéticos en la primera capa, la red se satura de ruido y fracasa al intentar trazar una frontera de decisión (reflejado en el bajo $\sim 70,80\%$ de precisión).
- **GCNEigDecoupled (Derecha):** Muestra una representación mejor y más estructurada en forma de trayectoria curva. Las clases están notablemente mejor ordenadas y los puntos rojos tienden a polarizarse hacia los extremos de la curva, mientras que los grises dominan el codo y el brazo superior izquierdo. Procesar el grado de los actores y la topología global en vías separadas permite a la red mejorar la clasificación.

5.7.2. Conclusión final y comparación con la tesis

El modelo ganador absoluto en este conjunto de datos es el **GCNEigDecoupled con 64 canales, Mean Pool y $k = 4$** , logrando una precisión en validación del **73,68%** y la mayor estabilidad computacional del estudio ($\pm 1,79$). Este resultado está muy cerca del obtenido con en la tesis $74,12 \pm 1,72$ con la arquitectura GIN (Graph Isomorphism Network) utilizando la estrategia de codificación posicional RWPE (Random Walk Positional Encoding). Quedarnos a menos de 0.5 puntos porcentuales de la referencia en la tesis es muy sorprendente y da mucho valor a la arquitectura construida.

6. REDDIT-BINARY

El conjunto de datos REDDIT-BINARY es otro referente clásico en la literatura de aprendizaje automático sobre grafos, también perteneciente a la colección TUDataset. Este conjunto contiene representaciones de redes sociales extraídas de hilos de discusión de la plataforma Reddit. En estos grafos, los nodos representan a los usuarios y las aristas indican si uno de ellos ha respondido al comentario del otro. El objetivo de la tarea es realizar una clasificación binaria para predecir el tipo de comunidad o *subreddit* del que se extrajo

el hilo (generalmente distinguiendo entre comunidades de debate frente a comunidades de preguntas y respuestas).

El cambio con respecto a los experimentos anteriores se encuentra de nuevo en cómo se generan las características iniciales de los nodos. Originalmente, este *dataset* tampoco posee características (*node features*). Sin embargo, debido al enorme tamaño de los grafos en este conjunto (que pueden llegar a tener casi 4000 nodos), utilizar la técnica anterior (`OneHotDegree`) habría generado vectores de una dimensionalidad inasumible. Por ello, se ha optado por utilizar el módulo de transformaciones de `PyTorch Geometric` con la función `T.LocalDegreeProfile()`. Esta técnica por cada nodo calcula 5 valores estadísticos simples y eficientes sobre su vecindario local: su propio grado, y el mínimo, máximo, media y desviación estándar de los grados de todos sus vecinos.

A continuación se detallan sus características principales:

- **Número total de grafos:** 2000.
- **Número de características de nodo:** 5 (generadas sintéticamente mediante el perfil de grado local).
- **Número de clases:** 2 (clasificación binaria).
- **Distribución de clases:** Perfectamente equilibrada, contando con exactamente 1000 muestras para la Clase 0 y 1000 muestras para la Clase 1.
- **Estadísticas de tamaño por red (grafo):**
 - **Media de nodos:** 429.63
 - **Mínimo de nodos:** 6
 - **Máximo de nodos:** 3782

Al inspeccionar el primer objeto de grafo del conjunto de datos, podemos ver que cuenta con **218 nodos (con vectores de características artificiales de 5 dimensiones)** y **480 aristas** (lo que resulta en un grado promedio de nodo de 2.20). También cuenta con exactamente **una etiqueta de grafo** ($y = [1]$).

Además, el análisis topológico de esta primera muestra (`Data(edge_index=[2, 480], x=[218, 5], y=[1], num_nodes=218)`) permite observar propiedades que nos ayudan a entender la naturaleza de estas enormes redes:

- **Naturaleza de las conexiones:** Es un grafo no dirigido (`Is undirected: True`), lo que significa que la interacción entre dos usuarios en el hilo se modela de forma bidireccional.
- **Conectividad:** La estructura no presenta nodos aislados (`Has isolated nodes: False`), asegurando que todos los usuarios presentes forman parte activa de la discusión principal del grafo.
- **Bucles:** No existen conexiones de un usuario consigo mismo (`Has self-loops: False`).

A continuación, en la Figura 9 se muestra un ejemplo de las redes sociales de interacción para cada una de las dos clases disponibles en el conjunto.




Figura 9: Ejemplos de las redes de interacción de usuarios extraídas de las dos clases del conjunto REDDIT-BINARY.

6.1. Experimento 1: Evaluación de arquitecturas base

Comenzamos el análisis del *dataset* REDDIT-BINARY estableciendo las líneas base. El objetivo es evaluar el comportamiento de las redes de clasificación de grafos y el impacto de la información geométrica al clasificar grandes hilos de discusión en comunidades de debate o de preguntas y respuestas.

6.1.1. Configuración experimental

En este primer experimento se utilizará la configuración que se detalla en la Tabla 32. Se trata de las versiones predeterminadas del *notebook* de clasificación, adaptadas a las dimensiones del problema.

Hiperparámetro	Valor
Canales Ocultos (<i>Hidden Channels</i>)	64
Número de Capas Convolucionales	3
Resolución Espectral (k)	4
Tipo de Agregación (<i>Pooling</i>)	Global Mean Pool

Tabla 32: Configuración inicial de los modelos para REDDIT-BINARY.

6.1.2. Descripción de las arquitecturas

Las arquitecturas base adaptadas a la dimensionalidad del problema son las siguientes:

- **GCN:** Actúa como línea base. Su primera capa (*conv1*) recibe **5 dimensiones**, correspondientes a las estadísticas locales del grado de los nodos (*Local Degree Profile*). Tras 3 capas de 64 canales, finaliza en una capa lineal que emite una predicción sobre **2 clases posibles** y no tiene en cuenta la topología espacial.
- **GCNEig (Fusión temprana):** Añade la codificación espectral desde el inicio. Su entrada se amplía a **9 dimensiones** (5 sintéticas + 4 espaciales). La red procesa simultáneamente las estadísticas del usuario y su posición global desde el primer salto de mensaje.
- **GCNEigDecoupled (Fusión tardía):** Comienza analizando el vector de 5 estadísticas locales en la rama convolucional y la geometría espacial en una proyección lineal independiente (*lin2* proyecta los 4 autovectores a 32 canales). Ambas señales se concatenan en la profundidad de la red (*conv3*) antes de emitir la clasificación binaria.

6.1.3. Análisis de resultados

Tras la evaluación de esta configuración base, se obtuvieron las métricas detalladas en la Tabla 33.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Mean	0	80.77 $\pm$ 3.68	79.90 $\pm$ 3.84
GCNEig	64	3	Mean	4	82.07 $\pm$ 2.82	81.88 $\pm$ 3.34
GCNEigDecoupled	64	3	Mean	4	77.74 $\pm$ 3.45	77.16 $\pm$ 3.92

Tabla 33: Resultados predictivos del Experimento 1 en REDDIT-BINARY.

Al observar las métricas, destaca un comportamiento muy diferente al de los conjuntos anteriores ya que los modelos apenas presentan sobreajuste estando las precisiones en entrenamiento y validación prácticamente a la par, lo que indica un aprendizaje robusto y generalizable.

A diferencia de IMDB-BINARY, aquí el modelo **GCNEig** logra el mejor rendimiento, alcanzando casi un 82 % en validación. Al ser las características iniciales simples resúmenes estadísticos (5 valores), concatenarlas directamente con los 4 autovectores en la primera capa da una importancia similar a ambas partes desde el principio.

Sorprendentemente, **GCNEigDecoupled** se queda atrás, cayendo al 77,16 %. Esto nos sugiere que aislar las características estadísticas y procesarlas por separado durante varias capas antes de inyectar la geometría resulta contraproducente.

A pesar de estos buenos resultados iniciales, utilizar **Global Mean Pool** puede estar diluyendo la importancia de los usuarios clave. Esto justifica avanzar al **Experimento 2**, donde exploraremos el uso de **Global Max Pool** para comprobar si aislar la activación más alta mejora el rendimiento de las redes. Cabe destacar que, debido a la variabilidad y al tamaño extremo de los grafos en este conjunto (llegando hasta los casi 4000 nodos), se ha descartado por completo utilizar **Global Add Pool** ya que la magnitud del vector resultante dependería casi exclusivamente de la cantidad de mensajes del hilo y no de su estructura, lo que confundiría a la red.

6.2. Experimento 2: Impacto de Global Max Pool

En este experimento decidimos variar la *readout layer* tras plantear la hipótesis de que el promedio (**Mean Pool**) podría estar diluyendo la importancia de los usuarios clave dentro de los grandes hilos de discusión de Reddit.

6.2.1. Análisis de resultados

Las métricas obtenidas con esta configuración se detallan en la Tabla 34.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Max	0	79.45 $\pm$ 3.25	78.86 $\pm$ 4.53
GCNEig	64	3	Max	4	81.19 $\pm$ 3.63	80.74 $\pm$ 4.01
GCNEigDec.	64	3	Max	4	81.08 $\pm$ 2.43	81.32 $\pm$ 3.09

Tabla 34: Resultados predictivos del Experimento 2 (*Max Pool*) en REDDIT-BINARY.

Al analizar las métricas, observamos que utilizar `global max pool` cambia el comportamiento de las arquitecturas:

El modelo base (GCN) y el de fusión temprana (GCNEig) experimentan un ligero retroceso respecto a sus resultados con `Mean Pool`. Sin embargo, el modelo `GCNEigDecoupled` se beneficia de esta configuración. Pasa de un 77,16 % en el experimento anterior a liderar la tabla con un **81,32 %** en validación.

A nivel general, se destaca un buen comportamiento de aprendizaje. Las diferencias entre la precisión de entrenamiento y validación son prácticamente inexistentes (en el caso de `GCNEigDecoupled`, la validación incluso supera ligeramente al entrenamiento). Esto demuestra que las redes están generalizando los conceptos, sin recurrir a la memorización.

La ausencia de *overfitting* nos abre una nueva vía de investigación. Al no estar memorizando el conjunto de entrenamiento, es posible que el rendimiento esté estancado en torno al $\sim 81\%$ debido a un cuello de botella en la capacidad de representación de la red. Al tratar con estructuras tan inmensas, 64 canales ocultos podrían ser insuficientes. Esto motiva el **Experimento 3**, donde evaluaremos la variación de los *Hidden Channels*. Probaremos a expandir la capacidad a 128 canales para comprobar si una mayor memoria permite a la red descifrar patrones más complejos, y lo contrastaremos con 32 canales para descartar cualquier sobre-parametrización.

6.3. Experimento 3: *Hidden Channels*

Para intentar mejorar el techo de rendimiento alcanzado en los experimentos anteriores, procedemos a evaluar cómo afecta la variación de la capacidad latente de la red, probando con 32 y 128 *hidden channels*. A partir de ahora, cada modelo se ha configurado con la función *readout* que mejor rendimiento obtuvo en sus respectivas pruebas previas (`Mean Pool` para GCN y GCNEig, y `Max Pool` para `GCNEigDecoupled`).

6.3.1. Justificación Teórica

A diferencia de los conjuntos de datos anteriores, en REDDIT-BINARY hemos logrado un aprendizaje muy sano, sin apenas *overfitting*. Dado que la entrada de la red consta únicamente de 5 características estadísticas simples (*Local Degree Profile*), proyectarlas directamente sobre 64 canales podría suponer una sobre-parametrización innecesaria. Reducir el espacio a 32 canales nos permite comprobar si podemos lograr el mismo rendimiento con un modelo más eficiente y comprimido. Por otro lado, la evaluación de 128

canales busca el extremo opuesto: al tratar con grafos que alcanzan los casi 4000 nodos, explorar una mayor capacidad de memoria nos indicará si el rendimiento estaba estancado debido a un cuello de botella en la representación de características.

6.3.2. Análisis de Resultados

Las métricas obtenidas tras variar la capacidad de las redes se presentan en la Tabla 35.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
32 canales						
GCN	32	3	Mean	0	81.04 ± 3.44	80.52 ± 5.07
GCNEig	32	3	Mean	4	83.08 ± 3.44	77.16 ± 10.37
GCNEigDec.	32	3	Max	4	78.03 ± 1.95	77.82 ± 2.30
128 canales						
GCN	128	3	Mean	0	81.93 ± 2.13	80.84 ± 2.51
GCNEig	128	3	Mean	4	79.78 ± 8.35	79.90 ± 7.79
GCNEigDec.	128	3	Max	4	78.33 ± 1.96	78.20 ± 2.81

Tabla 35: Impacto de la dimensionalidad oculta en el rendimiento para REDDIT-BINARY.

Los resultados demuestran que alterar la capacidad resulta contraproducente para las arquitecturas con geometría en este conjunto de datos. Cabe destacar que al reducir la memoria a 32 canales, los modelos espectrales se desploman. GCNEig sufre una altísima inestabilidad, con una desviación estándar en validación que se dispara por encima de $\pm 10\%$, mientras que GCNEigDecoupled cae hasta el 77,82%.

Por otro lado, aumentar a 128 canales tampoco aporta soluciones. Aunque las precisiones de entrenamiento y validación siguen estando muy a la par (lo que confirma que seguimos sin sufrir memorización), ensanchar la red no permite superar los mejores registros obtenidos con 64 canales. Por ejemplo, el modelo GCNEigDecoupled se estanca en un 78,20%.

Descartamos por tanto ambas configuraciones y restauramos los **64 canales ocultos** como el estándar óptimo. Pensamos también que en grafos de casi 4000 nodos, utilizar solo 3 capas convolucionales puede ser insuficiente, por ello, el **Experimento 4** se centrará en explorar la profundidad de la red, evaluando el aumento del número de capas (*Num. Layers*) para comprobar si una mayor propagación del mensaje nos permite romper la barrera del 81% de precisión.

6.4. Experimento 4: Profundidad de la red (*Num. Layers*)

Tras confirmar en el experimento anterior que la red no sufría de *overfitting* y que ensanchar las capas no mejoraba el rendimiento, procedemos a evaluar el impacto de la profundidad. Para ello, se ha añadido una cuarta capa convolucional (*Num. Layers* = 4) a las tres redes. Se mantienen las configuraciones óptimas de agregación para cada modelo y se configuran los modelos espectrales con 64 canales, mientras que para el modelo base (GCN) se ha evaluado una configuración combinada de 4 capas y 128 canales.

6.4.1. Justificación Teórica

En el *dataset* REDDIT-BINARY estamos tratando con hilos de discusión muy grandes que pueden alcanzar casi los 4000 nodos. Utilizar solo 3 capas implica que un usuario solo recibe información a 3 saltos de distancia, lo cual es puede ser insuficiente para que el contexto global del hilo fluya por toda la red. Aumentar a 4 capas busca expandir este campo receptor, permitiendo una mayor propagación del mensaje.

6.4.2. Análisis de Resultados

Las métricas obtenidas tras aumentar la profundidad de las redes se presentan en la Tabla 36.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	128	4	Mean	0	78.91 $\pm$ 5.68	77.48 $\pm$ 6.13
GCNEig	64	4	Mean	4	84.61 $\pm$ 2.14	82.10 $\pm$ 2.69
GCNEigDec.	64	4	Max	4	83.18 $\pm$ 2.30	82.46 $\pm$ 3.25

Tabla 36: Impacto del aumento de profundidad (4 capas) en el rendimiento para REDDIT-BINARY.

Los resultados confirman rotundamente nuestra hipótesis:

- Los modelos con geometría experimentan un salto de calidad notable, rompiendo por fin la barrera del 81 % en validación que nos frenaba desde el Experimento 2. El modelo GCNEigDecoupled alcanza un excelente **82,46 %**, mientras que GCNEig le sigue de cerca con un 82,10 %.
- Además, el aprendizaje sigue siendo extremadamente sólido. Las precisiones de entrenamiento se mantienen controladas en torno al 83-84 %, demostrando que la red utiliza esta capa extra para generalizar mejor las estructuras, no para memorizarlas.

- Por el contrario, el modelo base GCN (configurado con 4 capas y 128 canales) sufre un colapso en su rendimiento, cayendo al 77,48% y mostrando una preocupante inestabilidad (desviación estándar de $\pm 6,13$). Es posible que haya sufrido de *oversmoothing*, al aumentar la profundidad y la anchura sin información geométrica, los vectores de todos los nodos acaban promediándose hasta volverse indistinguibles, destruyendo la capacidad predictiva de la red.

A la vista de estos excelentes resultados, establecemos las **4 capas convolucionales y 64 canales** como la estructura para nuestros modelos espectrales en este conjunto de datos. El **Experimento 5** se centrará en la capa de entrada. Procederemos a variar el número de autovectores del Laplaciano ($k \in \{6, 8, 10\}$) para comprobar si mayor resolución espacial en grafos tan inmensos ayuda a la red a perfeccionar aún más su capacidad predictiva.

6.5. Experimento 5: *Positional Encoding* (k)

Para finalizar la experimentación, y habiendo fijado la profundidad en 4 capas y 64 *hidden channels* con la capa de agregación óptima para cada modelo, procedemos a evaluar cómo afecta el aumento de la resolución espacial mediante la variación del número de autovectores del Laplaciano (k). Incrementamos el parámetro a $k = 6$, $k = 8$ y $k = 10$ para comprobar si proporcionar mayor información de la topología ayuda a la red a clasificar mejor.

6.5.1. Justificación teórica

Al tratar con hilos de Reddit que alcanzan casi los 4000 usuarios, una resolución de $k = 4$ nos proporciona una buena visión general de la estructura, pero podría quedarse corta para identificar pequeñas comunidades muy interconectadas. Incrementar el parámetro a $k = 6, 8, 10$ busca dotar a la red de coordenadas espaciales con mayor densidad de información estructural. En teoría, al haber expandido el campo receptor a 4 capas, la red ahora debería ser capaz de asimilar y propagar estas frecuencias más altas para distinguir con mayor precisión si el hilo pertenece a una comunidad de debate o a una de preguntas y respuestas.

6.5.2. Análisis de Resultados

Las métricas obtenidas tras aumentar la resolución espectral se presentan en la Tabla 37. Se omite el modelo base GCN ya que no hace uso de este hiperparámetro.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
k = 6						
GCNEig	64	4	Mean	6	82.81 $\pm$ 4.20	79.98 $\pm$ 4.83
GCNEigDec.	64	4	Max	6	84.69 $\pm$ 2.06	83.14 $\pm$ 2.38
k = 8						
GCNEig	64	4	Mean	8	84.77 $\pm$ 2.52	83.38 $\pm$ 2.82
GCNEigDec.	64	4	Max	8	82.82 $\pm$ 3.55	80.26 $\pm$ 2.69
k = 10						
GCNEig	64	4	Mean	10	79.14 $\pm$ 12.99	77.12 $\pm$ 11.47
GCNEigDec.	64	4	Max	10	84.49 $\pm$ 3.47	80.88 $\pm$ 2.48

Tabla 37: Impacto de la alta resolución geométrica (k) en el rendimiento para REDDIT-BINARY.

Para la arquitectura desacoplada (GCNEigDecoupled), el punto dulce se encuentra en $k = 6$. Con esta configuración, el modelo logra un excelente **83,14 %** en validación, manteniendo un aprendizaje sano (84,69 % en entrenamiento) y una gran estabilidad ($\pm 2,38$). Sin embargo, si aumentamos la k por encima de 6, el rendimiento decae progresivamente hacia el 80 %.

Por otra parte, el modelo de fusión temprana (GCNEig) requiere una resolución ligeramente mayor, con $k = 8$ registra un **83,38 %** en validación, marcando el récord absoluto de toda la experimentación en este *dataset*. No obstante, los datos también nos muestran el peligro de excederse con la geometría espectral: al forzar la entrada a $k = 10$, la matriz de Laplacianos introduce un ruido que hace que el modelo GCNEig colapse por completo, cayendo al 77,12 % y mostrando inestabilidad (desviación estándar superior al ± 11 %).

Tras haber logrado romper la barrera del 83 %, damos por finalizada la optimización. Seleccionamos el modelo GCNEig con $k = 8$ por lograr el máximo rendimiento bruto, y el modelo GCNEigDecoupled con $k = 6$ por ofrecer un equilibrio excepcional entre alta precisión y baja varianza como los mejores modelos.

6.6. Evaluación del modelo Net

Para terminar con el análisis del dataset REDDIT-BINARY, se han ejecutado dos *runs* del modelo Net utilizando la semilla de reproducibilidad 12345. El objetivo de esta

prueba es evaluar una arquitectura que incorpora técnicas de agrupamiento jerárquico y que, en principio, debería ofrecer un rendimiento superior al de los modelos convolucionales simples en la clasificación de grafos complejos.

6.6.1. Configuración del modelo

Este modelo incorpora una técnica de reducción de dimensionalidad espacial más avanzada (**MinCut Pool**) y, para comprobar su tolerancia y capacidad de aprendizaje, se probó tanto con 32 como con 64 *hidden channels*.

- **Canales Ocultos (*Hidden Dim*):** 32 y 64
- **Número de Capas:** 2
- **Pooling:** MinCut Pool
- **Resolución Espectral (k):** 10

6.6.2. Análisis de resultados

Al ejecutar el modelo con la semilla indicada, se han obtenido los siguientes resultados:

- **Modelo con 32 canales:**
 - **Precisión en Entrenamiento (Train Accuracy):** 77,80 %
 - **Precisión en Validación (Test Accuracy):** 72,20 %
- **Modelo con 64 canales:**
 - **Precisión en Entrenamiento (Train Accuracy):** 73,00 %
 - **Precisión en Validación (Test Accuracy):** 63,60 %

A diferencia de lo que cabría esperar de una arquitectura más compleja, los resultados obtenidos son notablemente deficientes. El mejor registro de este modelo apenas alcanza un 72,20 % (con 32 canales), lo que lo sitúa a más de 11 puntos porcentuales de distancia del **83,38 %** logrado por nuestra propia arquitectura **GCNEig** en el Experimento 5.

Además, el modelo colapsa al aumentar su capacidad a 64 canales, donde la precisión en validación se desploma hasta un pobre 63,60 %. Este contraste pone en valor el trabajo de optimización realizado en nuestros modelos. Demuestra de forma concluyente que, para

redes sociales de gran tamaño, un paso de mensajes profundo (4 capas para ampliar el campo receptor) unido a la geometría resulta ser una estrategia más robusta, estable y eficaz.

6.7. Conclusiones

Tras completar la fase de experimentación, en esta sección se resumen los hallazgos principales y se analiza el comportamiento de las arquitecturas mediante la visualización de sus espacios latentes.

En la Tabla 38 se presentan las mejores configuraciones alcanzadas para cada tipo de red tras evaluar todas las variables.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	128	3	Mean	0	81.93 ± 2.13	80.84 ± 2.51
GCNEig	64	4	Mean	8	84.77 ± 2.52	83.38 ± 2.82
GCNEigDec.	64	4	Max	6	84.69 ± 2.06	83.14 ± 2.38

Tabla 38: Comparativa de los mejores modelos por arquitectura para el dataset REDDIT-BINARY.

Justificación de la selección: A diferencia de los conjuntos bioquímicos, el enorme tamaño de estas redes sociales requirió enfoques arquitectónicos distintos. El modelo base (GCN) necesitó ensancharse a 128 canales para alcanzar su pico, mientras que los modelos espectrales requirieron aumentar la profundidad a 4 capas para propagar la señal por todo el hilo de discusión. Además, se ha visto que en grafos inmensos, incrementar la resolución espacial por encima del estándar ayuda notablemente a clasificar sub-comunidades, encontrando los puntos óptimos en $k = 8$ (fusión temprana) y $k = 6$ (arquitectura desacoplada).

6.7.1. Análisis visual del espacio latente (t-SNE)

Para validar la calidad de estas representaciones y entender cómo los modelos separan las redes según la comunidad de origen, se ha proyectado el espacio latente de la última capa mediante el algoritmo t-SNE (Figura 10). Cabe destacar que la proyección de los modelos espectrales se ha generado utilizando $k = 4$.

Al ser un problema de clasificación binaria, buscamos observar una polarización clara entre los puntos rojos y grises. De la Figura 10 podemos extraer la siguiente información:




Figura 10: *Evolución del Espacio Latente t-SNE para los modelos en REDDIT-BINARY (GCN: $k = 0$, Modelos espectrales: $k = 4$).*

- **GCN (Izquierda):** Se observa una estructura dispersa y carente de un patrón claro. Aunque el modelo logra agrupar ligeramente algunos puntos, la gran mayoría de las redes están mezcladas caóticamente en la región central y derecha.
- **GCNEig (Centro):** El espacio latente sufre una transformación radical, organizándose en una clara banda o trayectoria diagonal. Comienza a apreciarse una segregación real: los puntos rojos tienden a agruparse en la parte inferior izquierda, mientras que los grises dominan la sección superior derecha. Añadir la topología del grafo permite a la red estructurar el espacio latente con mucha más lógica.
- **GCNEigDecoupled (Derecha):** Muestra una representación aún más estructurada y limpia siguiendo la misma distribución diagonal. Las clases están notablemente mejor ordenadas: los puntos rojos se polarizan de forma muy densa en la parte superior y el extremo derecho, mientras que los grises se concentran de forma compacta en la zona central e inferior izquierda. Procesar las características locales y la geometría global en vías separadas pule las fronteras de decisión y facilita enormemente la clasificación final.

6.7.2. Conclusión final

El modelo ganador absoluto en este conjunto de datos es el **GCNEig con 64 canales, 4 capas, Mean Pool y $k = 8$** , logrando una precisión en validación del **83,38 %**, seguido muy de cerca por la arquitectura **GCNEigDecoupled (83,14 % con $k = 6$)**.

La tesis de referencia [1] no proporciona resultados para este conjunto de datos, por lo que no podemos comparar nuestros resultados de manera directa. No obstante, el fracaso

del modelo *Net*, que colapsó al 63,60 % al enfrentarse a este volumen de datos, pone de manifiesto la robustez, escalabilidad y potencia predictiva de nuestras arquitecturas.

7. COLLAB

El conjunto de datos *COLLAB* es el último analizado, perteneciente también a la colección *TUDataset*. Este conjunto contiene representaciones de redes reales de colaboración científica. En estos grafos, los nodos representan a investigadores y las aristas indican si han escrito y publicado un artículo juntos. El objetivo de la tarea es realizar una clasificación multiclase para predecir a qué subcampo de la física pertenece la red de colaboración científica (Alta Energía, Materia Condensada o Astrofísica).

El cambio en este *dataset* respecto a los anteriores está en dos aspectos del preprocesamiento: la generación de características y el balanceo del conjunto. En primer lugar, dado que el conjunto original no posee características de nodo (*node features*) y la densidad de las aristas es alta por la existencia de investigadores muy conectados, se ha vuelto a aplicar la técnica *T.LocalDegreeProfile()*. Esta transformación comprime la topología en 5 características estadísticas (el grado del autor, y el mínimo, máximo, media y desviación estándar de los grados de sus coautores).

En segundo lugar, el conjunto original constaba de 5000 grafos fuertemente desbalanceados (2600 muestras para la Clase 0, frente a solo 775 para la Clase 1). Debido a los requisitos computacionales de estas redes y para evitar el sesgo del modelo hacia la clase mayoritaria, se ha aplicado una técnica de *undersampling* aleatorio. Se han extraído exactamente 775 muestras de cada clase, generando un nuevo conjunto de datos computacionalmente viable y matemáticamente equitativo.

A continuación se detallan las características principales del conjunto de datos final (tras aplicar el submuestreo):

- **Número total de grafos:** 2325.
- **Número de características de nodo:** 5 (generadas sintéticamente mediante el perfil de grado local).
- **Número de clases:** 3 (clasificación multiclase).
- **Distribución de clases:** Perfectamente equilibrada, contando con exactamente 775 muestras para la Clase 0, 775 para la Clase 1 y 775 para la Clase 2.

- **Estadísticas de tamaño por red (grafo):**

- **Media de nodos:** 72.03
- **Mínimo de nodos:** 32
- **Máximo de nodos:** 487

Al inspeccionar el primer objeto de grafo de nuestro subconjunto, podemos ver que cuenta con **67 nodos (con vectores de características artificiales de 5 dimensiones)** y **990 aristas** (lo que resulta en un grado promedio de nodo de 14.78). También cuenta con exactamente **una etiqueta de grafo** indicando el subcampo de la física ($y = [1]$).

Además, el análisis de la topología de esta primera muestra (`Data(edge_index=[2, 990], x=[67, 5], y=[1], num_nodes=67)`) muestra propiedades que nos ayudan a entender la naturaleza de las colaboraciones científicas:

- **Naturaleza de las conexiones:** Es un grafo no dirigido (`Is undirected: True`), lo que significa que la relación de coautoría de un artículo es mutua y recíproca.
- **Conectividad:** La estructura no presenta nodos aislados (`Has isolated nodes: False`), asegurando que todos los científicos del grafo forman parte de la red de colaboración principal.
- **Bucles:** No existen conexiones de un investigador consigo mismo (`Has self-loops: False`).

A continuación, en la Figura 11 se muestran ejemplos de las redes de colaboración científica para cada una de las tres clases disponibles en el conjunto.




Figura 11: Ejemplos de las redes de colaboración científica extraídas de las tres clases del conjunto COLLAB.

7.1. Experimento 1: Evaluación de arquitecturas base

Comenzamos el análisis del *dataset* COLLAB estableciendo las líneas base. El objetivo es evaluar el comportamiento inicial de las redes de clasificación de grafos y el impacto de la información geométrica al clasificar en las tres ramas de la física disponibles (Alta Energía, Materia Condensada o Astrofísica).

7.1.1. Configuración experimental

En este primer experimento se utilizará la configuración estándar que se detalla en la Tabla 39. Se trata de las versiones predeterminadas de nuestras arquitecturas, adaptadas a las dimensiones y naturaleza de este nuevo problema.

Hiperparámetro	Valor
Canales Ocultos (<i>Hidden Channels</i>)	64
Número de Capas Convolucionales	3
Resolución Espectral (k)	4
Tipo de Agregación (<i>Pooling</i>)	Global Mean Pool

Tabla 39: Configuración inicial de los modelos para COLLAB.

7.1.2. Descripción de las arquitecturas

Las arquitecturas base adaptadas a la dimensionalidad multiclase de este conjunto son las siguientes:

- **GCN:** Actúa como línea base. Su primera capa (*conv1*) recibe **5 dimensiones**, correspondientes a las estadísticas locales del grado de los nodos (*Local Degree Profile*). Tras 3 capas de 64 canales, finaliza en una capa lineal que emite una predicción sobre **3 clases posibles** y no tiene en cuenta la topología espacial.
- **GCNEig (Fusión temprana):** Añade la codificación espectral desde el inicio. Su entrada se amplía a **9 dimensiones** (5 sintéticas + 4 espaciales). La red procesa simultáneamente las estadísticas de coautoría del investigador y su posición global en el grafo desde el primer salto de mensaje.
- **GCNEigDecoupled (Fusión tardía):** Comienza analizando el vector de 5 estadísticas locales en la rama convolucional y la geometría espacial en una proyección

lineal independiente (`lin2` proyecta los 4 autovectores a 32 canales). Ambas señales se concatenan en la profundidad de la red (`conv3`) antes de emitir la clasificación multiclase.

7.1.3. Análisis de resultados

Tras la evaluación de esta configuración base, se obtuvieron las métricas detalladas en la Tabla 40.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Mean	0	74.11 $\pm$ 1.16	73.95 $\pm$ 0.84
GCNEig	64	3	Mean	4	72.94 $\pm$ 1.47	73.98 $\pm$ 0.83
GCNEigDecoupled	64	3	Mean	4	73.76 $\pm$ 1.14	73.37 $\pm$ 1.11

Tabla 40: Resultados predictivos del Experimento 1 en COLLAB.

Al analizar las métricas, el hallazgo más destacable y positivo de este primer experimento es la ausencia de *overfitting*. A diferencia de los conjuntos de datos anteriores (como IMDB-BINARY), las precisiones de entrenamiento y validación se encuentran perfectamente alineadas (e incluso el rendimiento en validación supera ligeramente al de entrenamiento en el caso de GCNEig).

En cuanto a la comparativa de arquitecturas, los tres modelos muestran un rendimiento muy parejo, orbitando el $\sim 74\%$ de precisión. El modelo de fusión temprana (GCNEig) logra una ligera ventaja (73,98 %) frente a la línea base GCN (73,95 %), mientras que la arquitectura desacoplada cede algo de terreno (73,37 %). En esta configuración inicial, la información geométrica ($k = 4$) no supone todavía una ayuda en la clasificación.

En la investigación científica, los subcampos pueden identificarse por la presencia de investigadores principales o por el volumen total del equipo de investigación. Para detectar estas estructuras utilizaremos `Global Max Pool` y `Global Add Pool` en el **Experimento 2**.

7.2. Experimento 2: Impacto de las capas de agregación (Max y Add Pool)

En este experimento decidimos variar la *readout layer* tras plantear la hipótesis de que el promedio (`Mean Pool`) evaluado en el experimento anterior podría estar diluyendo información. Por ello, probamos `Global Max Pool` para comprobar si aislar la activa-

ción más alta mejora el rendimiento, y **Global Add Pool** para evaluar si la clasificación depende de la magnitud y volumen total del equipo de investigación.

7.2.1. Análisis de resultados

Las métricas obtenidas con ambas configuraciones se detallan en la Tabla 41.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
Global Max Pool						
GCN	64	3	Max	0	74.55 $\pm$ 1.11	73.54 $\pm$ 1.60
GCNEig	64	3	Max	4	74.71 $\pm$ 0.52	74.79 $\pm$ 1.32
GCNEigDec.	64	3	Max	4	74.25 $\pm$ 1.04	74.21 $\pm$ 1.03
Global Add Pool						
GCN	64	3	Add	0	59.21 $\pm$ 14.38	61.72 $\pm$ 11.98
GCNEig	64	3	Add	4	51.64 $\pm$ 13.15	53.87 $\pm$ 11.81
GCNEigDec.	64	3	Add	4	67.72 $\pm$ 6.23	66.37 $\pm$ 5.35

Tabla 41: Resultados predictivos del Experimento 2 (*Max y Add Pool*) en COLLAB.

Al analizar las métricas, observamos que la variación de esta capa transforma por completo el comportamiento de las redes, ofreciendo dos realidades muy distintas:

Por un lado, **Global Add Pool** resulta ser una estrategia nefasta para este *dataset*. Las precisiones caen drásticamente hasta el rango del 50-60 %, y la inestabilidad se dispara (con desviaciones estándar que superan el ± 11 %). Podría explicarse porque la red casi solo está teniendo en cuenta la cantidad de investigadores que firmaron el artículo, llegando a confundirse. Confirmamos que el tamaño del equipo no es un factor válido para la clasificación del conjunto.

Por otro lado, el éxito de **Global Max Pool**. Extraer las características máximas consolida y mejora ligeramente los resultados del experimento inicial. Todos los modelos mantienen un aprendizaje, sin rastro de *overfitting*. Destaca especialmente el modelo de fusión temprana (GCNEig), que alcanza un **74,79 %** en validación, convirtiéndose en nuestra nueva mejor marca.

La ausencia de *overfitting* observada en las arquitecturas con **Max** y **Mean Pool** nos abre una nueva vía de investigación. Al no estar memorizando el conjunto de entrenamiento, es posible que el rendimiento esté estancado rozando el 75 % debido a un límite en la capacidad de representación de la red. Esto motiva el **Experimento 3**, donde evaluaremos la variación de los *hidden channels*. Probaremos a expandir la capacidad a 128 canales para comprobar si dotar a la red de mayor memoria le permite descifrar patrones más complejos,

y lo contrastaremos con 32 canales para descartar cualquier sobre-parametrización dada la simplicidad de nuestra entrada (5 variables locales). Para estas pruebas, configuraremos cada modelo con la capa de agregación que mejor resultado ha conseguido hasta ahora (Mean Pool para GCN, y Max Pool para GCNEig y GCNEigDecoupled).

7.3. Experimento 3: *Hidden Channels*

Para intentar mejorar el rendimiento procedemos a evaluar cómo afecta la variación de la capacidad latente de la red, probando con 32 y 128 *hidden channels*. A partir de ahora, cada modelo se ha configurado con la función *readout* que mejor rendimiento obtuvo en sus respectivas pruebas previas (Mean Pool para GCN, y Max Pool para GCNEig y GCNEigDecoupled).

7.3.1. Justificación Teórica

A diferencia de los primeros conjuntos de datos estudiados, en COLLAB hemos logrado un aprendizaje sin presencia de *overfitting* y dado que la entrada de la red consta únicamente de 5 características estadísticas simples (*Local Degree Profile*), proyectarlas directamente sobre 64 canales podría suponer una sobre-parametrización innecesaria. Reducir el espacio latente a 32 canales nos permite comprobar si podemos lograr un rendimiento superior con un modelo más eficiente y comprimido y aumentar a 128 canales busca explorar si una mayor capacidad permite a la red encontrar patrones más complejos.

7.3.2. Análisis de Resultados

Las métricas obtenidas tras variar la capacidad de las redes se presentan en la Tabla 42.

Ensachar la red a 128 canales no solo no aporta soluciones, sino que empeora ligeramente las predicciones de la mayoría de los modelos respecto a sus versiones de 64 canales. Al no haber problemas de memorización, este exceso de parámetros simplemente dificulta la convergencia de los gradientes.

Por el contrario, reducir la capacidad a 32 canales resulta ser una buena decisión. Las arquitecturas espectrales alcanzan sus mejores resultados con esta combinación: el modelo GCNEig logra un **74,85 %** en validación, seguido muy de cerca por GCNEigDecoupled con un 74,62 %. Además, mantienen una estabilidad extraordinaria (desviaciones estándar

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
32 canales						
GCN	32	3	Mean	0	73.82 $\pm$ 0.62	73.85 $\pm$ 1.18
GCNEig	32	3	Max	4	74.28 $\pm$ 0.52	74.85 $\pm$ 1.03
GCNEigDec.	32	3	Max	4	73.81 $\pm$ 1.02	74.62 $\pm$ 0.95
128 canales						
GCN	128	3	Mean	0	73.76 $\pm$ 0.71	73.38 $\pm$ 0.98
GCNEig	128	3	Max	4	74.24 $\pm$ 0.73	74.38 $\pm$ 1.31
GCNEigDec.	128	3	Max	4	73.86 $\pm$ 0.83	73.38 $\pm$ 1.46

Tabla 42: Impacto de la dimensionalidad oculta en el rendimiento para COLLAB.

en torno al $\pm 1,0\%$) y las precisiones de entrenamiento siguen estando perfectamente alineadas con las de validación.

A la vista de estos resultados, establecemos los **32 canales ocultos** como el nuevo estándar para los modelos con información geométrica. Tras haber optimizado la agregación y la anchura y seguir teniendo resultados similares en train y test, es decir, sin tener apenas *overfitting*, teniendo casos incluso de mayor rendimiento en test que en train; se propone en el siguiente experimento aumentar a 4 capas para dar más capacidad a la red antes de pasar a la optimización de la resolución espectral (k).

7.4. Experimento 4: Profundidad de la red (*Num. Layers*)

Procedemos a evaluar el impacto de la profundidad arquitectónica. Para ello, se ha añadido una cuarta capa convolucional (*Num. Layers* = 4) a las tres redes. Para esta prueba se han mantenido estrictamente las configuraciones óptimas descubiertas para cada modelo hasta la fecha: 64 canales y Mean Pool para la GCN base, y 32 canales con Max Pool para las arquitecturas espectrales con geometría ($k = 4$).

7.4.1. Justificación Teórica

En el *dataset* COLLAB estamos tratando con redes de colaboración científica que, aunque tienen un tamaño moderado (media de ~ 72 nodos), presentan una alta densidad (el grado medio roza las 44 aristas por nodo). Utilizar 3 capas implica que la información ya alcanza casi toda la red en muy pocos saltos. Aumentar a 4 capas busca comprobar si un mayor campo receptor permite asimilar patrones más profundos.

7.4.2. Análisis de Resultados

Las métricas obtenidas tras aumentar la profundidad de las redes se presentan en la Tabla 43.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	4	Mean	0	73.73 $\pm$ 0.60	74.07 $\pm$ 1.36
GCNEig	32	4	Max	4	74.09 $\pm$ 0.97	74.26 $\pm$ 0.96
GCNEigDec.	32	4	Max	4	73.41 $\pm$ 1.04	75.21 $\pm$ 0.88

Tabla 43: Impacto del aumento de profundidad (4 capas) en el rendimiento para COLLAB.

Los resultados han sido exitosos y han conseguido mejorar el *accuracy*:

- El modelo GCNEigDecoupled experimenta un salto de calidad notable, rompiendo por fin la barrera del 75 % en validación. Alcanza un excelente **75,21 %** con una varianza muy baja ($\pm 0,88$).
- Por el contrario, el modelo de fusión temprana GCNEig sufre un ligero retroceso respecto a su pico del Experimento 3 (donde alcanzó un 74,85 %). Al añadir la geometría directamente en la primera capa y propagarla 4 veces en grafos tan densos, la señal estructural parece diluirse.
- El modelo base GCN se mantiene estable, rondando el 74,07 %, pero sin lograr superar sus marcas con 3 capas, lo que sugiere que para una red sin contexto geométrico, aumentar las capas no aporta nueva información discriminativa.

A la vista de estos resultados, de cara a la última fase estableceremos: **3 capas** para GCN (64 canales) y GCNEig (32 canales), mientras que GCNEigDecoupled se consolidará con **4 capas** y 32 canales.

El **Experimento 5** se centrará en el número de autovectores del Laplaciano ($k \in \{6, 8, 10\}$) para comprobar si proporcionar mayor información en redes tan densas ayuda a aumentar aún más la capacidad predictiva.

7.5. Experimento 5: *Positional Encoding* (k)

Para finalizar la experimentación, y habiendo fijado las configuraciones óptimas descubiertas para cada arquitectura espectral (32 *hidden channels* y Global Max Pool, con 3 capas para GCNEig y 4 capas para GCNEigDecoupled), procedemos a evaluar cómo afecta

el aumento de la resolución espacial mediante la variación del número de autovectores del Laplaciano (k). Incrementamos el parámetro a $k = 6$, $k = 8$ y $k = 10$ para comprobar si proporcionar mayor información de la topología ayuda a la red a clasificar mejor.

7.5.1. Justificación teórica

Al tratar con redes de colaboración científica que poseen una alta densidad (un grado medio cercano a las 44 aristas por nodo), una resolución de $k = 4$ nos proporciona una visión global de la comunidad. Incrementar el parámetro a $k = 6, 8, 10$ busca proporcionar a la red de mayor información espacial. El objetivo es comprobar si esta información extra permite a los modelos superar su límite actual (estancado en torno al 75 % de precisión).

7.5.2. Análisis de Resultados

Las métricas obtenidas tras aumentar k se presentan en la Tabla 44. Se omite el modelo base GCN ya que no hace uso de este hiperparámetro.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
k = 6						
GCNEig	32	3	Max	6	74.22 $\pm$ 1.12	74.50 $\pm$ 1.40
GCNEigDec.	32	4	Max	6	74.12 $\pm$ 0.82	73.92 $\pm$ 1.24
k = 8						
GCNEig	32	3	Max	8	74.37 $\pm$ 1.00	74.62 $\pm$ 1.21
GCNEigDec.	32	4	Max	8	74.65 $\pm$ 0.80	74.47 $\pm$ 1.37
k = 10						
GCNEig	32	3	Max	10	74.22 $\pm$ 1.44	74.64 $\pm$ 0.84
GCNEigDec.	32	4	Max	10	74.45 $\pm$ 0.83	74.67 $\pm$ 1.50

Tabla 44: Impacto de la alta resolución geométrica (k) en el rendimiento para COLLAB.

Al analizar las métricas, observamos que, a diferencia de otros conjuntos, en COLLAB incrementar la información geométrica no se traduce en un mayor rendimiento, si no que se mantiene estable.

Para GCNEig, aumentar la resolución mantiene la red estable, fluctuando entre el 74,50 % (con $k = 6$) y el 74,64 % (con $k = 10$). Sin embargo, ninguna de estas configuraciones logra superar el **74,85 %** que este modelo registró en el Experimento 3 utilizando únicamente 4 autovectores.

De forma similar, GCNEigDecoupled sufre un ligero retroceso inicial al subir a $k = 6$ (cayendo al 73,92 %) y, aunque se recupera progresivamente hasta alcanzar un 74,67 %

con $k = 10$, se queda lejos del **75,21 %** logrado en el Experimento 4, también con $k = 4$.

Cabe destacar que, a pesar de no mejorar el *accuracy*, las redes demuestran robustez. Las precisiones de entrenamiento y validación siguen prácticamente calcadas, sin rastro de memorización, sin colapsar por ruido ni sufrir *overfitting*.

Esta estabilización nos dice que los primeros 4 autovectores contienen toda la información necesaria para diferenciar las ramas de la física. Las frecuencias más altas ($k \geq 6$) aportan detalles locales que resultan ser irrelevantes.

Seleccionamos el modelo `GCNEigDecoupled` (32 canales, 4 capas, `Max Pool`, $k = 4$) como el ganador absoluto en este conjunto de datos (75,21 %), seguido muy de cerca por `GCNEig` (32 canales, 3 capas, `Max Pool`, $k = 4$) por su gran eficiencia.

7.6. Evaluación del modelo Net

Para terminar con el análisis del *dataset* COLLAB, se ha ejecutado una *run* del modelo `Net` utilizando la semilla de reproducibilidad 12345. El objetivo de esta prueba es evaluar una arquitectura que incorpora técnicas de agrupamiento jerárquico y que, en principio, debería ofrecer un rendimiento superior al de los modelos convolucionales vistos.

7.6.1. Configuración del modelo

Este modelo incorpora una técnica de reducción de dimensionalidad espacial más avanzada (`MinCut Pool`). Para esta prueba final, se ha configurado la red con 64 *hidden channels*.

- **Canales Ocultos (*Hidden Dim*):** 64
- **Número de Capas:** 2
- **Pooling:** `MinCut Pool`
- **Resolución Espectral (k):** 10

7.6.2. Análisis de resultados

Al ejecutar el modelo con la semilla indicada, se han obtenido los siguientes resultados:

- **Modelo con 64 canales:**

- **Precisión en Entrenamiento (Train Accuracy):** 70,40 %
- **Precisión en Validación (Test Accuracy):** 71,99 %

A diferencia de lo que cabría esperar de una arquitectura teóricamente más compleja, los resultados se quedan a más de 3 puntos porcentuales de distancia del **75,21 %** logrado por nuestra propia arquitectura **GCNEigDecoupled** en el Experimento 4. Este contraste pone en valor el trabajo realizado en nuestros modelos.

Además, se ha probado el modelo Net con 32 canales y se han encontrado dificultades y colapsos numéricos por divisores cercanos a cero, independientemente de la *learning rate*. Esto nos dice que la técnica **MinCut Pool** resulta ser una estrategia inestable en para este conjunto de grafos.

7.7. Conclusiones y comparación con la tesis

Tras completar la fase de experimentación, en esta sección se resumen los principales resultados y se analiza la visualización de sus espacios latentes.

En la Tabla 45 se presentan las mejores configuraciones alcanzadas para cada tipo de red.

Modelo	Hidden Dim.	Num. Layers	Pooling	k	Train Acc. $\pm$ Std	Test Acc. $\pm$ Std
GCN	64	3	Mean	0	73.73 $\pm$ 0.60	74.07 $\pm$ 1.36
GCNEig	32	3	Max	4	74.28 $\pm$ 0.52	74.85 $\pm$ 1.03
GCNEigDec.	32	4	Max	4	73.41 $\pm$ 1.04	75.21 $\pm$ 0.88

Tabla 45: Comparativa de los mejores modelos por arquitectura para el dataset COLLAB.

Justificación de la selección: No ha sido posible mejorar los resultados del modelo **GCN** con cambios de profundidad ni de anchura, manteniéndose la configuración inicial como la más óptima. Por el contrario, los modelos espectrales encontraron una ventaja al reducir su capacidad a 32 canales y al utilizar **Global Max Pool** para identificar a los nodos principales. Además, mientras que **GCNEig** funcionó mejor con 3 capas, el modelo **GCNEigDecoupled** demostró una gran resistencia al *oversmoothing*, utilizando 4 capas para mejorar la clasificación. La alta conectividad de estos grafos hizo que la resolución espectral base ($k = 4$) fuera suficiente, ya que las frecuencias altas ($k \geq 6$) resultaron redundantes.

7.7.1. Análisis visual del espacio latente (t-SNE)

Para validar la calidad de estas representaciones y entender cómo los modelos separan las redes según las 3 categorías, se ha proyectado el espacio latente de la última capa mediante el algoritmo t-SNE (Figura 12).




Figura 12: Evolución del Espacio Latente t-SNE para los modelos en COLLAB (GCN: $k = 0$, Modelos espectrales: $k = 4$).

Al tratarse de un problema de tres clases equitativamente balanceadas (puntos rojos, azules y grises), buscamos observar la formación de tres clústeres bien definidos. De la Figura 12 podemos extraer la siguiente información:

- **GCN (Izquierda):** Se observa una estructura solapada y caótica. Aunque se percibe un ligero agrupamiento de puntos grises y rojos, la gran mayoría están mezclados. La ausencia de información topológica impide a la red encontrar diferencias entre los distintos campos de la física.
- **GCNEig (Centro):** Se percibe un agrupamiento más marcado, situándose los puntos grises a la izquierda, los rojos en el centro y los naranjas a la derecha aunque no hay fronteras de decisión claras. Añadir los autovectores del Laplaciano permite a la red comprender mejor las redes.
- **GCNEigDecoupled (Derecha):** No se aprecia una gran mejora respecto al gráfico anterior, pareceme estar separados en 3 grupos aunque todavía no hay fronteras de decisión claras, teniendo puntos mal situados.

7.7.2. Conclusión final y comparación con la tesis

El modelo ganador absoluto en este conjunto de datos es el **GCNEigDecoupled con 32 canales, 4 capas, Max Pool y $k = 4$** , logrando una precisión en validación del **75,21 %** y una de las mayores estabilidades de todo el estudio ($\pm 0,88$).

En la tesis de referencia [1], se reporta un rendimiento de $77,50\% \pm 0,50$ para este conjunto de datos, utilizando una arquitectura **GatedGCN** combinada con una codificación posicional basada en caminos aleatorios (*Random Walk Positional Encoding - RWPE*).

Aunque nuestra arquitectura no logra superar esta referencia (quedando a 2,29 puntos porcentuales de distancia), los resultados obtenidos son un éxito. Hemos conseguido alcanzar un rendimiento superior al 75 % utilizando una base convolucional estándar (**GCNConv**), inmensamente más simple y ligera que el mecanismo de puertas y atención paramétrica de una **GatedGCN**. Además, mientras que la arquitectura **Net** analizada previamente se quedó en un 71,99 % debido a la extrema densidad de estos grafos, nuestra estrategia de desacoplamiento espectral combinada con el submuestreo de *Local Degree Profile* ha demostrado ser una solución robusta y eficiente.

Referencias

- [1] Ahmed Begga. Empirical eigenfunctions for graph neural networks, 2025.